

R-Stars Lite

Análisis de datos con R y sin vértigo

Miguel Ángel Tarancón Morán

Catedrático de Economía Aplicada
Universidad de Castilla-La Mancha

R-Stars Lite

© 2026 Miguel Ángel Tarancón Morán

Esta obra está publicada bajo una licencia Creative Commons Atribución-NoComercial-SinDerivadas 4.0 Internacional (CC BY-NC-ND 4.0): https://creativecommons.org/licenses/by-nc-nd/4.0/deed.es. Puede descargarse, leerse, imprimirse y compartirse libremente citando al autor, sin fines comerciales y sin distribuir versiones modificadas. Véase el apartado *Licencia* al final del libro.

Versión en línea, siempre actualizada: https://teckel71.github.io/RStarslite-book/

Este PDF se generó el 30 de octubre de 2026.

Índice general

Prefacio **7**

Correspondencia con *R-Stars: La Guía* 8

1. Introducción. **9**

1.1. De los datos a la información: la analítica de datos. 9

1.2. ¿Qué es R y cómo nos ayuda a analizar datos? 10

1.3. Instalación de R y RStudio. 10

1.4. R y RStudio. Comienzo: Proyectos. 11

1.5. Scripts. 12

1.6. Funciones. 13

1.7. Paquetes (*packages*). 14

1.8. Help! (sistema de ayuda). 15

1.9. El universo R-Stars. 15

1.10. ¿Y ahora? 15

2. Almacenando y manipulando datos. **17**

2.1. Objetos. Datos. 17

2.2. Importando datos. 21

2.3. Manipulando datos con `{dplyr}`. 23

2.4. Las variables de la base de datos del proyecto R-Stars. 27

2.5. Materiales para realizar las prácticas del capítulo. 27

3. Análisis previo de datos. **29**

3.1. Introducción. 29

3.2. Encargo de la ARTI: auditoría sectorial. 30

3.3. Análisis de una variable. 33

3.4. Análisis de múltiples variables. 45

3.5. Materiales para realizar las prácticas del capítulo. 52

4. Componentes principales. **53**

4.1. Introducción. . . . 53
4.2. Información y varianza. . . . 54
4.3. La elección de *Arg-Us Korp*. . . . 55
4.4. Preparación previa de datos. . . . 57
4.5. Correlaciones e idoneidad del análisis. . . . 61
4.6. Cálculo de componentes. . . . 66
4.7. Retención de componentes. . . . 67
4.8. Puntuaciones de los casos (scores). . . . 69
4.9. Efecto de los *outliers* en las puntuaciones. . . . 71
4.10. La decisión de *Arg-Us Korp*. . . . 72
4.11. Materiales para realizar las prácticas del capítulo. . . . 74

5. Análisis clúster jerárquico. **75**

5.1. Introducción. . . . 75
5.2. El Informe *Bluebird*. . . . 77
5.3. Análisis jerárquico: el método de Ward. . . . 78
5.4. Materiales para realizar las prácticas del capítulo. . . . 93

6. Modelos de elección discreta. **95**

6.1. Introducción. . . . 95
6.2. Clasificación de los modelos de elección discreta. . . . 96
6.3. El modelo de respuesta binaria. . . . 96
6.4. El modelo logit binomial. . . . 97
6.5. Práctica: ¿qué determina la concesión de licencias en el sector interestelar? . . . 99
6.6. Capacidad predictiva del modelo. . . . 109
6.7. Simulación de escenarios. . . . 110
6.8. Selección automática de la especificación. . . . 113
6.9. Cierre: el veredicto de *Data-Evidence*. . . . 115
6.10. Materiales para realizar las prácticas del capítulo. . . . 116

7. Tablas de contingencia. **117**

7.1. Introducción. . . . 117
7.2. Asociación entre dos atributos: la prueba ji-cuadrado. . . . 118
7.3. Medidas de asociación. . . . 118
7.4. Práctica: el entramado comercial del cosmos. . . . 119
7.5. Materiales para realizar las prácticas del capítulo. . . . 128

8. Escalado multidimensional. **129**

8.1. Introducción: los mapas perceptuales. . . . 129

8.2. Escalado Multidimensional: concepto y tipos. . . . 130

8.3. El algoritmo SMACOF y el Stress. . . . 131

8.4. Práctica: el mapa perceptual del sector interestelar. . . . 133

8.5. Cierre: el informe de *Data-Evidence*. . . . 144

8.6. Materiales para realizar las prácticas del capítulo. . . . 144

Bibliografía **145**

Apéndice: Guía de uso de `MATlite`. **147**

Qué es `MATlite` y cómo funciona. . . . 147

Funciones generales. . . . 148

Análisis previo de datos. . . . 149

Componentes principales. . . . 151

Análisis clúster jerárquico. . . . 152

Modelos de elección discreta. . . . 153

Tablas de contingencia. . . . 155

Escalado multidimensional. . . . 156

Funciones auxiliares. . . . 156

Licencia **159**

Cita sugerida 159

BibTeX 159

Prefacio



Figura 0.1. ESTRELLAS... Y R.

R-Stars Lite es la versión reducida de *R-Stars: La Guía*, pensada para la asignatura **Métodos Aplicados al Análisis del Entorno Empresarial** del Máster Universitario en Iniciativa Empresarial: Análisis y Estrategias de la Universidad de Castilla-La Mancha.

Comparte con *La Guía* la teoría, los casos prácticos y los datos: las mismas empresas de **transporte interestelar de mercancías** del proyecto **R-Stars**, los mismos encargos y los mismos resultados. Lo que cambia es **el modo de llegar a ellos**.

En *La Guía*, cada práctica se resuelve con un *script* que escribe paso a paso todo el código: importar, depurar, calcular, dibujar y dar formato a cada tabla. En *R-Stars Lite*, ese código está **empaquetado** en las funciones del paquete **`{MATlite}`**, de modo que cada paso del análisis se hace con **una sola línea**. Se pierde flexibilidad, sí, pero se gana lo más importante en un primer contacto con R: tiempo y atención para lo que de verdad importa, que es **plantear bien el análisis e interpretar sus resultados**.

Todas las funciones de `{MATlite}` empiezan por `lite_`. Basta con escribir esas cinco letras en RStudio para que el autocompletado las muestre todas. El apéndice *Guía de uso de MATlite* recoge la ficha de cada una.

Correspondencia con *R-Stars: La Guía*

R-Stars Lite	*R-Stars: La Guía*	Contenido
1. Introducción	1	R, RStudio y el paquete `{MATlite}`
2. Almacenando y manipulando datos	2	Importar, seleccionar, filtrar y ordenar datos
3. Análisis previo de datos	5	Valores ausentes, *outliers*, descripción, normalidad y correlación
4. Componentes principales	6 (sin 6.10)	Adecuación, componentes, retención y *rankings*
5. Análisis clúster jerárquico	7 (solo 7.3)	Método de Ward
6. Modelos de elección discreta	10	Modelo logit binomial
7. Tablas de contingencia	11 (hasta 11.2)	Contraste ji-cuadrado y medidas de asociación
8. Escalado multidimensional	12	Mapas perceptuales

Tabla 0.1

Quien quiera ver el código completo que hay detrás de cada función, o ampliar el análisis, encontrará en *La Guía* los *scripts* originales de cada práctica.

Sobre el carácter gratuito de este libro. Este manual es, y seguirá siendo, de acceso libre y gratuito. Se agradecen tanto los comentarios y sugerencias que ayuden a su mejora, como su cita en aquellos documentos en los que se utilice como referencia. La referencia recomendada, en formato APA, es la siguiente:

> Tarancón Morán, M. Á. (2026). *R-Stars Lite* [libro electrónico]. Universidad de Castilla-La Mancha. https://teckel71.github.io/RStarslite-book/

CAPÍTULO 1

Introducción.

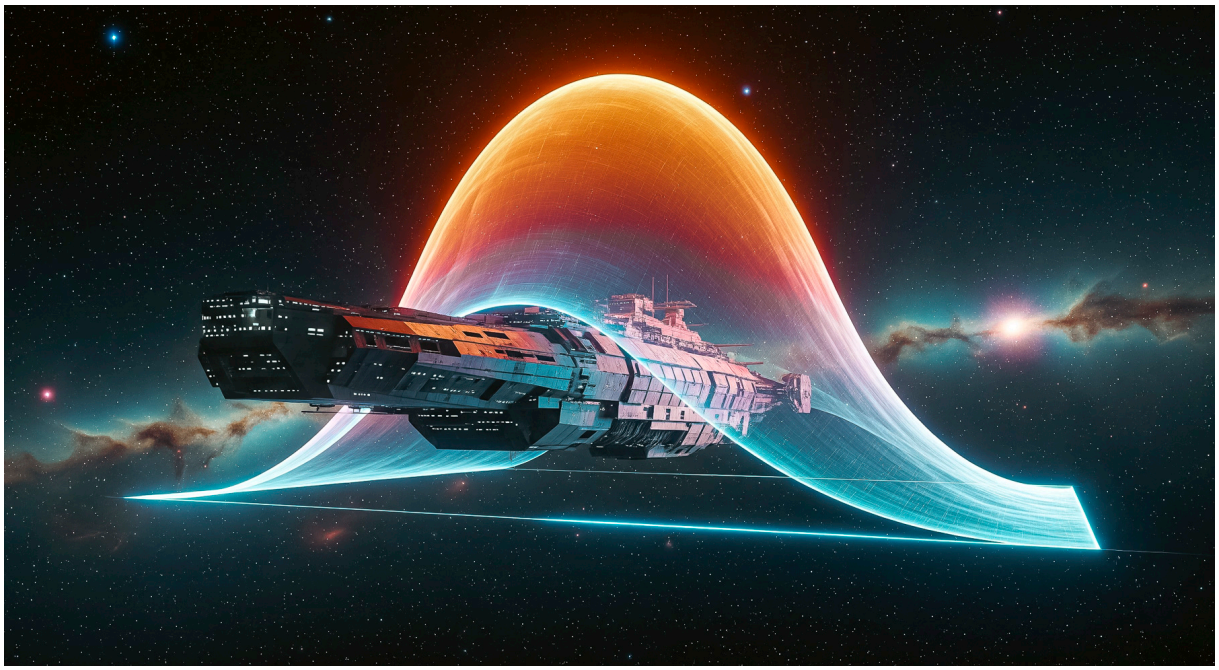


Figura 1.1. La distribución Normal...

1.1 De los datos a la información: la analítica de datos.

Vivimos rodeados de datos. Las administraciones públicas los recopilan para diseñar políticas; las empresas los generan en cada transacción; los mercados financieros los emiten segundo a segundo. Pero los datos, por sí solos, no son más que registros en bruto: cifras de ventas, cotizaciones, respuestas a una encuesta, indicadores macroeconómicos. Su verdadero valor aparece cuando somos capaces de transformarlos en **información** que sirva de base para la **toma de decisiones**.

Un gestor público quiere saber si una política de empleo está funcionando; una empresa aspira a anticipar la demanda o a conocer mejor a su competencia; un emprendedor necesita saber cómo es el sector en el que pretende entrar. En todos estos casos el punto de partida son datos, y el objetivo, extraer de ellos información fiable.

La ciencia que se ocupa de este tránsito del dato a la información es la **Estadística**, una **ciencia instrumental** que dota al resto de disciplinas de herramientas para recopilar datos de forma sistemática, organizarlos y extraer de ellos información relevante. Como señalan Mood y Graybill (1963):

"La Estadística es la tecnología del método científico."

La explotación de los datos y su conversión en información es lo que hoy se conoce como **analítica de datos** (*data analytics*). Este libro se sitúa precisamente en ese terreno, aplicado a problemas de naturaleza económica y empresarial: el análisis del **entorno** en el que operan las empresas.

Para llevar a cabo esta analítica, además de los datos y de los conocimientos metodológicos, resulta imprescindible contar con un **software** adecuado. En nuestro caso, la herramienta elegida es **R**.

1.2 ¿Qué es R y cómo nos ayuda a analizar datos?

R no es una aplicación al uso, sino todo un **lenguaje de programación** orientado principalmente a la analítica de datos, sobre todo desde una perspectiva estadística. Se distribuye como software libre y gratuito, y es multiplataforma, rasgos que han facilitado su difusión y el surgimiento de una comunidad muy activa de usuarios y desarrolladores.

R nos ofrece un ecosistema idóneo para cubrir todas las etapas de un proyecto de analítica de datos: desde la importación y depuración de los datos, pasando por su exploración gráfica y descriptiva, hasta la estimación de modelos y la presentación de resultados.

¿Y si nunca hemos programado? No hay de qué preocuparse. En este libro, buena parte del código está **empaquetado** en las funciones del paquete `{MATlite}`, de modo que cada paso del análisis se resuelve con una sola línea. Nuestro esfuerzo se concentrará en lo verdaderamente importante: **plantear bien el análisis e interpretar sus resultados**.

1.3 Instalación de R y RStudio.

Instalar R resulta sencillo: basta con acudir a la web de CRAN (*Comprehensive R Archive Network*), descargar la última versión disponible para nuestro sistema operativo (en este manual, Microsoft® Windows®) y ejecutar el archivo descargado, que completará la instalación.

R arrastra, eso sí, una limitación: el programa a través del cual interactuamos con el lenguaje resulta muy poco amigable. Para salvar este inconveniente utilizaremos **RStudio**, un entorno de trabajo (IDE) desarrollado por Posit® Software. También es gratuito, así que de nuevo bastará con visitar la web de RStudio y descargar e instalar la versión libre de coste.

Importante: hay que instalar **los dos programas**, primero R y después RStudio. A partir de ese momento trabajaremos siempre desde RStudio, que utiliza R "por debajo".

1.4 R y RStudio. Comienzo: Proyectos.

Con R y RStudio ya instalados, podemos ponernos manos a la obra. Abriremos RStudio pulsando en el icono correspondiente y aparecerá la siguiente ventana:

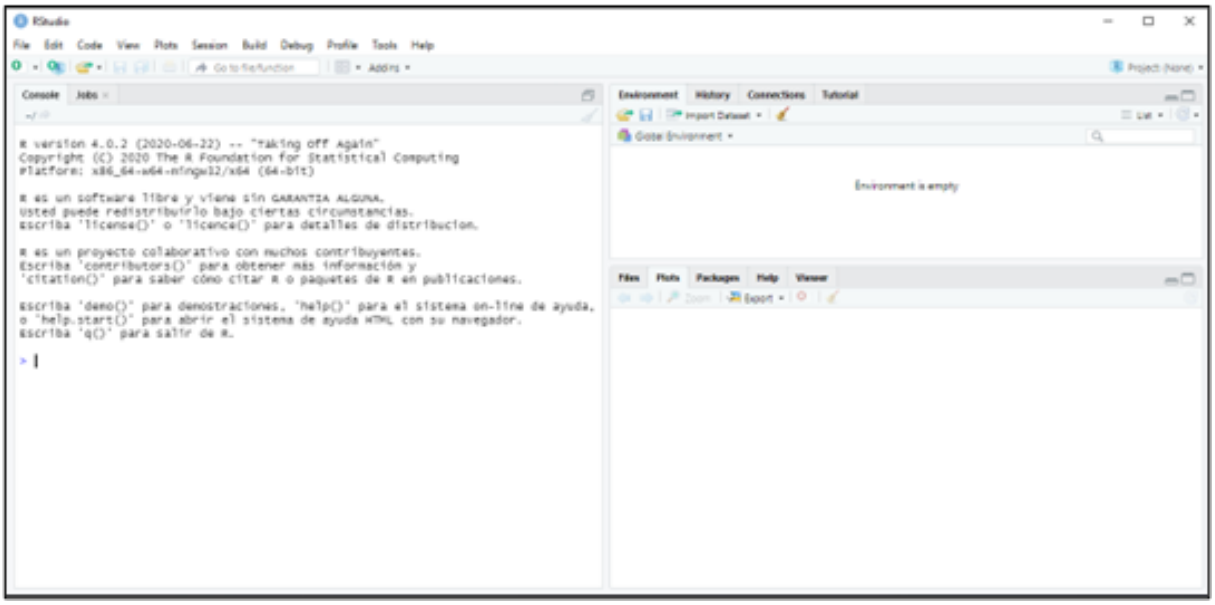


Figura 1.2. IDE DE RSTUDIO.

La parte izquierda de la ventana es la **consola**: la sección de RStudio desde la que manejamos R introduciendo código directamente. Escribamos, por ejemplo, `2+2` después del cursor (signo ">") y pulsemos `Enter`. La propia consola nos devolverá el valor 4:

```
2+2
```

```
## [1] 4
```

Con todo, la forma más eficiente de trabajar es mediante **proyectos** y **scripts**.

Un **proyecto** se asocia, en esencia, a la carpeta en la que R trabajará: allí buscará los datos que le sirven de *input* y allí depositará, llegado el caso, los resultados u *output*. Al abrir un proyecto desde RStudio le estamos indicando al programa que busque de forma preferente en esa carpeta todos los archivos que necesite y que guarde en ella lo que vaya generando. Así evitaremos el error más frecuente de quien empieza con R: que el programa "no encuentre" el archivo de datos.

Para crear un proyecto nuevo seguiremos la ruta `File → New Project`. El programa nos preguntará entonces si deseamos crearlo en una carpeta nueva o en una ya existente. Situémoslo, por ejemplo, en una carpeta llamada "explora", que ya tenemos preparada. Aparecerá una ventana para localizar la carpeta y, una vez encontrada, pulsaremos `Open` y `Create Project`. El proyecto ya está creado.

Si ahora abrimos el explorador de Windows® y buscamos la carpeta "explora", veremos en ella un archivo del mismo nombre, identificado con el icono de un cubo con una "R". Ese archivo actúa como un faro: le indica a R que, mientras trabajemos en el proyecto "explora", encontrará

en esa carpeta todos los datos que necesite y que en ella deberá depositar los ficheros de salida que produzca.

En sesiones posteriores, para retomar el mismo proyecto ya no recurriremos a `File → New Project`, sino a `File → Open Project` (o, sencillamente, haremos doble clic sobre ese archivo).

1.5 Scripts.

Los **scripts**, por su parte, son programas o rutinas en los que varias instrucciones se ejecutan de forma secuencial. Para crear uno seguiremos la ruta `File → New File → R Script`. ¿Y dónde se guardará? En la carpeta "explora", la del proyecto en el que estamos trabajando.

Observaremos que en la parte izquierda de RStudio ha surgido una ventana nueva, situada arriba, que desplaza la consola hacia abajo. Es la ventana del **editor**:

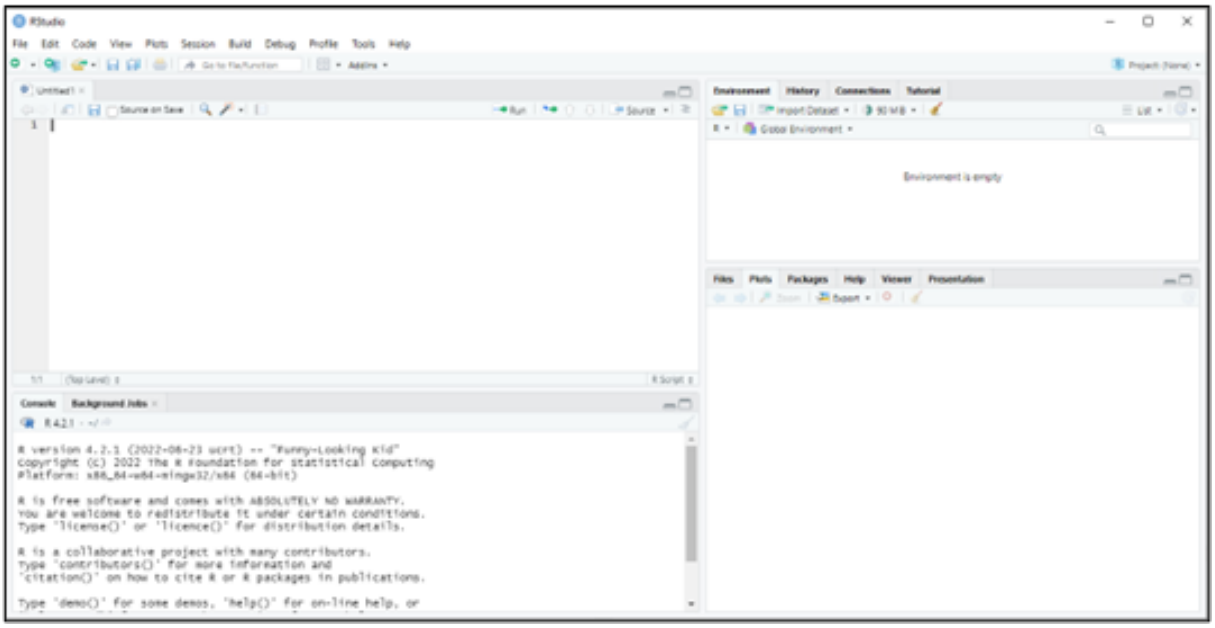


Figura 1.3. EL EDITOR DE SCRIPTS DE RSTUDIO.

Empecemos a escribir nuestro script. Cuando queramos introducir un comentario que no ejecute instrucción alguna, lo precederemos del símbolo almohadilla o *hashtag* "#". A continuación pediremos a R que realice la suma 2+2. Escribimos, por tanto, en el editor:

```
#Ejemplo de Script
2+2  #este script hace una simple suma.
```

Para ejecutar la línea en la que se encuentra el cursor bastará con pulsar `Control + ENTER` o el botón `Run`; y si queremos ejecutar varias líneas, las seleccionaremos previamente y emplearemos esas mismas opciones. Para ejecutar el script completo, `Control + Mayúsculas + ENTER`. En la consola aparecerá:

```
## [1] 4
```

Guardaremos el script con `File → Save As...`; y, de nuevo, el destino predeterminado será la carpeta "explora", la de nuestro proyecto. Llamémoslo, por ejemplo, "explorando". En la carpeta del proyecto encontraremos un archivo de texto llamado "explorando.R". Podremos ejecutarlo cuantas veces queramos sin necesidad de teclear nada, o modificarlo si necesitamos introducir cambios. Ahí reside, precisamente, la ventaja de trabajar con scripts.

En las prácticas de este libro no tendremos que escribir los scripts desde cero: cada capítulo ofrece, en su última sección, el script de la práctica listo para descargar. Bastará con guardarlo en la carpeta del proyecto y abrirlo con `File → Open File...`.

1.6 Funciones.

R trabaja fundamentalmente con datos y funciones. Pero ¿qué es exactamente una **función**?

Una función es un conjunto o **sistema de instrucciones** que convierte unos datos de entrada o **inputs** en unos datos de salida o **outputs**. Puede ser muy sencilla o realmente compleja. Sus partes básicas son:

- **Entradas, *inputs* o argumentos:** son las informaciones necesarias para llevar a cabo el procedimiento. Se escriben entre los paréntesis que siguen al nombre de la función, separadas por comas. Algunos argumentos tienen un valor **por defecto**, que la función utiliza si no le indicamos otro.
- **Cuerpo:** el conjunto de instrucciones que transforman las entradas en salidas.
- **Salidas:** los resultados u *outputs* de la función.

A modo de ejemplo, creemos una función llamada "suma", que recibirá dos argumentos —dos números cualesquiera— y devolverá como resultado la suma de ambos:

```
suma <- function(x, y) {
  resultado <- x + y
  return(resultado)
}
```

Una vez ejecutado el código anterior, para sumar los números 12 y 16 solo tendremos que escribir:

```
suma(x=12, y=16)
```

```
## [1] 28
```

Las funciones de `{MATlite}` que utilizaremos a lo largo del libro son exactamente eso: funciones como "suma", solo que su cuerpo contiene decenas de instrucciones que no necesitamos ver. Nosotros nos limitaremos a indicarles los argumentos —los datos, las variables, algún título— y a interpretar sus salidas.

1.7 Paquetes (*packages*).

En torno a R se ha desarrollado una cantidad casi inimaginable de recursos: funciones, bases de datos, utilidades... Estos recursos se organizan en **paquetes** (*packages*, en inglés). Un paquete es una colección de funciones o un conjunto de datos desarrollados por la comunidad de R, que amplían las capacidades básicas del lenguaje.

La mayor parte de los paquetes reside en diversos servidores denominados repositorios. El más importante es CRAN, el repositorio oficial, que alberga más de 20.000 paquetes, si bien existen otros, entre los que destaca GitHub.

Con los paquetes hay que distinguir dos operaciones:

- **Instalarlos**, es decir, descargarlos en nuestro ordenador. Se hace **una sola vez**. Para los paquetes de CRAN, basta con acudir a la ventana inferior derecha de RStudio, pestaña "Packages", botón "Install", o con la instrucción `install.packages("nombre del paquete")`.
- **Activarlos**, es decir, ponerlos a disposición de R en la sesión de trabajo. Se hace **cada vez** que abrimos RStudio, con la instrucción `library(nombre del paquete)`. Por eso todos los scripts del libro comienzan con una llamada a `library()`.

1.7.1 El paquete `{MATlite}`.

El paquete que utilizaremos a lo largo de todo el libro es `{MATlite}`. No está alojado en CRAN, sino en GitHub, así que se instala de un modo ligeramente distinto. Primero instalaremos, desde CRAN, el paquete `{remotes}`, que sabe descargar paquetes de GitHub, y después `{MATlite}`:

```
# Instalación (una sola vez)
install.packages("remotes")
remotes::install_github("teckel71/MATlite")
```

La instalación tarda unos minutos, porque `{MATlite}` trae consigo todos los paquetes que utiliza por dentro (`{readxl}`, `{dplyr}`, `{ggplot2}`, etc.). Si durante el proceso R pregunta si se desean actualizar otros paquetes, lo más sencillo es responder que sí a todos (opción "All").

Una vez instalado, en cada sesión de trabajo bastará con activarlo:

```
# Activación (cada vez que abrimos RStudio)
library(MATlite)
```

Todas las funciones de `{MATlite}` empiezan por `lite_`. Basta con escribir esas cinco letras en RStudio para que el autocompletado las muestre todas. Las dos primeras que conviene conocer son:

- **`lite_comprueba()`**: revisa que R y todos los paquetes necesarios estén correctamente instalados, y nos indica qué hacer si falta algo. Es una buena idea ejecutarla la primera vez.

- **`lite_datos()`**: descarga en la carpeta del proyecto los archivos de datos que utilizaremos en las prácticas.

```
lite_comprueba()   # ¿está todo listo?
lite_datos()       # descarga los datos del curso en la carpeta del proyecto
```

1.8 Help! (sistema de ayuda).

Es habitual albergar dudas sobre el uso de una función: qué argumentos admite, qué valores toman por defecto, qué resultados devuelve. Para consultarlo basta con escribir en la consola un signo de interrogación seguido del nombre de la función:

```
?lite_describe
```

La ficha de la función aparecerá en la pestaña **"Help"** de la ventana inferior derecha de RStudio, con la descripción de sus argumentos y algunos ejemplos de uso. Las fichas de todas las funciones de `{MATlite}` están, además, en el apéndice *Guía de uso de MATlite* al final del libro.

1.9 El universo R-Stars.

Los ejemplos de este libro se apoyan en un escenario ficticio: el **universo R-Stars**, ambientado en un hipotético sector de transporte interestelar de mercancías en el año 2150. Este universo proporciona una base de datos con 300 empresas caracterizadas por variables económico-financieras y operativas, lo que permite aplicar cada técnica a datos con una estructura realista, pero sin las restricciones de confidencialidad asociadas a datos reales.

La descripción completa del universo R-Stars —la historia del sector, las empresas más relevantes y la ficha de todas las variables— puede consultarse en los apéndices de *R-Stars: La Guía*.

1.10 ¿Y ahora?

Ya tenemos R, RStudio y `{MATlite}` instalados, y sabemos crear proyectos, abrir y ejecutar scripts y consultar la ayuda. En el siguiente capítulo aprenderemos cómo almacena R los datos y cómo importarlos y manipularlos.

CAPÍTULO 2

Almacenando y manipulando datos.

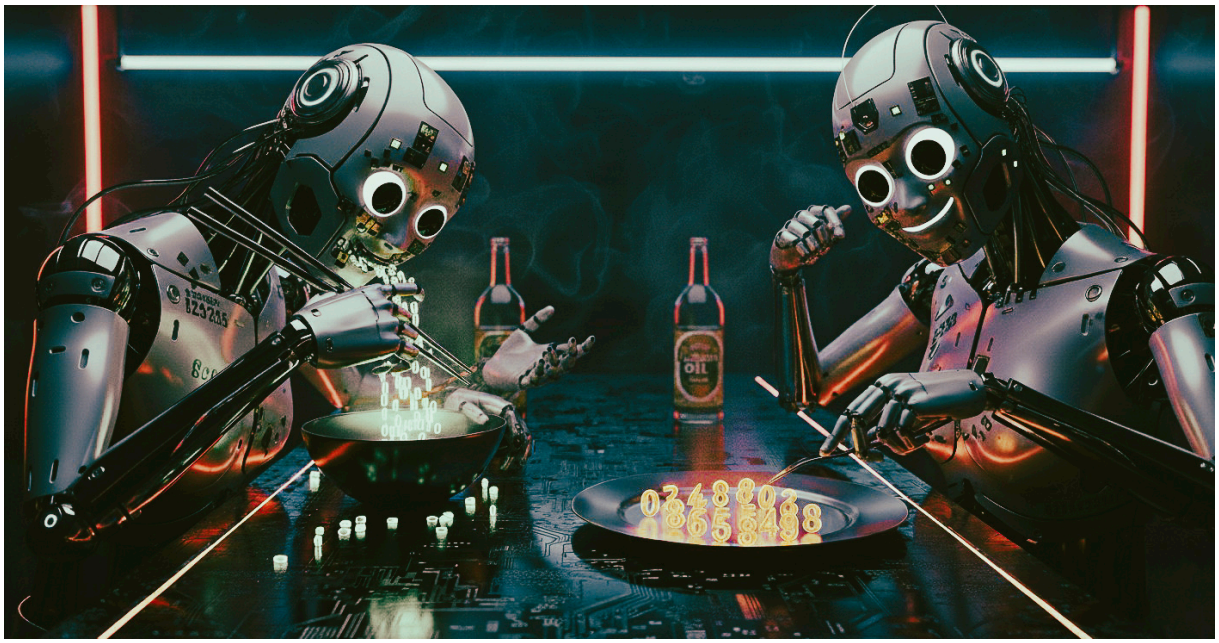


Figura 2.1. ¡DATOS, DATOS!

2.1 Objetos. Datos.

Como vimos en el capítulo 1, R es interactivo: responde a las instrucciones que recibe, ya sea desde la consola o desde un script. Esas instrucciones actúan sobre **objetos**: estructuras o *contenedores* diseñados para almacenar datos y resultados. Los más importantes para nosotros son:

- Vectores.
- *Data frames*.
- Factores.
- Listas.

Los datos almacenados en los objetos pueden ser, básicamente, de tres tipos: números (`numeric`), cadenas de texto (`character`) o valores lógicos, verdadero o falso (`logical`).

Situémonos en el proyecto que creamos en el capítulo anterior (proyecto "explora") y abramos un script nuevo para practicar.

2.1.1 Vectores.

Los **vectores** son conjuntos de elementos **del mismo tipo**. Definamos, por ejemplo, el vector x = (1,3,5,8). Para ello escribiremos en nuestro script:

```
x <- c(1,3,5,8)
```

Ejecutamos la línea situando el cursor en cualquier punto de ella y pulsando a la vez las teclas `Control + Enter` (o haciendo clic en el botón `Run` del editor). Ya tenemos en memoria nuestro primer objeto. Conviene reparar en que acabamos de realizar una **asignación**: una flecha formada por los signos "<" y "-" traslada al vector llamado "x" los elementos 1, 3, 5 y 8, que hemos reunido con la función `c()` (de *combinar*).

Para ver su contenido basta con escribir el nombre del vector, "x":

```
x
```

```
## [1] 1 3 5 8
```

Si además dirigimos la mirada a la ventana superior derecha de RStudio, comprobaremos que el ***Global Environment*** —la ventana que recoge los objetos que R mantiene en memoria— muestra nuestro vector:

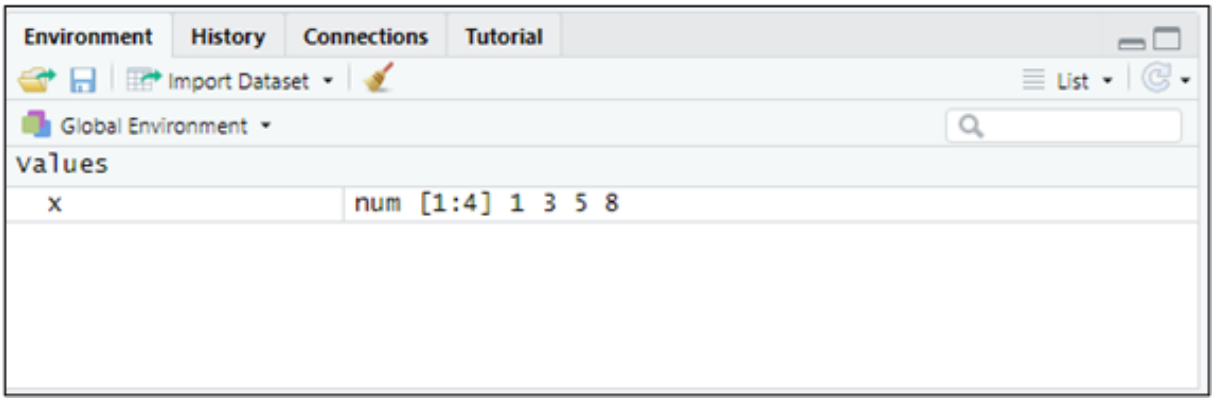


Figura 2.2. NUESTRO VECTOR EN MEMORIA.

Un vector puede albergar también cadenas de texto, siempre entrecomilladas. Sirva de ejemplo el vector "genero" (¡evitemos las tildes al nombrar los objetos o podemos encontrarnos con problemas!):

```
genero <- c("Mujer","Hombre")
genero
```

```
## [1] "Mujer"  "Hombre"
```

Cuando falta un dato en un vector, escribiremos "NA" (*not available*, no disponible). Por ejemplo, si no dispusiéramos del tercer dato del vector "Z", lo definiríamos así:

```
Z <- c(1,2,NA,2,8)
```

Para **seleccionar un elemento** concreto de un vector indicaremos, entre corchetes, la posición que ocupa. Así, para recuperar el tercer elemento del vector "x" haremos:

```
x[3]
```

```
## [1] 5
```

2.1.2 *Data frames.*

Un ***data frame*** es la estructura con la que más trabajaremos: una tabla en la que las filas son los distintos casos (empresas, personas...) y las columnas, las variables. Cada columna es un vector, y todas tienen la misma longitud.

Construyamos, por ejemplo, el *data frame* **"datos"**, con tres variables —peso, altura y color de ojos, a las que llamaremos "Peso", "Altura" y "Cl.ojos"— referidas a 3 personas. Definimos primero las tres variables como vectores y las reunimos después mediante la función `data.frame()`:

```
Peso <- c(68,75,88)
Altura <- c(1.6,1.8,1.9)
Cl.ojos <- c("azules","marrones","marrones")
datos <- data.frame(Peso, Altura, Cl.ojos)
datos
```

```
##   Peso Altura  Cl.ojos
## 1   68    1.6   azules
## 2   75    1.8 marrones
## 3   88    1.9 marrones
```

Para referirnos a una variable concreta de un *data frame* escribiremos el nombre del *data frame*, el símbolo **$** y el nombre de la variable:

```
datos$Peso
```

```
## [1] 68 75 88
```

Y para conocer el número de filas (casos) y de columnas (variables), las funciones `nrow()` y `ncol()`:

```
nrow(datos)
```

```
## [1] 3
```

```r
ncol(datos)
```

```
## [1] 3
```

2.1.3 Factores.

En R, un **factor** es un tipo especial de objeto destinado a representar **datos categóricos** o atributos: datos que no son magnitudes, sino que pertenecen a un conjunto limitado de categorías, también llamadas *niveles*. Pensemos en la variable "Cl.ojos": para R es, por ahora, un simple vector de texto. Para convertirla en un factor:

```r
Cl.ojosF <- factor(Cl.ojos)
Cl.ojosF
```

```
## [1] azules   marrones marrones
## Levels: azules marrones
```

"Cl.ojosF" es algo más que un vector de texto: es una variable cuyos elementos solo pueden adoptar dos valores categóricos, los niveles "azules" y "marrones".

¿Por qué conviene, a veces, transformar los datos categóricos en factores? Por dos razones principales:

- **Orden de las categorías**: podemos fijar en qué orden deben considerarse. Por ejemplo, el estado de una flota de naves puede ser "ANTIGUA", "MADURA" o "RENOVADA", un orden con significado.
- **Modelos estadísticos**: muchas técnicas reconocen automáticamente los factores como variables cualitativas y les aplican el tratamiento adecuado. Lo comprobaremos en el capítulo dedicado a los modelos de elección discreta, donde utilizaremos la función `lite_factor()` para convertir variables en factores y elegir su categoría de referencia.

2.1.4 Listas.

Por último, una **lista** es un tipo de objeto capaz de albergar en su interior prácticamente cualquier cosa: números, textos, vectores, *data frames*, gráficos, tablas... Podemos imaginarla como una caja organizadora con muchos compartimentos, en cada uno de los cuales cabe un objeto distinto. Creemos, por ejemplo, la lista "mi_lista":

```r
mi_lista <- list(
  nombre = "María",
  edad = 21,
  notas = c(8.5, 9.0, 7.2)
)
```

Para ver solo uno de sus compartimentos utilizaremos, como en los *data frames*, el símbolo `$` seguido de su nombre:

```
mi_lista$notas
```

```
## [1] 8.5 9.0 7.2
```

Las listas son muy importantes para nosotros, porque **así es como `{MATlite}` nos entrega los resultados de los análisis**: cada función de análisis devuelve una lista con todas sus tablas y gráficos. Escribiendo el nombre del objeto veremos todos sus resultados; escribiendo el nombre, `$` y el nombre de un compartimento, solo ese resultado. Lo veremos en acción a partir del capítulo 3.

2.2 Importando datos.

Lo habitual no es teclear los datos, como hemos hecho hasta ahora, sino importarlos a R desde algún archivo externo. En nuestro caso los traeremos desde Microsoft® Excel®. Guardemos en la carpeta del proyecto "explora" los dos archivos de esta práctica, cuyos enlaces de descarga figuran en la sección final del capítulo:

- Un archivo de Microsoft® Excel® llamado "interestelar_100.xlsx". También podemos descargarlo desde R con `lite_datos("interestelar_100")`.
- El script "datos_lite.R", con las instrucciones que vamos a mostrar a continuación.

Si abrimos el archivo "interestelar_100.xlsx", comprobaremos que consta de tres hojas: la primera recoge un aviso sobre el uso exclusivo que debe darse a los datos; la segunda describe las variables consideradas; y la tercera (hoja "Datos") contiene la información que vamos a **importar** desde RStudio. Se trata de variables económico-financieras y de otra índole, referidas a una muestra de empresas dedicadas al transporte interestelar de mercancías. Merece la pena fijarse en un detalle: algunas celdas sin dato aparecen en blanco, y otras, con el texto "n.d." (no disponible).

Abramos ahora el script "datos_lite.R" con `File → Open File…` (o haciendo clic sobre el archivo en la ventana inferior derecha de RStudio, pestaña "Files"). Sus primeras instrucciones son:

```
## Importando datos de las empresas R-Stars

# Limpiando el Global Environment
rm(list = ls())

# Cargando el paquete de la asignatura
library(MATlite)
```

La primera instrucción **limpia el *Global Environment*** (la memoria) de los objetos que hayan quedado de sesiones de trabajo anteriores. La segunda activa el paquete `{MATlite}`, que, como vimos, debe haberse instalado previamente.

Para importar los datos de la hoja "Datos" del archivo "interestelar_100.xlsx" utilizaremos la función `lite_importa()`:

```
# DATOS
interestelar_100 <- lite_importa("interestelar_100.xlsx")
```

En el *Global Environment* aparece ya un objeto: un *data frame* llamado "interestelar_100", con 104 filas (una por empresa) y 28 columnas (una por variable). `lite_importa()` ha hecho por nosotros tres cosas:

- Leer la hoja "Datos" del archivo (si la hoja se llamase de otro modo, la indicaríamos con el argumento `hoja =`).
- Registrar como dato faltante (*NA*) tanto las celdas en blanco como las que contienen "n.d." (si las ausencias se anotasen de otra forma, la indicaríamos con el argumento `na =`).
- Tomar la primera columna de la hoja —el nombre de cada empresa— como el **nombre de las filas** del *data frame*, y no como una variable más: no es una característica de las empresas, sino su identificador.

Para explorar el contenido del *data frame* de un vistazo disponemos de la función `lite_resumen()`:

```
# Resumen visual de las variables
lite_resumen(interestelar_100)
```

interestelar_100: 104 casos × 28 variables

Variable	Tipo	Categorías	Ausentes (%)	Media	Mediana	Desv. típica
SEDE	Categórica	29	0.0			
GALAXIA	Categórica	5	0.0			
ACTIVO	Métrica		1.0	259.98	159.08	445.21
FPIOS	Métrica		0.0	115.64	59.81	209.27
ING	Métrica		0.0	238.23	103.91	370.77
MARGEN	Métrica		1.0	60.35	56.72	16.93
RES	Métrica		0.0	128.22	54.61	192.45
SOLVENCIA	Métrica		0.0	179.49	174.67	30.71
ACTCOR	Métrica		0.0	64.64	23.58	130.38
PASCOR	Métrica		0.0	107.89	59.92	176.53
LIQUIDEZ	Métrica		0.0	0.66	0.70	0.23
APALANCA	Métrica		1.0	145.60	133.73	63.19
RENECO	Métrica		1.0	52.38	50.43	11.39
RENFIN	Métrica		0.0	121.54	119.24	32.84
EMPLEA	Métrica		1.0	35.78	30.00	19.72
FJUR	Categórica	3	0.0			
FLOTA	Métrica		0.0	27.35	24.50	13.77
COSTOP	Métrica		1.0	110.04	29.82	192.74
CAPEX	Métrica		0.0	39.39	11.16	110.46
IMD	Métrica		0.0	16.33	4.95	26.73
EFLO	Categórica	3	0.0			
RUTAS	Métrica		0.0	397.71	327.50	376.16
IDIG	Métrica		0.0	18.16	16.71	10.92
IDIVERSE	Métrica		1.0	23.81	22.39	13.18
IFIDE	Métrica		1.0	39.39	39.18	6.16
GMEDRUT	Métrica		1.0	0.33	0.20	0.31
DIST	Métrica		1.9	164.93	57.79	279.35
BMAL	Métrica		1.9	8292.13	1285.59	33732.37

Tabla 2.1

La tabla recoge una fila por variable, con su tipo (numérica o de texto), un pequeño gráfico de su distribución, el porcentaje de datos faltantes y, para las variables numéricas, la media, la mediana y la desviación típica.

2.3 Manipulando datos con `{dplyr}`.

El paquete `{dplyr}` ofrece una gramática sencilla para **manipular** *data frames*: seleccionar variables, ordenar casos, filtrarlos o crear variables nuevas. `{MATlite}` pone a nuestra disposición sus funciones principales, de modo que no hace falta activarlo por separado.

Todas las funciones de `{dplyr}` comparten tres rasgos:

- El primer argumento es el *data frame* con el que se va a trabajar.
- Los demás argumentos describen qué hacer con él. Las variables se escriben por su nombre, **sin utilizar el símbolo $**.
- El resultado es un **nuevo** *data frame*.

2.3.1 Seleccionando variables: `select()`.

La función `select()` se queda con las variables (columnas) que le indiquemos. Supongamos que solo nos interesan tres variables de "interestelar_100": ACTIVO, FPIOS y LIQUIDEZ. Crearemos con ellas un nuevo *data frame*, "interestelar_100A":

```
# Seleccionando variables
interestelar_100A <- select(interestelar_100, ACTIVO, FPIOS, LIQUIDEZ)
```

En el *Global Environment* figura ahora otro *data frame*, "interestelar_100A", con 3 variables y los mismos 104 casos. Para verlo, basta con escribir su nombre:

```
interestelar_100A
```

```
##                              ACTIVO    FPIOS  LIQUIDEZ
## hyperion star haulage        211.14  88.9400 0.5592011
## jovian logistics             220.56  78.9300 0.5358355
## sandworm freight              17.55   8.6700 0.9659574
## ripley interstellar freight   37.07  19.6300 0.8586790
## chakotay cargo systems      2158.69 971.4105 0.5963287
## dune dynamics                515.86 178.6400 0.4919417
## sith transport corp.         515.98 212.9600 0.6386439
## seven of nine logistics      477.80 215.0100 1.2580305
## moya cargo systems           520.29 169.4900 0.5264522
## travis star haulage          466.63 244.9200 0.4893415
```

(**Nota:** solo mostramos aquí los 10 primeros casos del *data frame*).

Si lo que queremos es **eliminar** una variable, basta con anteponer a su nombre el signo "-". Por ejemplo, para prescindir de la forma jurídica (FJUR):

```
interestelar_100B <- select(interestelar_100, -FJUR)
```

"interestelar_100B" tiene una variable menos (27) que "interestelar_100".

2.3.2 Ordenando casos: `arrange()`.

La función `arrange()` ordena los casos (filas) según los valores de una variable, de menor a mayor. Creemos, por ejemplo, el *data frame* "interestelar_100C" con las variables RENECO, EFLO y ACTIVO, y ordenémoslo según la rentabilidad económica (RENECO):

```
# Ordenando casos
interestelar_100C <- select(interestelar_100, RENECO, EFLO, ACTIVO)
interestelar_100C <- arrange(interestelar_100C, RENECO)
```

```
##                            RENECO     EFLO  ACTIVO
## mustafar haulage         28.04152   MADURA  183.05
## mos eisley haulage       31.05354   MADURA  186.42
```

```
## forest moon freight      32.46888   MADURA  222.49
## kelvin universe movers   33.67418  ANTIGUA   43.03
## io star transport        34.26908   MADURA  498.00
## event horizon haulage    35.31742   MADURA  204.46
## chakotay cargo systems   37.09704 RENOVADA 2158.69
## tannhäuser freight       37.33466   MADURA  190.52
## mon calamari freight co. 37.73973  ANTIGUA   29.20
## darth vader logistics    38.20225  ANTIGUA   29.37
```

Para ordenar de mayor a menor, envolveremos el nombre de la variable en la función `desc()`:

```
interestelar_100D <- arrange(interestelar_100C, desc(RENECO))
```

```
##                         RENECO     EFLO ACTIVO
## jovian logistics      93.84748   MADURA 220.56
## sandworm freight      89.40171  ANTIGUA  17.55
## hyperion star haulage 79.68646   MADURA 211.14
## vulcan star freight   74.21537   MADURA 226.22
## shuttlepod movers     72.50491   MADURA 249.39
## sdf-1 freightworks    68.66035  ANTIGUA  36.95
## betazoid transport    68.44444  ANTIGUA  56.25
## dagobah freightlines  66.83549 RENOVADA 511.39
## super star logistics  66.25660 RENOVADA 490.17
## moya cargo systems    66.05547 RENOVADA 520.29
```

2.3.3 El operador *pipe*.

Cuando necesitamos encadenar varias operaciones, resulta muy cómodo el **operador *pipe*** `%>%`: toma el resultado de lo que tiene a su izquierda y se lo pasa como primer argumento a la función que tiene a su derecha. Así, las dos operaciones del apartado anterior (seleccionar variables y ordenar casos) pueden escribirse en una sola secuencia:

```
interestelar_100C <- interestelar_100 %>%
  select(RENECO, EFLO, ACTIVO) %>%
  arrange(RENECO)
```

El código se lee de un modo muy natural: "toma `interestelar_100`, selecciona esas tres variables y ordena por RENECO". Lo utilizaremos con frecuencia en los capítulos siguientes, sobre todo para seleccionar las variables de un análisis:

```
seleccion <- interestelar_100 %>% select(IDIVERSE, IFIDE, IDIG)
```

2.3.4 Seleccionando casos: `filter()`.

La función `filter()` se queda con los casos que cumplen una o varias condiciones. Por ejemplo, para quedarnos con las empresas con un resultado (RES) mayor o igual a 500 miles de PAVOs, y mostrar solo sus valores de RES y RENECO:

```
# Seleccionando casos
interestelar_100 %>%
  filter(RES >= 500) %>%
  select(RES, RENECO)
```

```
##                            RES   RENECO
## chakotay cargo systems  800.81 37.09704
## hyperdrive express     1130.14 45.20668
## home one cargo          609.58 53.21612
## arrakis freight        1189.86 40.10962
```

Un mismo filtro admite varias condiciones, que se enlazan con el operador "**&**" (equivale a "y": deben cumplirse todas) o con la barra vertical "**|**" (equivale a "o": basta con que se cumpla una). Las empresas con un resultado mayor o igual a 500 **y** una rentabilidad económica inferior al 40 % son:

```
interestelar_100 %>%
  filter(RES >= 500 & RENECO < 40) %>%
  select(RES, RENECO, ACTIVO)
```

```
##                           RES   RENECO  ACTIVO
## chakotay cargo systems 800.81 37.09704 2158.69
```

Solo una empresa satisface ambas condiciones. Los operadores de comparación más habituales son >, <, >=, <=, == (igual: atención, con dos símbolos de igualdad seguidos) y != (distinto).

2.3.5 Creando variables: `mutate()`.

Por último, la función `mutate()` añade al *data frame* variables nuevas, calculadas a partir de las existentes. Si necesitamos, por ejemplo, el cociente entre el resultado y el activo de cada empresa, al que llamaremos RATIO:

```
# Creando variables a partir de otras variables
interestelar_100 <- mutate(interestelar_100, RATIO = RES / ACTIVO)
```

```
##                              RES  ACTIVO     RATIO
## hyperion star haulage     168.25  211.14 0.7968646
## jovian logistics          206.99  220.56 0.9384748
## sandworm freight           15.69   17.55 0.8940171
## ripley interstellar freight 15.15   37.07 0.4086863
## chakotay cargo systems    800.81 2158.69 0.3709704
## dune dynamics             283.27  515.86 0.5491219
```

```
## sith transport corp.        226.58  515.98 0.4391255
## seven of nine logistics     243.88  477.80 0.5104228
## moya cargo systems          343.68  520.29 0.6605547
## travis star haulage         286.66  466.63 0.6143197
```

El *data frame* "interestelar_100" tiene ahora una variable más, RATIO (29 en total).

2.4 Las variables de la base de datos del proyecto R-Stars.

La base de datos completa del proyecto R-Stars contiene datos económicos, financieros y operativos de 300 empresas de transporte interestelar de mercancías, recogidos en unas 30 variables. La segunda hoja de cada archivo de Excel describe sus variables, y la ficha detallada de cada una puede consultarse en el apéndice *Bases de datos utilizadas en el libro* de *R-Stars: La Guía*.

2.5 Materiales para realizar las prácticas del capítulo.

En esta sección se recogen los enlaces de acceso a los distintos materiales (*scripts*, datos...) necesarios para desarrollar los contenidos prácticos del capítulo.

Datos (en formato Microsoft® Excel®):

- interestelar_100.xlsx (obtener aquí), o bien, desde R: `lite_datos("interestelar_100")`.

Script:

- datos_lite.R (obtener aquí)

CAPÍTULO 3

Análisis previo de datos.



Figura 3.1. COMANDANTE DE *Rogue One Freight* SUPERVISANDO LOS DATOS DE TRAVESÍA.

3.1 Introducción.

Antes de aplicar técnicas complejas que nos permitan extraer conclusiones relevantes, conviene detenerse en unas **tareas previas** que persiguen dos objetivos:

- **Preparar nuestros datos** para que puedan ser procesados correctamente sin provocar distorsiones en los resultados. En especial, hay dos puntos clave: el tratamiento de los datos faltantes (***missing values***) y de los casos atípicos o ***outliers***.
- Obtener una **visión inicial de la información** que esconden los datos: las medidas básicas que caracterizan la distribución de frecuencias de cada variable y, cuando manejamos más de una, la relación estadística que existe entre ellas.

Es preciso, además, que esos rasgos iniciales de nuestra muestra o población se presenten de un modo **visualmente amigable**, claro y conciso. Un buen análisis previo que nadie entiende sirve de bien poco.

A lo largo de esta práctica, y sobre un ejemplo basado en una base de datos de empresas dedicadas al transporte interestelar de mercancías, recorreremos una serie de buenas prácticas y de análisis básicos con los que preparar y explorar cualquier conjunto de datos.

3.2 Encargo de la ARTI: auditoría sectorial.

La **Autoridad Reguladora del Transporte Interestelar (ARTI)** ha decidido realizar una auditoría de la salud financiera del sector. Su directora, ***Mara Qyà*** —conocida en los pasillos de la ARTI como *"la mujer que no firma nada sin un p-valor"*—, necesita un **informe previo** antes de que los auditores se desplieguen por las cinco galaxias. Y lo necesita, como siempre, *para ayer*.

Mara Qyà plantea dos preguntas concretas:

1. **¿Es la rentabilidad económica del sector razonablemente homogénea**, o hay empresas con comportamientos anómalos que merezcan una inspección particular? → Para responder, analizaremos la variable **RENECO** (rentabilidad económica) de forma univariante.
2. **¿Cómo se relacionan entre sí los principales indicadores financieros** —rentabilidad, tamaño, margen y resultado—, y hay empresas que destaquen como atípicas cuando se examinan todas estas dimensiones a la vez? → Para ello, ampliaremos el análisis a cuatro variables: **RENECO**, **ACTIVO**, **MARGEN** y **RES**.

Antes de responder, Mara Qyà exige que los datos estén **depurados**: sin valores faltantes que distorsionen los resultados y con una decisión razonada sobre los posibles *outliers*. Quiere, además, gráficos claros y medidas concretas. Manos a la obra.



VÍDEO

Dudas financieras...

https://youtu.be/7tw93JvKJ8k

3.2.1 El *script* y el paquete `{MATlite}`.

Supongamos que trabajamos dentro del **proyecto** "explora" que creamos anteriormente. En su carpeta guardaremos el *script* de la práctica, "previo_lite.R", y el archivo de Microsoft® Excel® "interestelar_100.xlsx", cuyos enlaces de descarga figuran en la sección final del capítulo. Si preferimos no descargar los datos a mano, `lite_datos("interestelar_100")` los guarda directamente en la carpeta del proyecto.

Abramos el *script* con `File → Open File...` (o haciendo clic sobre él en la ventana inferior derecha, pestaña "Files"). Sus primeras instrucciones son:

```
## Tratamiento y análisis previo de datos.

# Limpiando el Global Environment
```

```
rm(list = ls())

# Cargando el paquete de la asignatura
library(MATlite)
```

La primera instrucción limpia el *Global Environment* (la memoria) de los objetos que hayan quedado de sesiones de trabajo anteriores. La segunda **activa el paquete `{MATlite}`**, y es la única llamada a `library()` que necesitaremos: `{MATlite}` se encarga de que estén disponibles todos los paquetes que intervienen en la práctica (`{readxl}`, `{dplyr}`, `{ggplot2}`, `{visdat}`, `{GGally}`, `{moments}`...).

En este capítulo utilizaremos estas funciones de `{MATlite}`:

- **`lite_importa()`**: importa una hoja de Excel y toma la primera columna como el nombre de cada caso.
- **`lite_resumen()`**: presenta un resumen visual de las variables de un *data frame*.
- **`lite_na()`**: localiza los ***missing values*** de una o varias variables, dibuja el mapa de ausencias, lista los casos afectados y, si se le pide, los elimina.
- **`lite_outliers()`**: detecta los ***outliers*** mediante la regla de 1,5·IQR, dibuja el *box-plot*, lista los casos atípicos y, si se le pide, los elimina. Funciona tanto con una variable como con varias, en cuyo caso recurre a la distancia de *Mahalanobis*.
- **`lite_describe()`**: describe una variable métrica con su tabla de frecuencias, sus gráficos básicos, sus principales medidas y el contraste de normalidad.
- **`lite_correlaciones()`**: dibuja la matriz de correlaciones entre varias variables.

Todas comparten una misma filosofía: **no hacen nada que no pudiéramos hacer nosotros**; se limitan a empaquetar secuencias de instrucciones que, de otro modo, ocuparían decenas de líneas. Quien sienta curiosidad por ese código encontrará en el capítulo 5 de *R-Stars: La Guía* la misma práctica escrita paso a paso. La ficha completa de cada función está en el apéndice *Guía de uso de MATlite*.

3.2.2 Importando los datos.

Si abrimos "interestelar_100.xlsx", comprobaremos que consta de tres hojas: la primera recoge un aviso sobre el uso exclusivo que debe darse a los datos; la segunda describe las variables consideradas; y la tercera (hoja "Datos") contiene la información que vamos a **importar** desde RStudio. Se trata de variables económico-financieras y de otra índole, referidas a una muestra de empresas dedicadas al transporte interestelar de mercancías.

Merece la pena fijarse en un detalle: la hoja de cálculo contiene variables con datos faltantes (*missing values*). Unos se reconocen por la presencia de celdas en blanco, pero otros aparecen como celdas con el texto "n.d." (no disponible). Identificar cómo se anota cada ausencia resulta clave, porque **R debe registrar ambas como *NAs*** (*not available*).

Cerremos el archivo "interestelar_100.xlsx" y volvamos a RStudio. Para importar los datos alojados en la hoja "Datos" y echar un primer vistazo a las variables que contiene, ejecutaremos:

```
## DATOS

# Importando datos desde Excel
interestelar_100 <- lite_importa("interestelar_100.xlsx")

# Resumen visual de las variables
lite_resumen(interestelar_100)
```

interestelar_100: 104 casos × 28 variables

Variable	Tipo	Categorías	Ausentes (%)	Media	Mediana	Desv. típica
SEDE	Categórica	29	0.0			
GALAXIA	Categórica	5	0.0			
ACTIVO	Métrica		1.0	259.98	159.08	445.21
FPIOS	Métrica		0.0	115.64	59.81	209.27
ING	Métrica		0.0	238.23	103.91	370.77
MARGEN	Métrica		1.0	60.35	56.72	16.93
RES	Métrica		0.0	128.22	54.61	192.45
SOLVENCIA	Métrica		0.0	179.49	174.67	30.71
ACTCOR	Métrica		0.0	64.64	23.58	130.38
PASCOR	Métrica		0.0	107.89	59.92	176.53
LIQUIDEZ	Métrica		0.0	0.66	0.70	0.23
APALANCA	Métrica		1.0	145.60	133.73	63.19
RENECO	Métrica		1.0	52.38	50.43	11.39
RENFIN	Métrica		0.0	121.54	119.24	32.84
EMPLEA	Métrica		1.0	35.78	30.00	19.72
FJUR	Categórica	3	0.0			
FLOTA	Métrica		0.0	27.35	24.50	13.77
COSTOP	Métrica		1.0	110.04	29.82	192.74
CAPEX	Métrica		0.0	39.39	11.16	110.46
IMD	Métrica		0.0	16.33	4.95	26.73
EFLO	Categórica	3	0.0			
RUTAS	Métrica		0.0	397.71	327.50	376.16
IDIG	Métrica		0.0	18.16	16.71	10.92
IDIVERSE	Métrica		1.0	23.81	22.39	13.18
IFIDE	Métrica		1.0	39.39	39.18	6.16
GMEDRUT	Métrica		1.0	0.33	0.20	0.31
DIST	Métrica		1.9	164.93	57.79	279.35
BMAL	Métrica		1.9	8292.13	1285.59	33732.37

Tabla 3.1

`lite_importa()` lee por defecto la hoja "Datos" y trata como *NAs* tanto las celdas vacías como las que contienen "n.d.". Si en otra base de datos la hoja se llamase de otro modo, o las ausencias se anotasen de otra forma, bastaría con indicarlo: `lite_importa("archivo.xlsx", hoja = "Hoja1", na = c("n.d.", "s.d."))`.

Además, la función toma la primera columna de la hoja —el nombre de cada empresa— como el **nombre de las filas** del *data frame*, y no como una variable más: no es una característica de las empresas, sino su identificador.

La "tabla" de variables resultante nos confirma que 24 de ellas son métricas y 4, categóricas.

3.3 Análisis de una variable.

3.3.1 Buscando *missing values* y *outliers*.

Centrémonos en la *Rentabilidad Económica* (RENECO), la variable que nos permitirá responder a la primera pregunta de Mara Qyà. Lo primero es comprobar que todas las empresas tienen su correspondiente valor de RENECO, es decir, que no existen **valores perdidos o *missing values***.

El diagnóstico exige siempre los mismos tres pasos: **representar** gráficamente dónde están las ausencias, **identificar** los casos concretos que las padecen y **decidir** qué hacer con ellos. La función `lite_na()` reúne los tres. Le indicamos el *data frame*, la variable o variables que deben examinarse, la acción a realizar y los títulos del gráfico. El resultado lo guardamos en un nuevo *data frame*, "muestra", para preservar la integridad del original:

```
## Análisis de una variable.

# Localizando y eliminando missing values.
muestra <- lite_na(interestelar_100, RENECO,
                   accion    = "eliminar",
                   titulo    = "Rentabilidad Económica: valores ausentes",
                   subtitulo = "Transporte de mercancías interestelar")
```

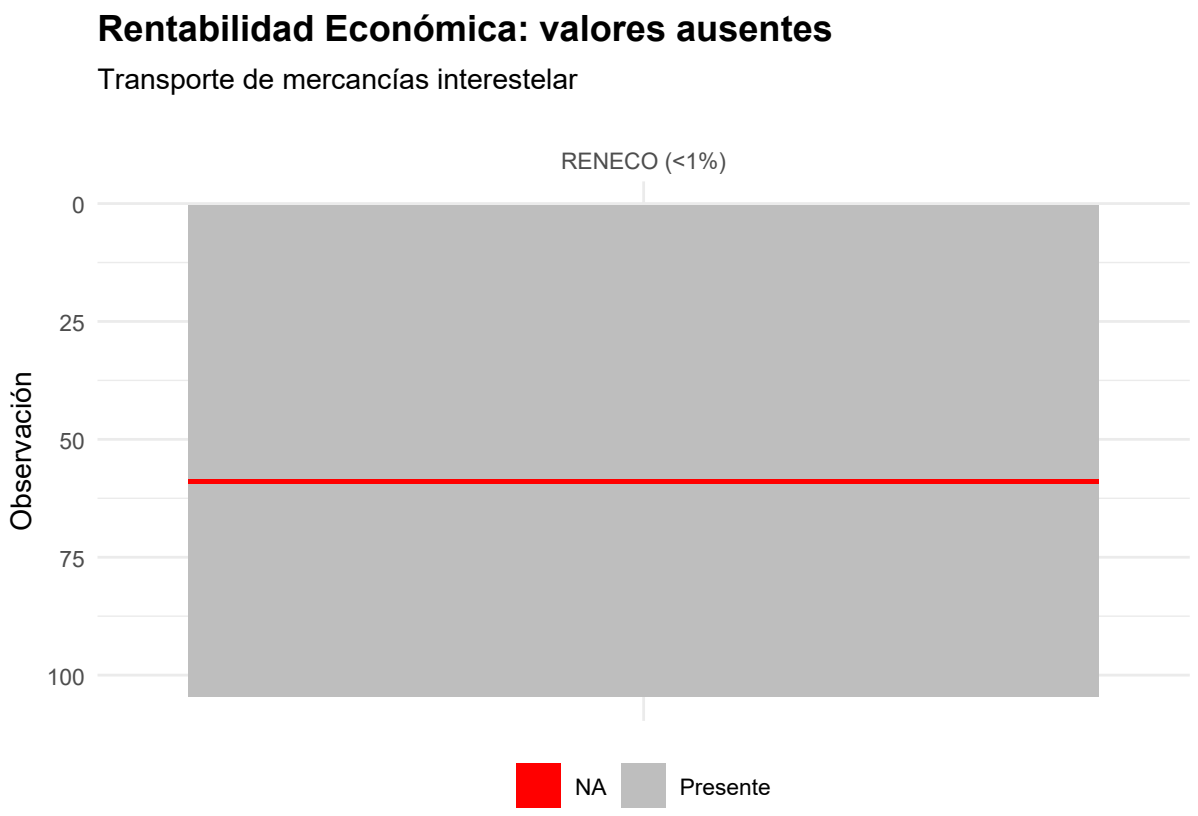


Figura 3.2

	RENECO
photon pack freight	NA

Tabla 3.2

Los argumentos merecen un comentario:

- **`RENECO`**: la columna que se examina. Si se omite, la función revisa todas las del *data frame*; si son varias, se indican como `c(VAR1, VAR2, ...)`.
- **`accion = "eliminar"`**: además de mostrar el gráfico y la tabla, descarta del *data frame* los casos afectados. Si no queremos eliminarlos todavía, basta con omitir este argumento y limitarnos al diagnóstico.
- **`titulo`** y **`subtitulo`**: encabezan el gráfico de ausencias.

El **gráfico de ausencias** dibuja un mapa de celdas en el que cada fila es una observación y cada columna, una variable: en rojo, los datos que faltan; en gris, los presentes. Revela que, en RENECO, aproximadamente un 1 % de los casos carece de dato, es decir, uno de los 104. La **tabla** que lo acompaña nos dice de cuál se trata: *Photon Pack Freight*.

Ahora bien, ¿por qué hemos elegido *eliminar* el caso? Ante la existencia de *missing values*, se puede actuar de varios modos. La decisión no es trivial y depende de la proporción de datos faltantes, de si su ausencia es aleatoria o sistemática, y del tipo de análisis posterior. Las principales estrategias son:

- **Eliminación del caso** (*listwise deletion*): se descartan las observaciones con algún valor faltante. Es la opción más sencilla, pero implica perder información. Si los datos no faltan de forma completamente aleatoria (MCAR, *Missing Completely At Random*), la eliminación puede introducir sesgos en los resultados (Rubin 1976).
- **Imputación por media o mediana**: se sustituye el valor faltante por la media (o la mediana) de la variable. Conserva el tamaño muestral, pero subestima la variabilidad real y puede distorsionar las relaciones entre variables.
- **Imputación múltiple** (paquete `{mice}` en R): en lugar de rellenar cada hueco con un único valor, genera **varios** conjuntos de datos completos, con valores distintos pero igualmente plausibles, analiza cada uno por separado y combina después los resultados. Es el enfoque de referencia en investigación, porque es el único de esta lista que arrastra hasta las conclusiones finales la incertidumbre de no haber observado el dato (Rubin 1987).
- **Imputación por k-vecinos más próximos** (función `kNN()` del paquete `{VIM}`): estima el valor faltante a partir de los casos más parecidos en las demás variables. Intuitivo y eficaz cuando las variables están relacionadas entre sí.

En nuestro ejemplo, dado que los *missing values* representan un porcentaje muy reducido respecto al total (apenas 1 caso de 104 para RENECO), **optaremos por la eliminación del caso**, que es la vía más directa y no introduce distorsión apreciable en este contexto. En situaciones con

mayor proporción de datos faltantes, o cuando se sospeche que la ausencia no es aleatoria, convendría considerar las técnicas de imputación mencionadas. De ahí el `accion = "eliminar"` del código anterior. En el *Global Environment* podemos comprobar que el *data frame* "muestra" tiene un caso menos que "interestelar_100": 103.

Resueltos los valores perdidos, **conviene rastrear la posible presencia de *outliers*** o casos atípicos, capaces de desvirtuar los resultados de ciertos análisis. Como trabajamos con una sola variable métrica, la rentabilidad económica, nos basta con representarla mediante un ***box-plot*** o gráfico de caja, localizar los casos que quedan fuera de los bigotes y decidir qué hacer con ellos. De nuevo son tres pasos, y de nuevo `{MATlite}` los reúne en una sola llamada, esta vez con `lite_outliers()`:

```
## Localizando y eliminando outliers
muestra_so <- lite_outliers(muestra, RENECO,
                            accion    = "eliminar",
                            titulo    = "Rentabilidad Económica",
                            subtitulo = "Empresas de transporte interestelar")
```

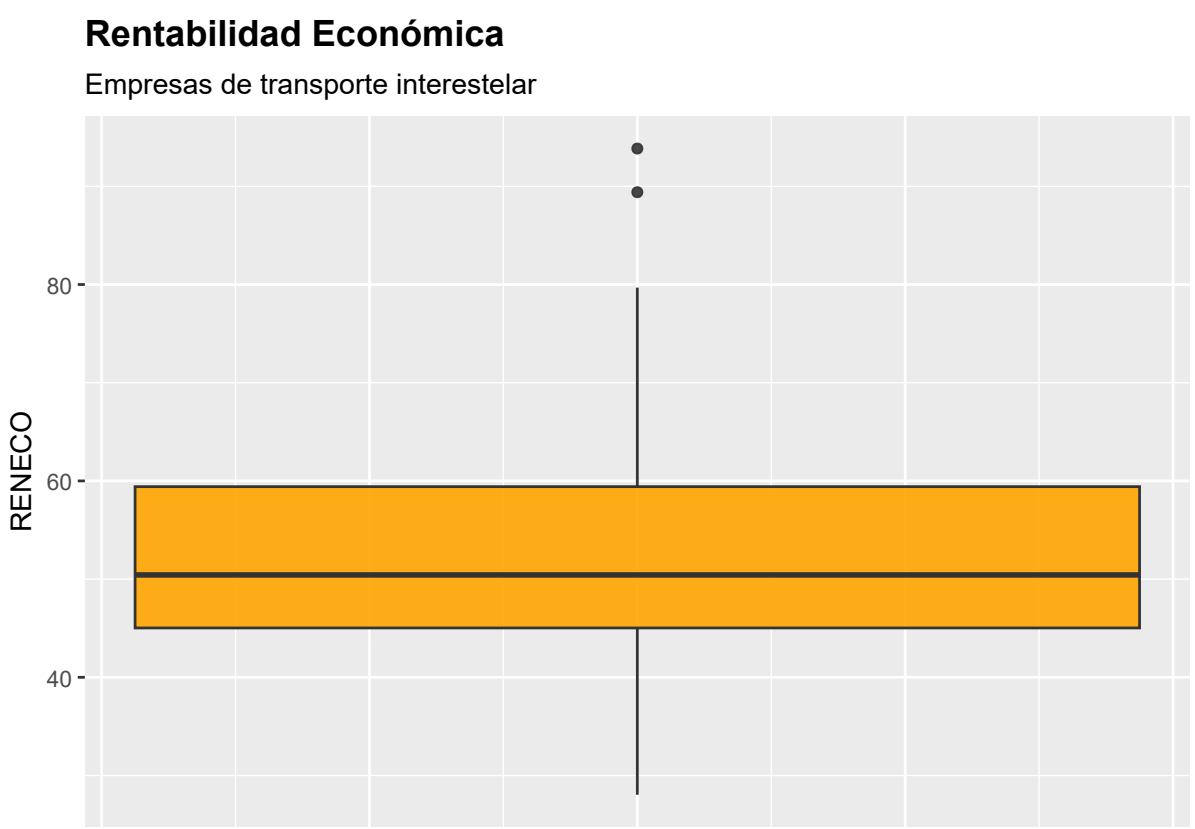


Figura 3.3

	RENECO
sandworm freight	89.40171
jovian logistics	93.84748

Tabla 3.3

Los argumentos son los mismos que los de `lite_na()`. Obsérvese que aquí **no sobrescribimos "muestra"**, sino que creamos un *data frame* nuevo, "muestra_so" (*sin outliers*), porque más adelante nos interesará comparar los resultados con y sin casos atípicos.

Recordemos brevemente cómo se lee este gráfico. La "caja" alberga el 50 % central de los casos, los comprendidos entre el primer y el tercer cuartil, cuya diferencia es el *rango intercuartílico*; la línea horizontal que la atraviesa es la mediana. De la caja salen dos segmentos o "bigotes": el superior alcanza el mayor valor que no llega a considerarse atípico y el inferior, el menor. Los casos atípicos u *outliers* son precisamente los que quedan más allá, a más de **1,5 veces** el rango intercuartílico por encima del tercer cuartil o por debajo del primero, y se dibujan como puntos sueltos. Esa es exactamente la regla que aplica la función, y la tabla que acompaña al gráfico nos da los nombres: *Jovian Logistics* y *Sandworm Freight*.

`lite_outliers()` incorpora además una mejora visual que conviene conocer: cuando los *outliers* son tan extremos que "aplastan" la caja del *box-plot* hasta hacerla ilegible, activa automáticamente una **escala pseudologarítmica** en el eje Y, que comprime los valores grandes sin alterar los pequeños. El subtítulo del gráfico avisa cuando se ha aplicado.

Como ocurría con los *missing values*, el **tratamiento de los *outliers*** depende de la información que se tenga, y del enfoque que se quiera seguir en la aplicación de las diferentes técnicas. Es un tema que a veces resulta **complejo**, y que no está exento de divergencias en la opinión de los investigadores. Las principales alternativas son:

- **Eliminar el caso**: adecuado cuando son pocos, representan una proporción reducida de la muestra y se sospecha que el valor extremo obedece a un error de medida o de registro. Es la opción que adoptaremos en este libro.
- **Winsorizar**: sustituir los valores extremos por el del percentil 5 (o el 95), o por el límite del bigote del *box-plot*. El caso se conserva, pero su influencia queda acotada.
- **Mantener y documentar**: a veces el *outlier* es un dato real y relevante (una empresa genuinamente excepcional). Eliminarlo supondría perder información legítima. En estos casos, conviene reportar los resultados con y sin *outliers* para valorar su impacto.
- **Usar técnicas estadísticas robustas**: muchos métodos disponen de versiones diseñadas para mitigar el efecto de valores extremos sin necesidad de eliminarlos. Algunos ejemplos concretos: la **mediana** en lugar de la media como medida de posición central; la **MAD** (*Median Absolute Deviation*) en lugar de la desviación típica como medida de dispersión; o la **correlación de Spearman** en lugar de la de Pearson, que es menos sensible a valores extremos.

La decisión depende en última instancia del contexto del análisis. Al final de este capítulo veremos, precisamente, cómo la presencia o ausencia de *outliers* puede alterar las correlaciones entre variables, lo que subraya la importancia de esta decisión.

En nuestro ejemplo, dado que los *outliers* son solo dos y apenas representan una fracción de la muestra, **prescindiremos de esas dos empresas de comportamiento atípico** para que **no distorsionen los resultados** de las técnicas que apliquemos después. En el *Global Environment* comprobamos que "muestra_so" conserva las mismas variables que "muestra", pero con dos casos menos: 101.

3.3.2 Descripción de una variable.

Con la base de datos ya depurada de *missing values* y *outliers*, y **antes** de aplicar la técnica que corresponda a los objetivos del estudio, se acostumbra a presentar una batería de **gráficos** básicos y **medidas** descriptivas que ofrecen una **idea inicial de la estructura** del sector en la variable analizada. Hablamos de medidas y gráficos de posición, de dispersión y de forma, esto es, de asimetría y curtosis.

Toda esa batería la obtiene, de una vez, la función `lite_describe()`. Le indicamos el *data frame*, la variable y, si queremos, el texto con que se rotularán los ejes de los gráficos y el título del resumen final:

```
# Descripción completa de la variable
rentabilidad <- lite_describe(muestra_so, RENECO,
                              etiqueta  = "Rentabilidad Económica (%)",
                              titulo    = "Rentabilidad Económica",
                              subtitulo = "Empresas TMI (sin outliers)")
```

Aparentemente, no ha ocurrido nada. Pero en el *Global Environment* ha aparecido un nuevo objeto, "rentabilidad", que guarda **todos los resultados** del análisis. Así funcionan las funciones de análisis de `{MATlite}`:

- Si escribimos el nombre del objeto, `rentabilidad`, R muestra todos sus resultados principales: las tablas, en el panel *Viewer*, y los gráficos, en el panel *Plots*. Al final, la consola lista todo lo que contiene el objeto.
- Si escribimos el nombre del objeto seguido de `$` y el nombre de una de sus piezas, R muestra solo esa pieza. Al teclear `rentabilidad$`, RStudio despliega la lista de piezas disponibles.

Iremos pieza a pieza. Conviene abrir el recorrido con una tabla que recoja la **distribución de frecuencias** de la variable. Cuando los casos son numerosos —101 en nuestro ejemplo—, lo razonable es agruparlos en intervalos, tal como aprendimos en el capítulo 4 de *La Guía*. `lite_describe()` fija el número de intervalos con el método de *Sturges*:

```
rentabilidad$frecuencias
```

Intervalo	n(i)	N(i)	f(i)	F(i)
[28,34.5]	5	5	0.05	0.05
(34.5,41]	10	15	0.10	0.15
(41,47.4]	18	33	0.18	0.33
(47.4,53.9]	25	58	0.25	0.57
(53.9,60.3]	25	83	0.25	0.82
(60.3,66.8]	12	95	0.12	0.94
(66.8,73.2]	4	99	0.04	0.98
(73.2,79.7]	2	101	0.02	1.00

Tabla 3.4

La lectura de la tabla es clara: la **rentabilidad económica** de estas empresas se concentra en valores **medios-altos**, en torno al 50-60 %, y son los dos intervalos centrales (47,4-53,9 y 53,9-60,3) los que reúnen la mayor parte de los casos. Alrededor de ocho de cada diez compañías quedan entre el 41 % y el 66,8 %, lo que apunta a un sector relativamente estable, con resultados parecidos entre sí. Los extremos están poco poblados: apenas un 5 % presenta rentabilidades por debajo del 34,5 % y solo un 2 % supera el 73,2 %. En términos económicos, la competencia y la eficiencia operativa parecen empujar a las empresas hacia un rendimiento **razonable y sostenido**, de modo que tanto el fracaso como el éxito excepcional resultan **minoritarios**. **Primera respuesta parcial para Mara Qyà:** el sector exhibe una rentabilidad bastante homogénea, si bien aún debemos confirmar esta impresión con las medidas descriptivas y descartar la presencia de anomalías.

El **análisis gráfico**, por su parte, ofrece una imagen mucho más intuitiva de cómo se distribuyen nuestros casos en la variable estudiada. Un gráfico fundamental es el **histograma**:

```
rentabilidad$histograma
```

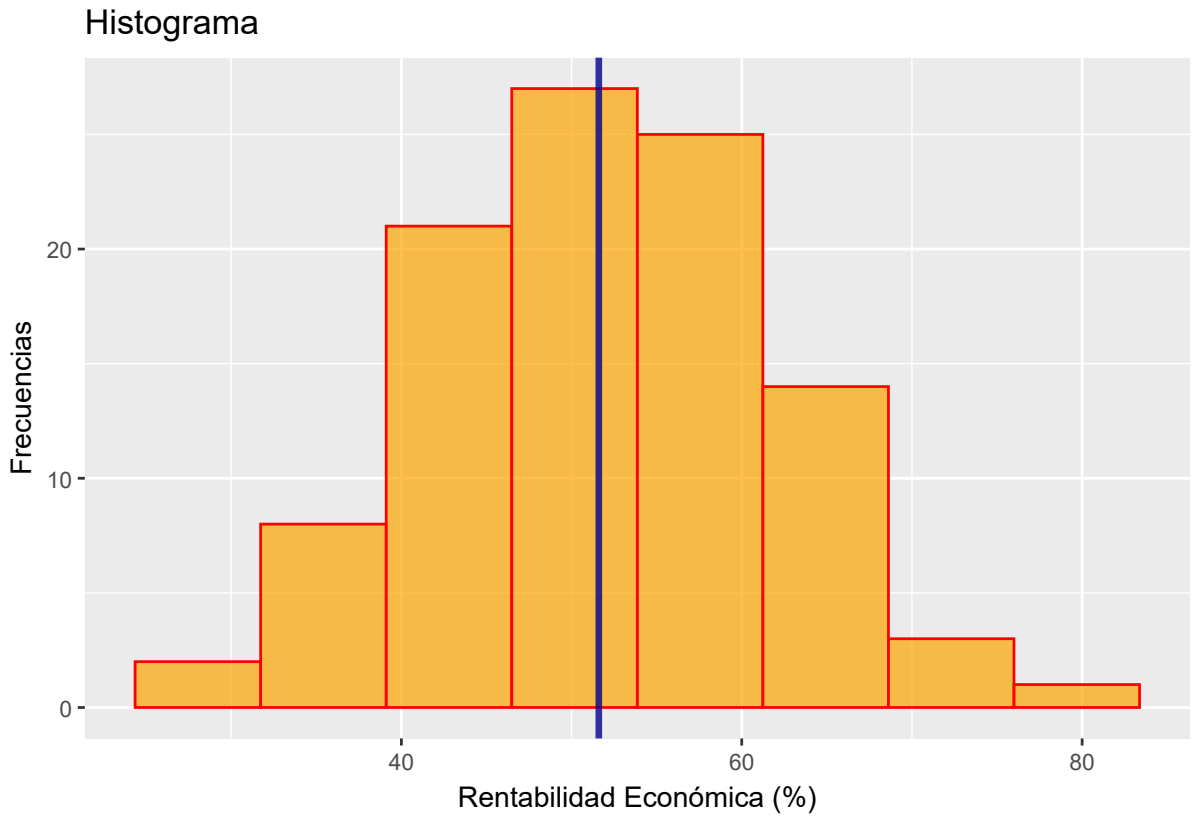


Figura 3.4

El gráfico muestra con nitidez cómo se reparten las empresas según su rentabilidad económica. La línea vertical azul señala la rentabilidad media. A simple vista, la distribución resulta acampanada y prácticamente simétrica.

Como complemento del histograma, `lite_describe()` dibuja un **gráfico de densidad** de RENECO, que no es sino una versión "suavizada" de aquel y que representa la distribución de probabilidad empírica de la muestra. Sobre él superpone una curva normal con la misma media y

desviación típica que nuestros datos. La comparación entre ambas curvas permite confirmar de un vistazo los rasgos que el histograma solo dejaba intuir, como una ligera asimetría:

```
rentabilidad$densidad
```

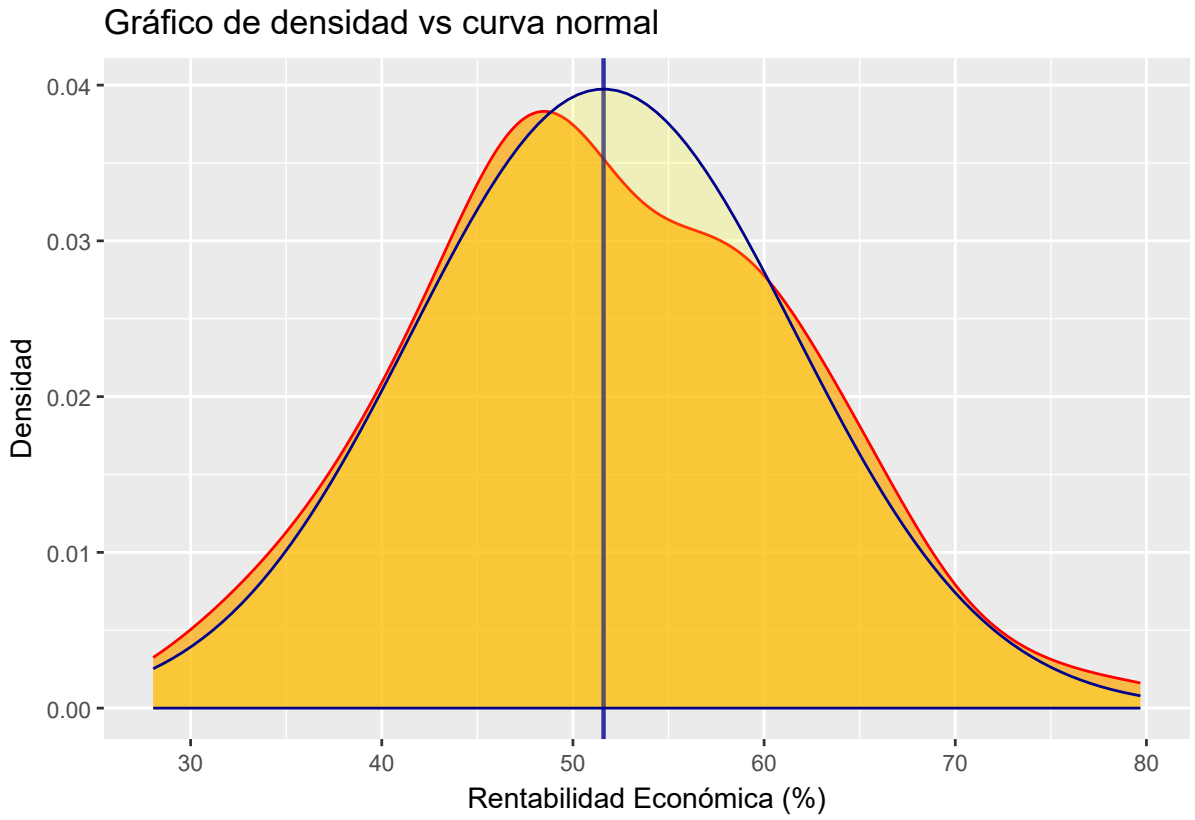


Figura 3.5

La curva naranja muestra cómo se distribuye la **rentabilidad económica**: tiene forma de "campana", con la mayoría de empresas concentradas alrededor del 50–60 %. La línea vertical azul marca el valor central (media), en torno al 52 %. Comparada con la curva azul de referencia (la normal), la distribución real es muy parecida, aunque algo más ancha y con un ligero peso extra en rentabilidades algo por debajo del centro; en el extremo alto hay menos casos de lo que predeciría una campana perfecta. En términos económicos: el sector muestra un rendimiento **bastante estable** y similar entre compañías, con **pocas** muy rezagadas o extraordinariamente rentables.

Un tercer gráfico útil es el ***box-plot***, construido ya sobre la muestra sin *outliers* y enriquecido con los valores individuales de cada empresa (los puntos rojos):

```
rentabilidad$boxplot
```

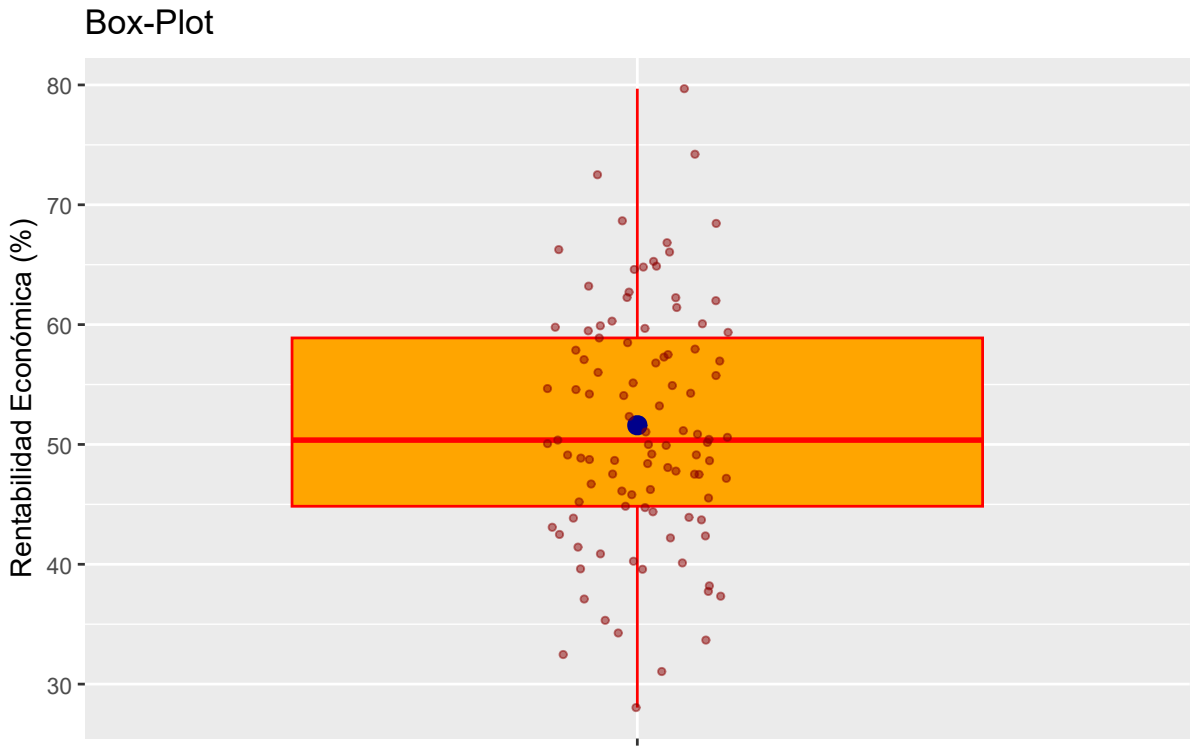


Figura 3.6

El *box-plot* confirma que la rentabilidad económica se concentra en la zona central. La **mediana** ronda el **50 %** —la línea que atraviesa la caja— y la mitad de las empresas se sitúa aproximadamente entre el 46 % y el 59 %, altura de la caja o rango intercuartílico, lo que denota una variabilidad moderada. El punto azul, que marca la media, queda muy próximo a la mediana, señal de una distribución casi simétrica. Los bigotes se extienden hasta valores en torno al 28 % y al 80 %, y ya no aparece ningún caso atípico, puesto que los dos detectados se eliminaron previamente. La nube de puntos rojos confirma lo esencial: la mayoría de las compañías rinde de forma parecida y estable en el entorno del 50-60 %.

Conviene, además, conocer el valor de las principales **medidas descriptivas** —de posición, dispersión y forma— que caracterizan la distribución: la media, la desviación típica, el valor mínimo, la mediana, el valor máximo, el coeficiente de asimetría de *Fisher* y el coeficiente de apuntamiento o curtosis de *Fisher*. Este último está calculado de modo que la distribución perfectamente mesocúrtica (la normal) tome el valor 0:

```
rentabilidad$estadisticos
```

Media	Desviación Típica	Valor mínimo	Mediana	Valor Máximo	C. Asimetría Fisher	C. Curtosis Fisher
51.6	10.04	28.04	50.36	79.69	0.14	-0.19

Tabla 3.5

En conjunto, cabe afirmar lo siguiente:

- La rentabilidad típica del sector está en torno al 51–52 % (media ≈ 51,6 % y mediana ≈ 50,4 %), lo que indica un nivel medio-alto y sin sesgos fuertes.
- La variabilidad es moderada (desv. típica ≈ 10 p.p.): la mayoría de empresas se mueve, grosso modo, entre ~42 % y ~62 %. Es un sector relativamente estable.
- La asimetría ligeramente positiva (0,14) sugiere que hay algunas compañías con rentabilidades algo superiores a lo habitual, pero no dominan el panorama.
- La curtosis negativa (−0,19, platicúrtica) revela una distribución más "plana" que la normal: menos casos extremos, tanto por arriba como por abajo, y algo menos de concentración en el centro. En términos económicos, existe una diversidad razonable de resultados, pero escasean los fracasos sonados y los éxitos extraordinarios.
- Los extremos observados (≈ 28 % mínimo y ≈ 80 % máximo) existen, pero son minoría.
- **Conclusión:** el negocio de transporte interestelar muestra una **rentabilidad sostenida y relativamente homogénea**; hay diferencias entre empresas (gestión, escala, rutas, mix tecnológico), pero el **riesgo de resultados extremos** parece **contenido**, y los "superéxitos" son poco frecuentes.

3.3.3 Normalidad.

Numerosas técnicas multivariantes de corte inferencial —el análisis de la varianza o la regresión lineal, por citar dos— exigen que las variables sigan una **distribución normal**. Para comprobarlo disponemos de dos caminos: el análisis gráfico y el análisis formal, este último basado en contrastar la hipótesis nula de normalidad.

Empecemos por el **método gráfico** más extendido: el ***gráfico qq*** o cuantil-cuantil, que enfrenta los cuantiles de nuestra muestra con los de una distribución normal teórica de idéntica media y desviación típica. Si los puntos se alinean sobre la diagonal, asumiremos un comportamiento aproximadamente normal:

```
rentabilidad$qq
```

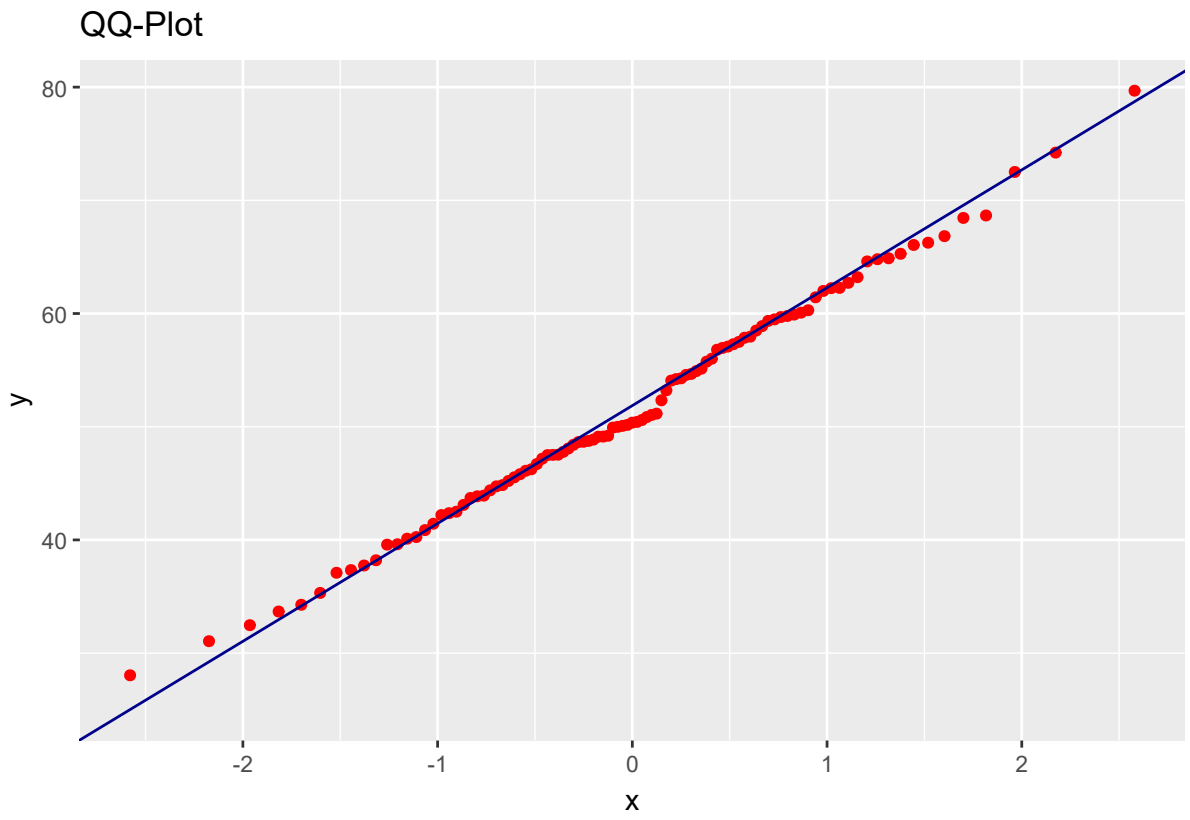


Figura 3.7

No siempre resulta fácil extraer una conclusión firme de un gráfico *qq*. En nuestro ejemplo, sin embargo, los puntos se ciñen a la diagonal con bastante fidelidad, lo que invita a pensar que RENECO podría seguir una distribución normal.

Si queremos ser más precisos, al análisis gráfico podemos añadir uno formal, apoyado en un **contraste de hipótesis**. La prueba más habitual es la **de normalidad de *Shapiro y Wilk***, que se comporta bien en muestras relativamente reducidas. Su hipótesis nula es, justamente, el supuesto de normalidad; así que, para una significación del 5 %, un p-valor superior a 0,05 nos llevará a no rechazarla. `lite_describe()` ya la ha realizado:

```
rentabilidad$normalidad
```

Contraste	Estadístico W	p-valor	Decisión
Shapiro-Wilk	0.9949	0.9715	No se rechaza H0 (normalidad) al 5 %

Tabla 3.6

El p-valor obtenido supera con holgura el umbral de 0,05, de modo que **no se rechaza la hipótesis nula de normalidad**: con una significación del 5 %, la muestra respalda que RENECO se comporta de forma normal, tal como ya anticipaba el gráfico *qq*. La propia tabla recoge la decisión en su última columna.

3.3.4 Resumen: 4 gráficos básicos en la descripción de una variable.

En definitiva, para describir inicialmente la distribución de frecuencias de una variable métrica basta con los cuatro gráficos que acabamos de recorrer. Y como en un informe el espacio siempre escasea, `lite_describe()` los reúne también en una sola imagen, con el título y el subtítulo que le indicamos:

```
rentabilidad$resumen
```

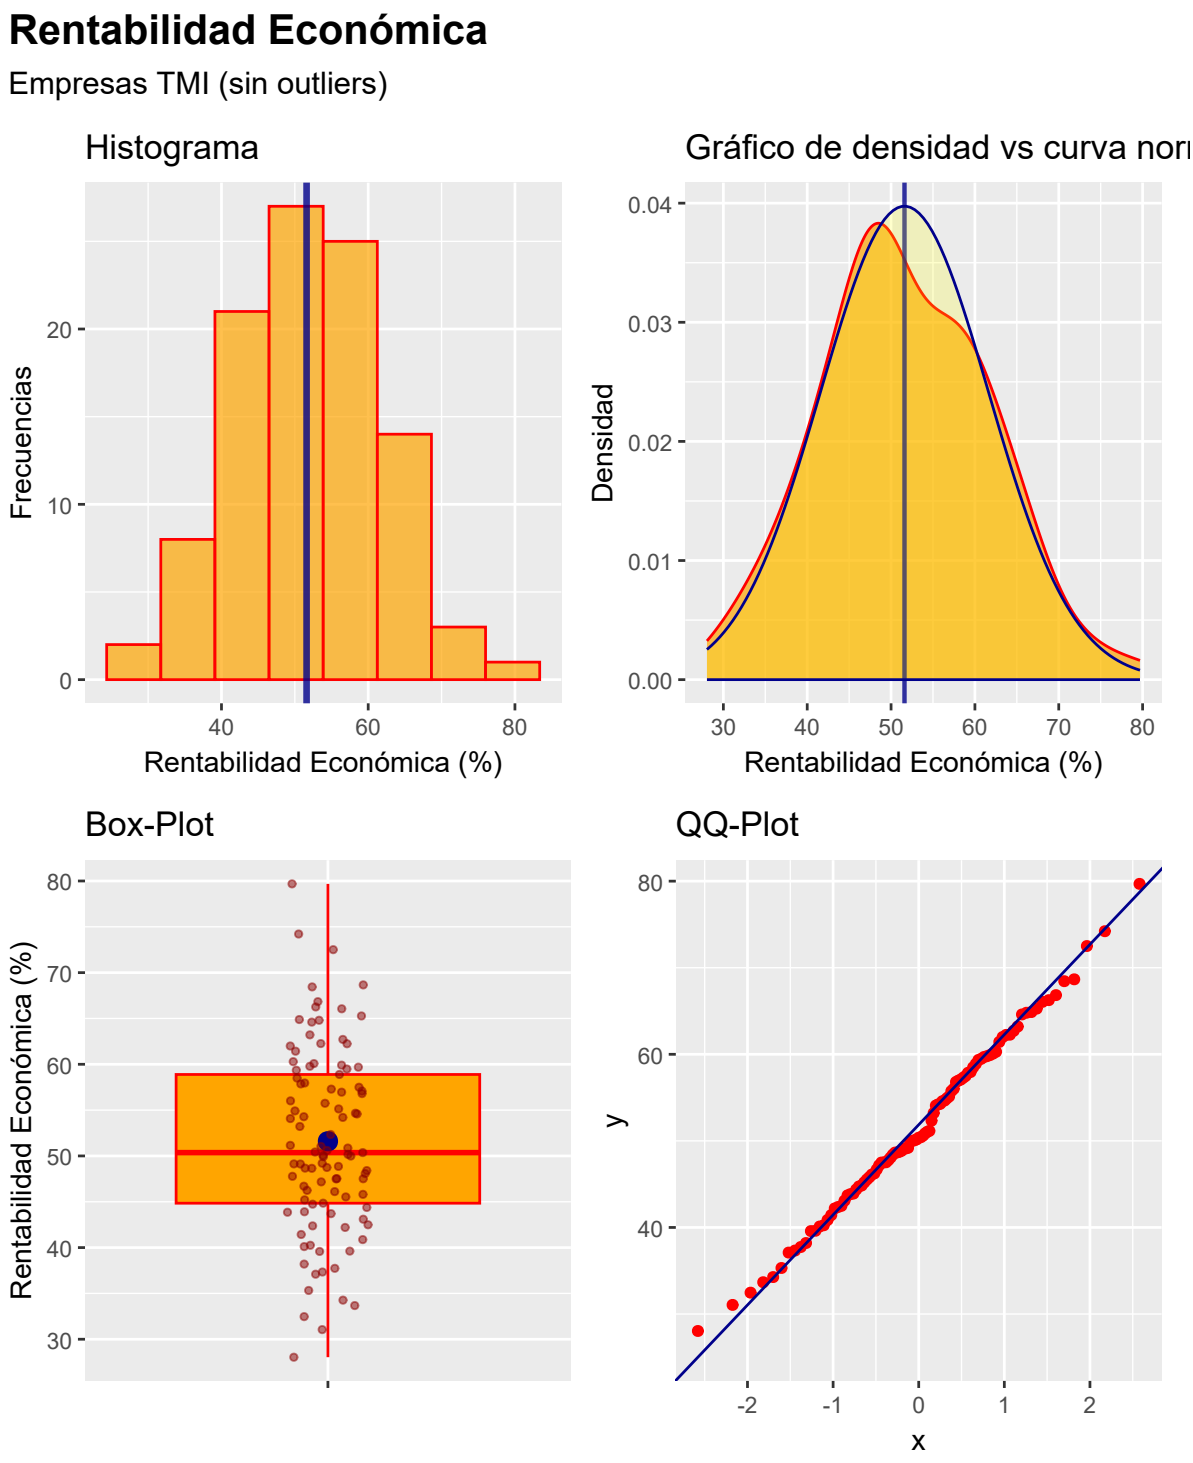

Rentabilidad Económica
Empresas TMI (sin outliers)
Histograma
Frecuencias
Rentabilidad Económica (%)
Gráfico de densidad vs curva nor
Densidad
Rentabilidad Económica (%)
Box-Plot
Rentabilidad Económica (%)
QQ-Plot
y
x

Figura 3.8

3.4 Análisis de múltiples variables.

Muchas de las técnicas que se aplican al análisis de datos económicos —el análisis de componentes principales, la regresión o el análisis clúster, entre otras— parten de una distribución de frecuencias multivariante. En este apartado nos ceñiremos a las **variables métricas**, pues a los atributos, variables categóricas o factores les dedicaremos un capítulo entero.

Pasamos ahora a la segunda pregunta de Mara Qyà: ¿cómo se relacionan entre sí los principales indicadores financieros, y hay empresas que destaquen como atípicas al examinar varias dimensiones a la vez?

Todas ellas reclaman, una vez más, una fase inicial que ponga a punto la base de datos y ofrezca una fotografía de las variables implicadas. Lo aconsejable es aplicar a cada variable por separado algunos de los análisis gráficos que acabamos de ver.

A ese examen individual hay que sumar uno adicional, dirigido a cuantificar el **grado de intensidad de la relación estadística** entre las variables: el estudio de la ***correlación***. Pero antes debemos detenernos en un problema específico que surge en cuanto manejamos varias variables a la vez: la detección de casos atípicos.

3.4.1 Localización de *missing values* y *outliers*.

También aquí el primer paso consiste en localizar los casos con **valores perdidos o *missing values***, para decidir después cómo tratarlos: eliminar el caso, estimar el valor ausente, etc.

Imaginemos un análisis que tenga en cuenta cuatro variables: RENECO (rentabilidad económica), ACTIVO (volumen de activos de la empresa), MARGEN (margen de beneficio) y RES (resultado del ejercicio). Son, precisamente, las cuatro dimensiones por las que pregunta Mara Qyà.

Aplicaremos `lite_na()` al *data frame* original, indicando esta vez las cuatro variables del análisis, y guardaremos el resultado en un nuevo *data frame*, "muestra2":

```
## Trabajando con múltiples variables.

# Diagnóstico y filtrado de missing values.
muestra2 <- lite_na(interestelar_100, c(RENECO, ACTIVO, MARGEN, RES),
                    accion    = "eliminar",
                    titulo    = "Variables económico-financieras: valores ausentes",
                    subtitulo = "Transporte de mercancías interestelar")
```

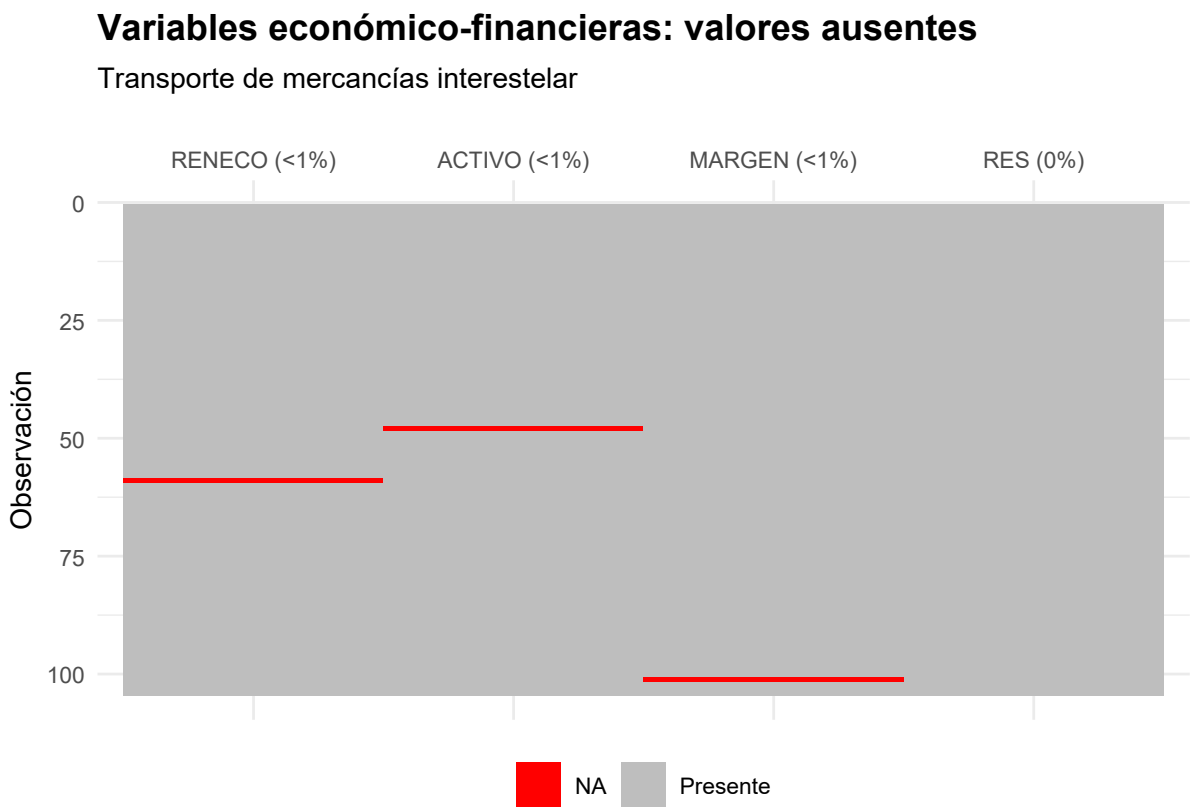


Figura 3.9

	RENECO	ACTIVO	MARGEN	RES
vega transport	50.42554	NA	48.4567	104.87
photon pack freight	NA	57.78	48.7883	24.36
poe dameron cargo	54.20692	49.68	NA	26.93

Tabla 3.7

Obsérvese que ahora el mapa de ausencias tiene cuatro columnas, una por variable, y que la eliminación es *listwise*: se descarta el caso entero si le falta el dato en **cualquiera** de las cuatro. El *data frame* "muestra2" contiene, pues, los mismos datos que "interestelar_100" salvo los 3 casos con *missing values* (101): *Vega Transport*, *Photon Pack Freight* y *Poe Dameron Cargo*.

En cuanto a la **detección de *outliers***, examinar las variables de una en una no es solo poco operativo cuando son numerosas: es, sobre todo, **incompleto**. Y conviene detenerse en este punto, porque es la razón de fondo por la que hace falta un procedimiento distinto.

Una empresa puede presentar valores **perfectamente normales en cada variable por separado** y ser, sin embargo, un caso atípico **en el conjunto**: lo raro no es ninguno de sus valores, sino la **combinación** de todos ellos. El *box-plot* aplicado variable a variable nunca detectará algo así, porque mira cada dimensión por separado y es ciego a cómo se relacionan entre sí.

Podemos comprobarlo con nuestros propios datos. El gráfico siguiente enfrenta RENECO con MARGEN. La banda sombreada delimita el rango que la regla de 1,5·IQR considera normal **en cada una de las dos variables**, y la elipse roja recoge el 95 % de la nube atendiendo a su forma, es decir, a la relación que existe entre ambas:

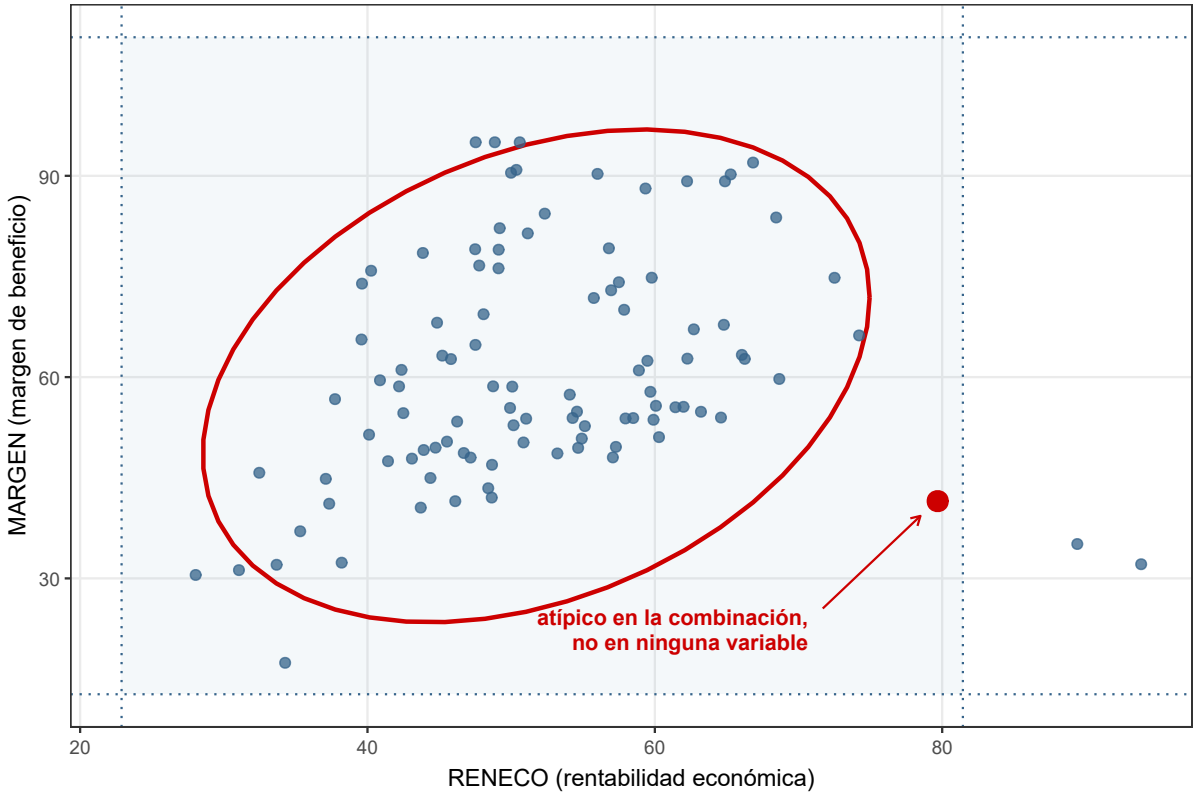


Figura 3.10

El caso señalado en rojo tiene una rentabilidad económica de 79.7 y un margen de 41.5. **Ninguno de los dos valores sobrepasa las vallas de 1,5·IQR** de su respectiva variable: analizadas por separado, ambas cifras pasarían el filtro sin levantar sospecha. Y, sin embargo, el punto queda **claramente fuera de la elipse**. La razón es económica, no estadística: en esta muestra, rentabilidad y margen van de la mano, de modo que una empresa con una rentabilidad de las más altas del sector y un margen de los más bajos constituye una combinación insólita. Eso es exactamente lo que un examen variable a variable deja escapar.

Obsérvese también la diferencia entre la **banda** y la **elipse**. La banda es un rectángulo: trata cada variable como si fuera independiente de la otra. La elipse está **girada**, porque incorpora la correlación entre ambas. Es esa inclinación la que convierte en atípico a un punto que, proyectado sobre cada eje, resultaría de lo más corriente.

Necesitamos, por tanto, una medida que **resuma el comportamiento de cada caso en todas las variables a la vez**, teniendo en cuenta además cómo se relacionan entre sí. Esa medida es la ***distancia de Mahalanobis***, que actúa como **"resumen" del comportamiento de cada caso** en todas las variables consideradas a la vez. Podemos verla como una especie de "z-score multivariante": mide cuántas desviaciones típicas se aleja una observación del "centro" del conjunto, teniendo en cuenta todas las variables y el modo en que se relacionan entre sí.

Su utilización, intuitivamente, se puede justificar de este modo:

- Con una sola variable, el "raro" es el que está a muchos **z-scores** de la media.
- Con varias variables (p. ej., rentabilidad, activo, margen, resultado), el "centro" es el vector de medias y la forma de la nube viene dada por la covarianza (las variables pueden estar en escalas distintas y estar correlacionadas).

- La *distancia de Mahalanobis:*
  - **Estandariza** las escalas (una variable en millones no pesa más que otra en porcentajes).
  - **Gira y estira** el espacio según las correlaciones (si dos variables están muy correlacionadas, moverte a lo largo de su diagonal "cuesta" menos que moverte perpendicularmente).
- En 2D lo verías como **elipses** alrededor del centro (no círculos). Los puntos fuera de la elipse "grande" son **potenciales *outliers***.

La distancia de Mahalanobis de un vector $\mathbf{x} \in \mathbb{R}^p$ respecto del centro μ y la matriz de covarianzas $\boxtimes$ es:

$$D_M(\mathbf{x}) = \sqrt{(\mathbf{x}-\mu)^\top \boxtimes^{-1} (\mathbf{x}-\mu)}.$$

Una vez calculada esa distancia para cada empresa, el procedimiento es exactamente el mismo que en el caso univariante: se representa mediante un *box-plot* y se consideran atípicos los casos que superan el umbral de 1,5·IQR. Por eso **no necesitamos una función nueva**: cuando a `lite_outliers()` se le pasan varias variables, reconoce automáticamente que estamos ante un caso multivariante, calcula por su cuenta la distancia de Mahalanobis y le aplica la regla de 1,5·IQR. Dicho de otro modo, **una misma función resuelve ambos escenarios**: con una sola variable trabaja directamente sobre ella; con varias, sintetiza su comportamiento mediante Mahalanobis.

```
# Identificando y descartando outliers con distancia de Mahalanobis.
muestra2_so <- lite_outliers(muestra2, c(RENECO, ACTIVO, MARGEN, RES),
                             accion    = "eliminar",
                             titulo    = "DISTANCIA DE MAHALANOBIS",
                             subtitulo = "RENECO, ACTIVO, MARGEN, RES. Empresas TMI.")
```

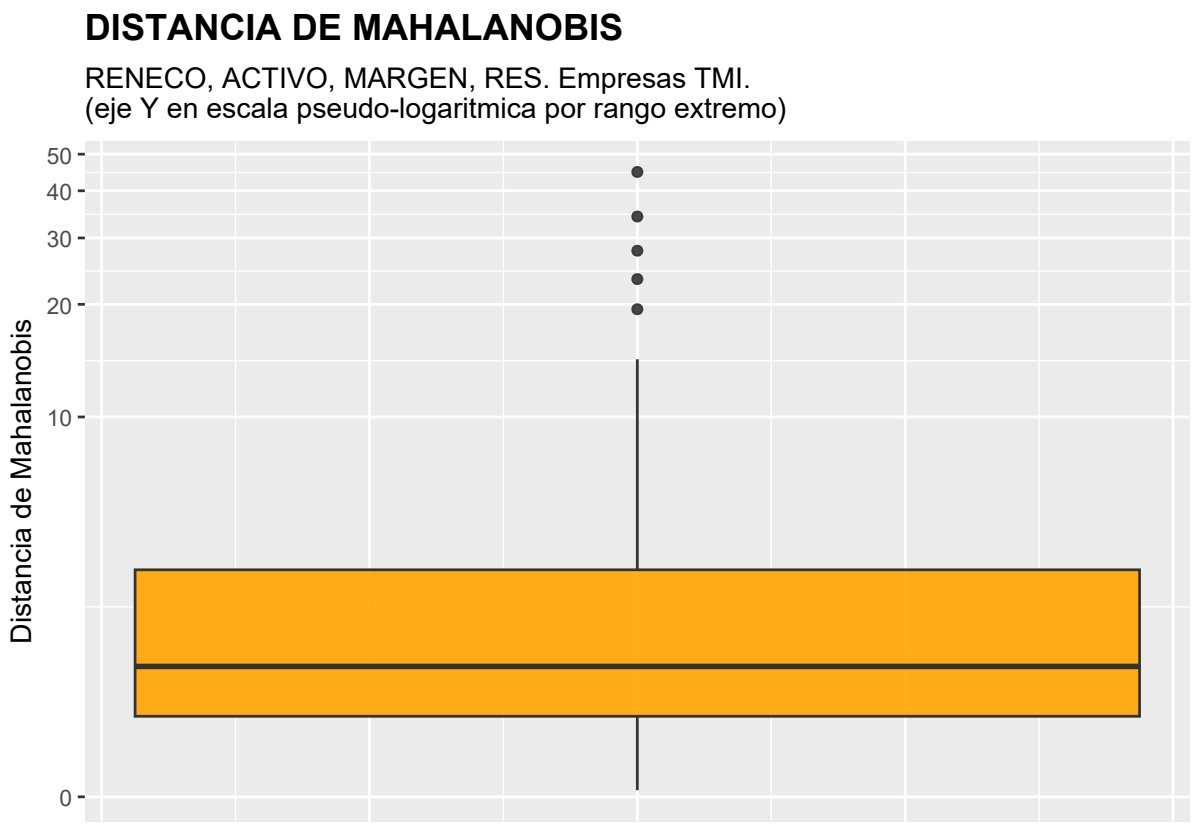


Figura 3.11

	MAHALANOBIS	RENECO	ACTIVO	MARGEN	RES
arrakis freight	44.863023	40.10962	2966.52	51.42027	1189.86
chakotay cargo systems	34.189074	37.09704	2158.69	44.83819	800.81
hyperdrive express	27.755439	45.20669	2499.94	63.19775	1130.14
sandworm freight	23.338920	89.40171	17.55	35.12424	15.69
jovian logistics	19.407213	93.84748	220.56	32.11189	206.99
home one cargo	14.276454	53.21612	1145.48	48.62131	609.58
dagobah freightlines	11.049984	66.83549	511.39	91.97546	341.79
hyperion star haulage	8.443881	79.68646	211.14	41.51348	168.25
io star transport	8.143146	34.26908	498.00	17.41820	170.66
moya cargo systems	7.987575	66.05547	520.29	63.31031	343.68

Tabla 3.8

El *box-plot* delata varios casos atípicos, y la tabla los identifica junto con sus valores en las cuatro variables, ordenados de mayor a menor distancia. El *data frame* "muestra2_so" es una réplica de "muestra2" sin esos casos: 91 empresas en total.

3.4.2 Correlación entre variables.

Cuando manejamos más de una variable, un rasgo de primer orden es la intensidad con que esas variables se relacionan estadísticamente entre sí: el estudio de las correlaciones. La función `lite_correlaciones()` dibuja la **matriz de correlaciones** de las variables que le indiquemos. Si además le pasamos, con el argumento `comparar_con`, el *data frame* que todavía conserva los *outliers*, prepara también la matriz con ellos para poder comparar ambas:

```
## Correlaciones entre variables.
correlaciones <- lite_correlaciones(muestra2_so, c(RENECO, ACTIVO, MARGEN, RES),
                                    comparar_con = muestra2)
```

Veamos primero la matriz calculada sin los *outliers*:

```
correlaciones$grafico
```

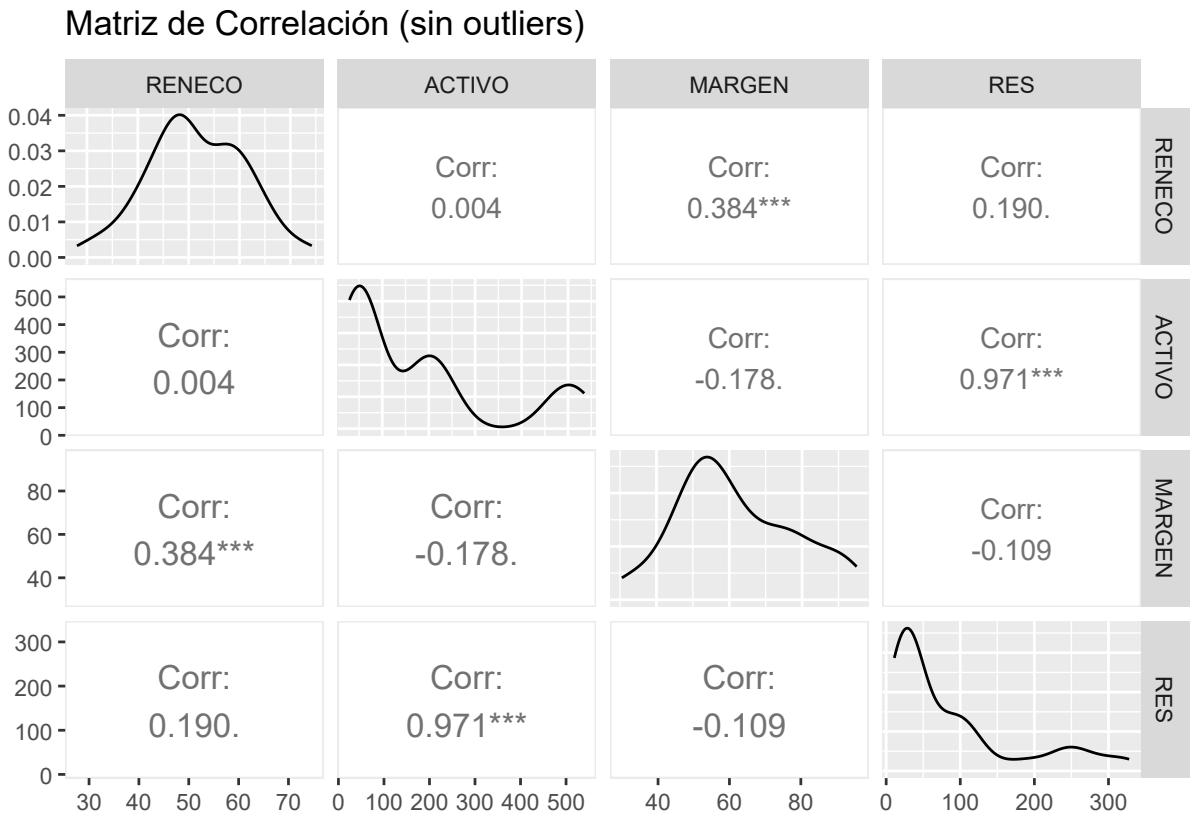


Figura 3.12

La matriz es una cuadrícula con una fila y una columna por variable:

- En la **diagonal**, la distribución de cada variable (su gráfico de densidad).
- Fuera de la diagonal, el **coeficiente de correlación de *Pearson*** de cada par de variables (en el triángulo inferior, destacado con un tamaño de letra mayor), acompañado de los asteriscos de significación estadística. La convención habitual es $\star$ para $p < 0{,}05$, $\star\star$ para $p < 0{,}01$ y $\star\star\star$ para $p < 0{,}001$; cuantos más asteriscos, menos probable resulta que la relación observada se deba al azar.

Un coeficiente de correlación se mueve entre **-1**, que indica una relación intensa en sentido opuesto, y **+1**, que señala una relación igualmente intensa pero en el mismo sentido. El gráfico muestra que ACTIVO y RES mantienen una relación muy fuerte y positiva, y que entre MARGEN y RENECO existe también un vínculo apreciable. En cambio, ACTIVO y MARGEN, por un lado, y RENECO y ACTIVO, por otro, apenas guardan relación estadística.

Para terminar, comparemos las correlaciones anteriores con las que resultan si mantenemos en la muestra los casos *outliers*:

```
correlaciones$comparacion
```

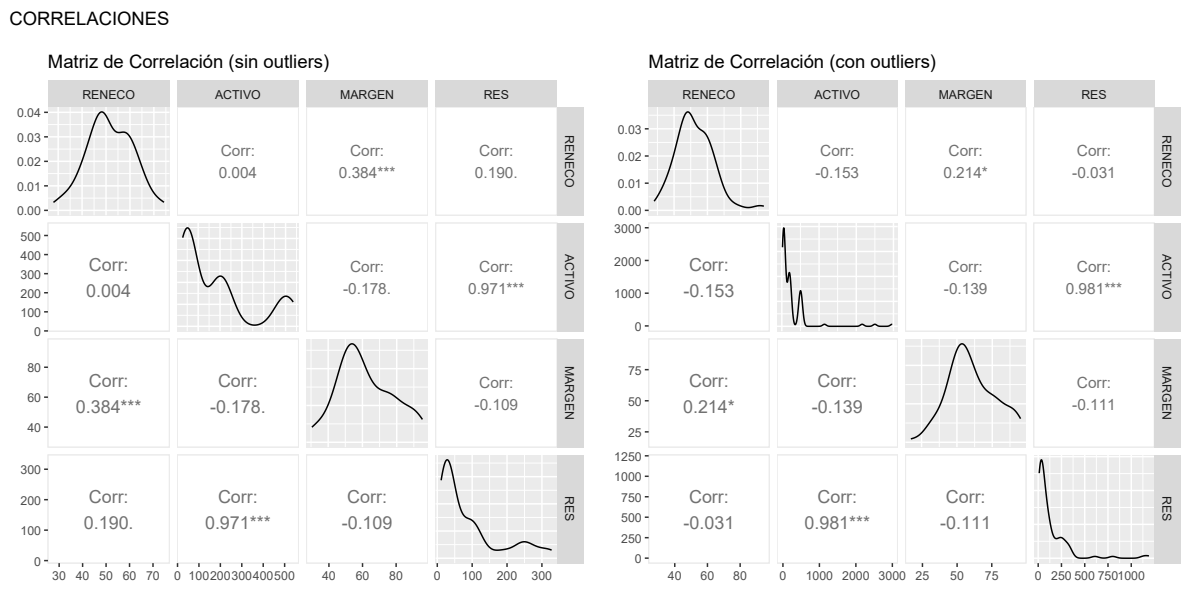


Figura 3.13

El contraste es elocuente: la presencia de *outliers* altera las relaciones entre las variables. La correlación entre ACTIVO y RES se refuerza, mientras que las de RENECO con MARGEN y con RES se debilitan. Todo ello confirma lo que ya apuntábamos: **decidir si se trabaja con o sin los casos atípicos** es una cuestión tan **relevante** como delicada.

Conclusión para el informe de Mara Qyà (parte 2): los principales indicadores financieros del sector están moderadamente correlacionados, con una relación especialmente fuerte entre el tamaño (ACTIVO) y el resultado (RES). No obstante, estas correlaciones son sensibles a la presencia de *outliers*, por lo que cualquier análisis más profundo deberá documentar explícitamente la decisión adoptada al respecto. Mara Qyà ya tiene los elementos clave para su auditoría.

3.5 Materiales para realizar las prácticas del capítulo.

En esta sección se recogen los enlaces de acceso a los distintos materiales (*scripts*, datos...) necesarios para desarrollar los contenidos prácticos del capítulo.

Datos (en formato Microsoft® Excel®):

- interestelar_100.xlsx (obtener aquí), o bien, desde R: `lite_datos("interestelar_100")`.

Script:

- previo_lite.R (obtener aquí)

CAPÍTULO 4

Componentes principales.



Figura 4.1. Carguero a dos niveles de resolución.

4.1 Introducción.

A veces, menos es más. Esta es la filosofía que subyace a las **técnicas de reducción de la dimensión** de la información.

Imaginemos una serie de casos (por ejemplo, las empresas de un sector económico) caracterizados por múltiples variables. Puede ocurrir que, paradójicamente, el contar con tantas variables haga difícil la caracterización de los casos. Esto ocurre cuando algunas de las variables aportan una información muy parecida sobre tales casos. Por ejemplo, es más difícil hacerse una idea del comportamiento global en el ámbito económico o financiero de un grupo de empresas si tenemos que atender a los valores que toman en un conjunto de 10 variables, que si solo tenemos que atender a un par de indicadores.

Las técnicas de reducción de la dimensión de la información tratan, precisamente, de disminuir el número de variables necesarias para caracterizar un grupo de casos, aprovechando la posibilidad de que las (múltiples) variables originales compartan información sobre estos. Es decir, la idea fundamental es pasar de un planteamiento basado en manejar muchas variables

con información compartida o redundante (variables que "dicen lo mismo" sobre el comportamiento de los casos) a un planteamiento en el que hay **menos variables**, pero que **no comparten información** (variables que "dicen" cosas diferentes sobre el comportamiento de los casos). En este proceso es importante que la pérdida de información sea mínima, y que solo se pierda la información redundante o repetida.

La principal técnica de reducción de la dimensión de la información es la de **componentes principales,** y es la que se expondrá y ejemplificará en el resto del capítulo. Pero antes, es preciso concretar la relación entre dos conceptos muy presentes en esta técnica: información y varianza.

4.2 Información y varianza.

En el apartado anterior hemos hablado de la posibilidad de que algunas variables compartan "información" sobre el comportamiento de los casos que constituyen nuestra muestra u objeto de estudio. Pero, ¿qué es, en este contexto, la "información"?

La ***información*** que una variable contiene sobre un conjunto de casos puede entenderse como su **capacidad para diferenciar a unos casos de otros**.

Observemos este ejemplo, en el que se representan los valores que toman un grupo de 20 empresas en 3 variables.



Figura 4.2. INFORMACIÓN Y VARIANZA

En la variable 1, todas las empresas toman el mismo valor. Por tanto, la capacidad que tiene la variable para distinguir a los casos (empresas), unos de otros, es nula. Eso es debido a que, en definitiva, esta variable no contiene información sobre el grupo de 20 empresas.

En la variable 2, existe cierta dispersión, aunque reducida, en los valores que adoptan los casos. Esto permite distinguir a unos de otros, aunque a veces con cierta dificultad. Por ejemplo, la empresa 17 se distingue del resto por ser la que tiene un valor (un poco) mayor. Aun así, como la dispersión es reducida, no se distinguen algunos casos de otros demasiado bien. En definitiva, la variable 2 contiene cierta cantidad de información sobre el conjunto de empresas de la muestra, aunque no demasiado grande.

Por último, la variable 3 muestra una dispersión considerablemente mayor que las otras dos variables. Existe un amplio abanico de valores que toman los diferentes casos (empresas). Esto hace que puedan diferenciarse con facilidad, en general, unos de otros. Esta variable posee, por tanto, una cantidad de información superior respecto a las empresas, ya que observando los valores que toman en la variable pueden diferenciarse con facilidad unas de otras.

Como conclusión, podemos establecer que cuanto mayor dispersión muestra una variable para un grupo de casos, mayor cantidad de información contiene sobre ellos, en el sentido de disfrutar de un mayor "poder" de diferenciación de unos casos respecto a otros.

Una medida de la dispersión de una variable usualmente utilizada es la **varianza**. Por tanto, en cierta manera, la varianza sirve para medir la cantidad de información que contiene la variable: a mayor varianza, mayor dispersión. Y a mayor dispersión, mayor cantidad de información.

En el ejemplo, puede observarse cómo la variable 3 es la que mayor varianza tiene, luego la variable 2, y la variable 1 tiene una varianza de 0 (y no posee información sobre las 20 empresas). Esta comparación de varianzas es válida siempre y cuando las tres variables estén expresadas en las mismas unidades, ya que la varianza es una medida de dispersión absoluta. Por ello, para poder comparar, hemos añadido también en el ejemplo una medida de dispersión relativa: el coeficiente de variación. Podemos comprobar cómo el mayor coeficiente de variación pertenece a la variable 3 (que es la que tiene una mayor cantidad de información), luego la variable 2 (que cuenta con menor cantidad de información), y por último la variable 1, con un coeficiente de 0 (no contiene información sobre las empresas).

4.3 La elección de *Arg-Us Korp*.

Vamos a considerar el caso del sector del "Transporte Interestelar". Tenemos una selección de 104 empresas o compañías. El "magnate" de los negocios a escala interplanetaria, *Arg-us Korp* (en la imagen), está de compras: quiere adquirir una de las empresas que mejor proyección a futuro en el sector tenga.



Figura 4.3. ARG-US KORP.

Entre las variables disponibles en la base de datos, la base de datos interestelar contiene varios indicadores que podrían reflejar la preparación de una empresa para afrontar el futuro: gasto en I+D, edad de la flota, gastos de capital, solvencia, beneficio por año-luz, diversificación, fidelización, digitalización...

Tras consultar con su equipo de analistas, *Korp* ha seleccionado tres de ellos, los que considera más relevantes para su estrategia de adquisición:

- **IDIVERSE (Índice de Diversificación):** empresas con operaciones diversificadas tienen mayor resiliencia ante cambios del mercado, ya que no dependen de una única fuente de ingresos ni de un solo tipo de carga.
- **IFIDE (Índice de Fidelización):** un alto nivel de fidelización indica relaciones sólidas con los clientes, lo que proporciona estabilidad de ingresos y ventajas competitivas a largo plazo.
- **IDIG (Índice de Digitalización):** la digitalización es clave en la eficiencia operativa y la adaptabilidad tecnológica. Un IDIG elevado sugiere inversión en automatización, software avanzado y optimización de procesos.

Aun así, su equipo sabe que Korp quiere una respuesta precisa. Un nombre de una empresa.

VÍDEO

Argus Korp sale de compras... pero con información.

https://youtu.be/DpeJxNtELLQ

El equipo ha pensado en crear un *ranking* de compañías basándose en estos tres indicadores. Pero, si tienen 3 variables, ¿cómo combinar su análisis para obtener un solo *ranking* de modo objetivo? ¿Cómo ponderar las tres variables?

La respuesta ha venido al comprobar que las tres variables guardan entre sí unas correlaciones relativamente altas (en valor absoluto). Es decir: aportan una información bastante parecida sobre cada una de las empresas de la selección. Esto es importante porque, si en gran medida comparten información "redundante", pueden ser, seguramente, "resumidas" en un solo indicador, cuyo valor o puntuación para cada caso (empresa) podría servir para establecer el ranking de compañías candidatas a ser adquiridas.

El método para obtener este indicador a partir de las tres variables originales se llama ***Análisis de Componentes Principales* (PCA)**. Ese indicador, que es la clave de toda la estrategia, será la primera "componente" del PCA, una combinación lineal de las tres variables originales; siempre y cuando su poder para "retener" la información global ofrecida por esas tres variables sea lo suficientemente alto.

4.4 Preparación previa de datos.

Vamos a suponer que trabajamos dentro de un **proyecto** que hemos creado previamente, de nombre **"componentes"**. Dentro de la carpeta del proyecto guardaremos el *script* "componentes_lite.R" y el archivo de Microsoft® Excel® "interestelar_100.xlsx", que contiene diferentes variables económicas y financieras de 104 empresas dedicadas a los servicios de transporte interestelar de mercancías.

Comenzaremos con los pasos habituales: limpiar el *Global Environment*, cargar `{MATlite}`, importar los datos y crear un *data frame* más reducido, al que llamaremos "seleccion", con las únicas variables del análisis (IDIVERSE, IFIDE e IDIG):

```
### Análisis de Componentes Principales ###

# Limpiando el Global Environment
rm(list = ls())

# Cargando el paquete de la asignatura
library(MATlite)

## DATOS
interestelar_100 <- lite_importa("interestelar_100.xlsx")

# Seleccionando las variables del análisis
seleccion <- interestelar_100 %>% select(IDIVERSE, IFIDE, IDIG)
lite_resumen(seleccion)
```

seleccion: 104 casos × 3 variables

Variable	Tipo	Categorías	Ausentes (%)	Media	Mediana	Desv. típica
IDIVERSE	Métrica		1.0	23.81	22.39	13.18
IFIDE	Métrica		1.0	39.39	39.18	6.16
IDIG	Métrica		0.0	18.16	16.71	10.92

Tabla 4.1

El siguiente paso consistirá en localizar los posibles ***missing values***, ya que para obtener componentes principales es necesario que todos los casos posean dato en todas las variables del análisis. Ante la existencia de *missing values*, se puede actuar de varios modos. Por ejemplo, **se puede intentar obtener el conjunto de valores que no están disponibles por otro canal de información,** o recurrir **a alguna estimación**. En caso de que esto sea difícil, se puede optar, simplemente, por **eliminar** estos casos, en especial cuando representan un porcentaje muy reducido respecto al total de observaciones. En nuestro ejemplo supondremos que hemos optado por esta última vía.

Recurrimos a la función `lite_na()`, que ya conocemos. Como "seleccion" solo contiene las variables del análisis, no es necesario indicarlas:

```
# Diagnóstico y filtrado de missing values.
seleccion <- lite_na(seleccion, accion = "eliminar",
                     titulo    = "Indicadores: Diversificación, Fidelidad, Digitalización",
                       subtitulo = "Transporte de mercancías interestelar")
```

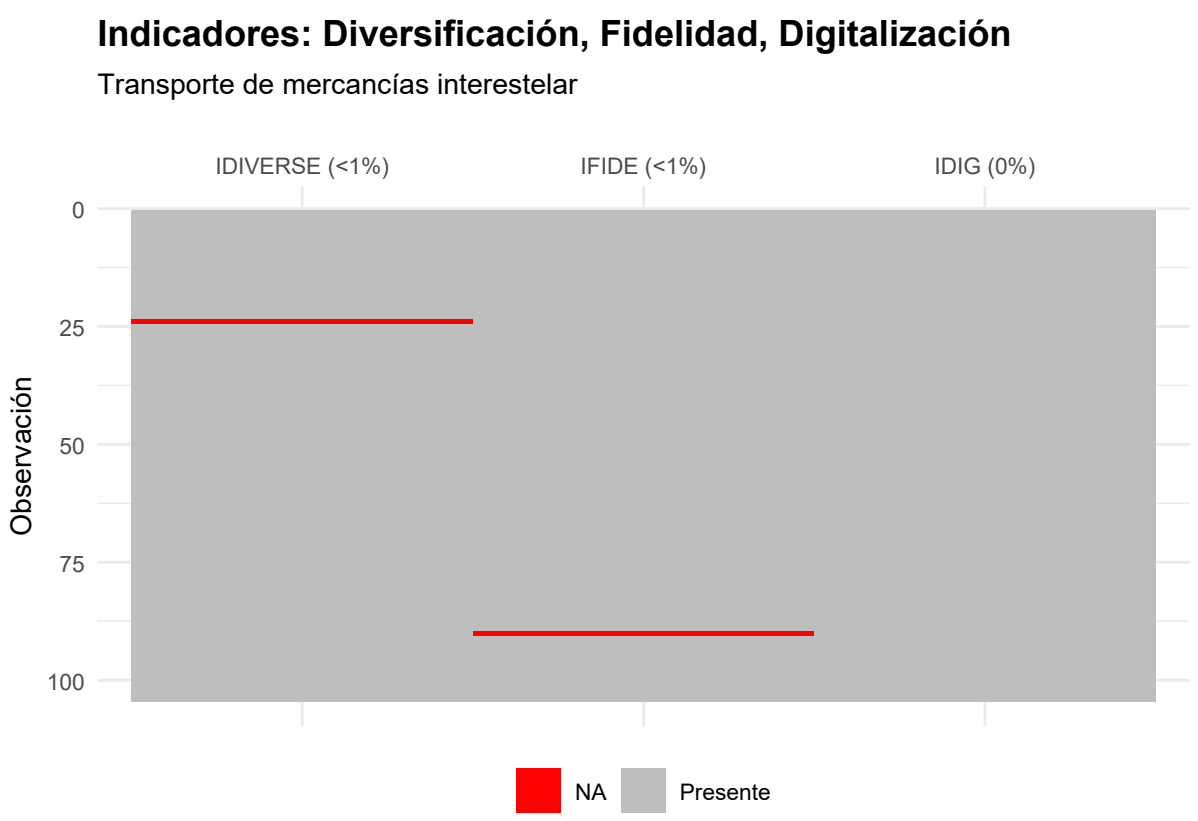


Figura 4.4

	IDIVERSE	IFIDE	IDIG
ezra bridger haulage	NA	34.11209	29.06697
alderaan freight	35.96067	NA	19.10291

Tabla 4.2

Del gráfico y de la tabla anteriores se desprende que existen 2 *missing values* repartidos en 2 de las 3 variables del estudio, correspondientes a las empresas *Ezra Bridger Haulage* y *Alderaan Freight*, que quedan eliminadas. Podemos verificar en el *Global Environment* que el *data frame* "seleccion" ha pasado a tener 102 casos.

Por otro lado, la técnica de componentes principales **es muy sensible a la existencia de *outliers***. En concreto, las observaciones atípicas pueden afectar a los resultados a través de tres vías:

- **Distorsión de las componentes principales:** pueden influir en la dirección de las componentes principales, haciendo que estas se ajusten más a los valores atípicos que a la mayoría de los datos. Esto puede llevar a una interpretación incorrecta de las relaciones entre las variables.
- **Afectación a las cargas de las variables:** estas cargas son relevantes porque indican la importancia relativa de cada variable original en la formación de la componente, es decir, cuánto contribuye o se correlaciona una variable específica con una componente principal.
- **Modificación de la varianza explicada:** pueden *inflar* la varianza total de los datos, lo que puede afectar a la proporción de varianza explicada por cada componente principal. Esto puede ocasionar una selección incorrecta del número de componentes a retener.

En consecuencia, deberán ser identificados y, en su caso, eliminados. Como contamos con tres variables métricas, `lite_outliers()` "resumirá" el valor que toma cada empresa en el conjunto de las variables mediante la ***distancia de Mahalanobis***, sobre la que aplicará la regla de 1,5 veces el rango intercuartílico. El resultado se almacena en un nuevo *data frame* llamado "seleccion_so":

```
# Diagnóstico y filtrado de outliers.
seleccion_so <- lite_outliers(seleccion, accion = "eliminar",
                              titulo    = "DISTANCIA DE MAHALANOBIS",
                              subtitulo = "IDIVERSE, IFIDE, IDIG. Empresas TMI.")
```

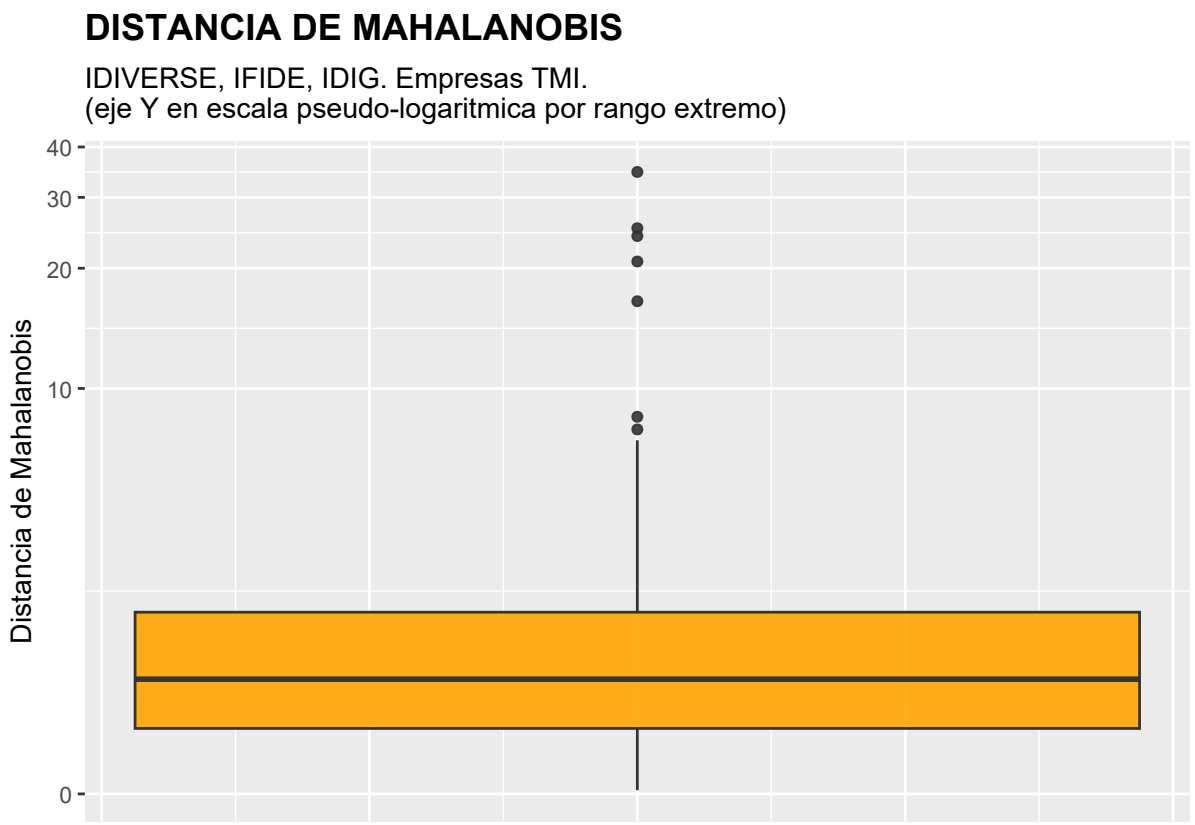


Figura 4.5

	MAHALANOBIS	IDIVERSE	IFIDE	IDIG
arrakis freight	34.687429	38.8813669	73.30230	58.5101128
ripley interstellar freight	25.147548	71.3507415	40.12974	4.4464628
hyperdrive express	24.045602	35.7898130	68.14784	33.6619031
home one cargo	20.784784	22.1760155	46.77635	60.8325142
chakotay cargo systems	16.548312	54.3681496	64.26013	42.7197240
kyber crystal shipping	8.476561	22.6273372	30.97667	34.0135033
tannhäuser freight	7.869429	47.8884591	42.64052	8.2092915
io star transport	7.380454	38.0206319	33.82858	35.1177708
hal intergalactic freight	7.174817	7.4887170	31.61145	28.1566284
andromeda cargo	6.445906	46.0541586	44.98949	44.3415811
jovian logistics	6.337391	22.3920052	29.77401	27.4342295
kobol cargo systems	5.449331	0.7736944	39.46283	0.6007237
hyperion star haulage	5.212257	11.7150226	26.44375	13.7407440

Tabla 4.3

El gráfico y la tabla anteriores confirman que hay 13 empresas que se comportan como *outliers*, considerando conjuntamente las tres variables del análisis. El *data frame* "seleccion_so" contiene los 89 casos restantes (los que **no** son *outliers* y no contenían *missing values*). Con él es con el que se procederá al cálculo de las componentes.

4.5 Correlaciones e idoneidad del análisis.

La **condición previa** para el **cálculo de componentes** es que las variables originales del análisis contengan información redundante, es decir, que en buena medida tengan una capacidad para diferenciar a los casos (empresas) parecida. Esto se verifica con la existencia de **altas correlaciones**, en valor absoluto, entre ellas (al menos, entre *algunas*). Por tanto, hemos de examinar la matriz de correlaciones:

```
# Correlaciones.
correlaciones <- lite_correlaciones(seleccion_so,
                                    titulo = "Matriz de Correlación sin outliers")
```

```
correlaciones$grafico
```

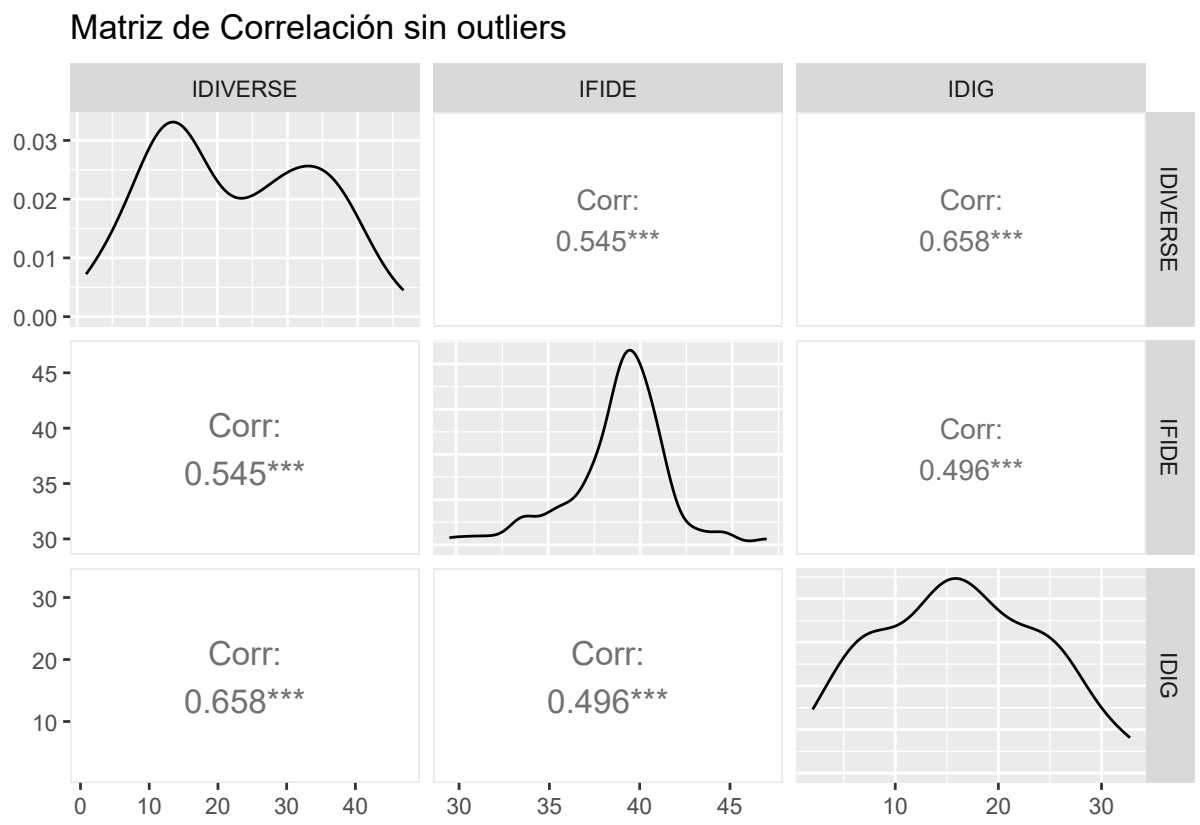


Figura 4.6

Puede apreciarse cómo existen altas correlaciones (en valor absoluto) entre todas las variables. Por tanto, tiene sentido hacer un análisis de componentes principales, ya que hay variables que parecen **compartir información**.

Ahora bien, este diagnóstico es **visual y, en buena medida, subjetivo**: ¿a partir de qué valor consideramos que una correlación es "alta"? ¿Y qué hacemos si unas variables correlacionan mucho y otras poco? Afortunadamente, existe una **medida objetiva** que ayuda a responder a estas preguntas: la **medida de adecuación muestral KMO** (*Kaiser-Meyer-Olkin*), heredada de la tradición del *análisis factorial*, y que se calcula siempre **antes** de extraer las componentes.

Su filosofía es la siguiente. El KMO compara la magnitud de las correlaciones *simples* entre las variables con la de las correlaciones *parciales*, esto es, las que quedan entre cada par de variables una vez descontado el efecto del resto. El razonamiento es que, si las variables comparten una estructura común —que es justamente lo que una componente trata de capturar—, al descontar el efecto de las demás la correlación entre dos de ellas debería reducirse mucho. En ese caso las correlaciones parciales serán pequeñas frente a las simples, y el KMO tomará un valor próximo a 1. Si, por el contrario, cada par de variables correlaciona "por su cuenta", las parciales seguirán siendo altas y el KMO se aproximará a 0. Formalmente:

$$\text{KMO} = \frac{\sum_{i \neq j} r_{ij}^2}{\sum_{i \neq j} r_{ij}^2 + \sum_{i \neq j} a_{ij}^2}$$

donde r_{ij} son las correlaciones simples entre cada par de variables, y a_{ij} las correlaciones parciales (los elementos de la denominada *matriz anti-imagen*).

Qué es, exactamente, una correlación parcial. Conviene detenerse en este concepto, porque es la pieza sobre la que descansa todo el indicador. Una correlación parcial no responde a una fórmula distinta de la ordinaria: es una **correlación corriente, calculada sobre los restos**. Para obtener la que existe entre dos variables una vez descontado el efecto de una tercera, el procedimiento consta de tres pasos:

1. Se regresa la **primera** variable sobre la tercera, y se guardan los **residuos**: la parte de la primera que la tercera *no* consigue explicar.
2. Se hace lo mismo con la **segunda** variable.
3. Se **correlacionan ambos vectores de residuos**. Eso es la correlación parcial.

Podemos comprobarlo con nuestros propios datos. La correlación entre IFIDE (fidelización) e IDIG (digitalización) es apreciable; pero si descontamos de ambas el efecto de IDIVERSE (diversificación) y correlacionamos lo que queda, el resultado cambia radicalmente:

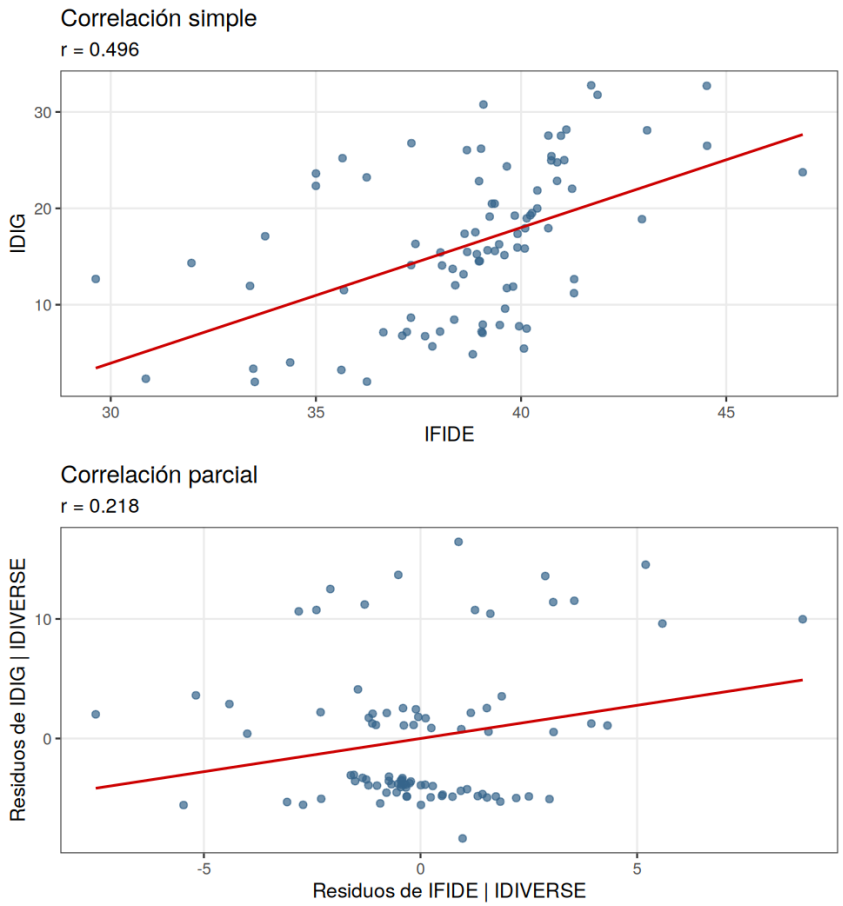


Figura 4.7. Correlación simple frente a correlación parcial entre IFIDE e IDIG, descontando el efecto de IDIVERSE.

La correlación pasa de 0,496 a 0,218: cae un 56 %. Dicho en términos económicos, **la fidelización y la digitalización se relacionan, en buena medida, a través de la diversificación**. Una vez descontada esta, lo que queda de relación directa entre aquellas dos es mucho más débil. Ese desplome es, precisamente, la señal que el KMO busca.

Y es también lo que distingue las dos situaciones que el indicador pretende separar:

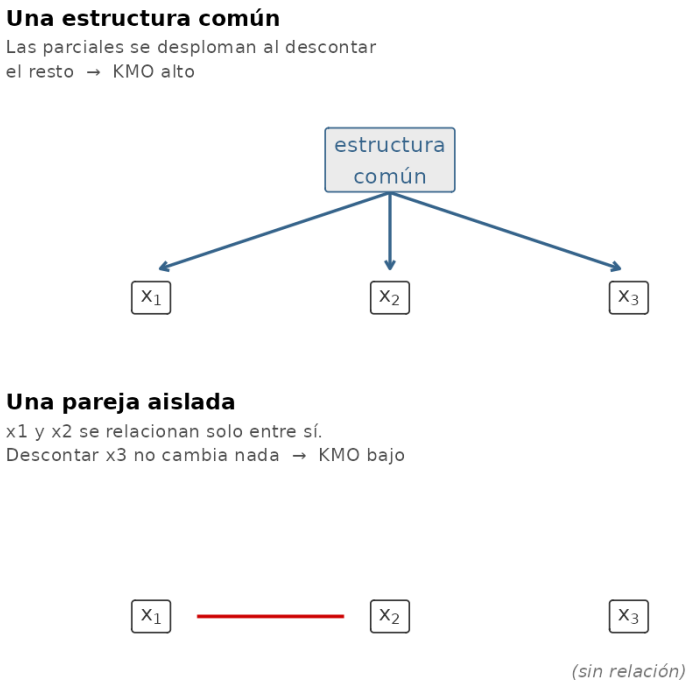


Figura 4.8. Las dos situaciones que distingue el KMO: una estructura común a todas las variables frente a una pareja de variables aislada.

A la izquierda, todas las variables son manifestaciones de una misma dimensión subyacente —que es lo que una componente principal trata de capturar—, de modo que al descontar unas de otras la relación directa se evapora. A la derecha, en cambio, las variables se emparejan **por su cuenta**, en bloques independientes: descontar las ajenas no altera nada, las parciales siguen siendo altas y el KMO se desploma.

La diferencia no es un tecnicismo. El PCA promete **resumir muchas variables en pocas**, y eso solo funciona si existe una dimensión compartida por todas. Si lo que hay son parejas sueltas, haría falta una componente por pareja: no se habría reducido nada.

Kaiser propuso la siguiente escala para interpretar el resultado:

- KMO ≥ 0.90: excelente.
- 0.80 ≤ KMO < 0.90: notable.
- 0.70 ≤ KMO < 0.80: aceptable.
- 0.60 ≤ KMO < 0.70: mediocre.
- 0.50 ≤ KMO < 0.60: bajo.
- KMO < 0.50: inaceptable (no debería plantearse el análisis).

Junto a este KMO global, que se refiere al conjunto del análisis, puede calcularse un KMO **individual** para cada variable: es la medida *MSA* (*Measure of Sampling Adequacy*). Resulta muy útil en la práctica, porque permite detectar variables que no encajan en la estructura común del

conjunto: si alguna presenta un MSA inferior a 0.50, lo razonable es plantearse excluirla del análisis y recalcular.

Ambas medidas, y todo lo que necesitamos para el resto del análisis, se obtienen con la función `lite_acp()`. Le indicamos el *data frame* con el que vamos a calcular las componentes ("seleccion_so") y, si queremos, un subtítulo para sus gráficos. Guardaremos el resultado en el objeto "componentes":

```
# Componentes principales
componentes <- lite_acp(seleccion_so, subtitulo = "Empresas TMI")
```

La adecuación muestral queda en la pieza `kmo`:

```
componentes$kmo
```

Medida	Valor	Interpretación
KMO global	0.688	mediocre
MSA: IDIVERSE	0.649	Adecuada
MSA: IFIDE	0.773	Adecuada
MSA: IDIG	0.672	Adecuada

Tabla 4.4

En nuestro caso, el KMO global asciende a 0.688, un valor que la escala de Kaiser califica como **mediocre**: queda algo por debajo del umbral de 0.70 que marcaría una adecuación claramente aceptable, pero bastante por encima del 0.50 a partir del cual habría que descartar el análisis. Dicho de otro modo, las tres variables comparten información suficiente para justificar el PCA, aunque no estemos ante un caso de libro. Conviene no perder de vista, en este sentido, que solo manejamos tres variables, de modo que cada correlación parcial se calcula descontando el efecto de una única variable.

En cuanto a los MSA individuales, los tres superan con holgura el umbral de 0.50 —el menor corresponde a IDIVERSE, con 0.649—, por lo que ninguna de las variables desentona del conjunto y no hay motivo para excluir a ninguna del análisis.

Conviene cerrar el apartado con una precisión. El KMO nació en el ámbito del *análisis factorial*, una técnica emparentada con el PCA, pero no idéntica. El análisis de componentes principales es, en esencia, una técnica **descriptiva**: no exige supuestos distribucionales ni pretende inferir una estructura latente, por lo que, en rigor, ningún indicador "autoriza" o "prohíbe" su aplicación. El KMO debe entenderse, por tanto, como una **ayuda a la decisión** que complementa —pero no sustituye— al examen de la matriz de correlaciones y al criterio del analista.

4.6 Cálculo de componentes.

`lite_acp()` calcula las componentes a partir de las **versiones tipificadas** de las variables originales, de modo que todas ellas pesan lo mismo con independencia de sus unidades de medida. El primer resultado que conviene examinar es la cantidad de información (varianza) que recoge cada componente:

```
componentes$varianza
```

Componente	Desv. típica	Proporción de varianza (comunalidad)	Proporción de varianza (comunalidad) acumulada
PC1	1.46	0.71	0.71
PC2	0.73	0.18	0.89
PC3	0.58	0.11	1.00

Tabla 4.5

La "desviación típica" es la raíz cuadrada de los autovalores asociados a cada componente. La "proporción de varianza" nos dice la proporción de la suma de varianzas de las variables originales (*comunalidad*) recogida por cada componente, proporción que se acumula en la última columna. Nótese que las componentes aparecen ordenadas de más a menos importantes en función de la cantidad de varianza que capturan.

En este caso, podemos destacar que la primera componente recoge más del 71 % de la varianza (*comunalidad*) o información puesta en juego globalmente por las tres variables originales. Las dos primeras componentes, en conjunto, aglutinan casi el 89 % de la información que las tres variables ofrecen sobre el comportamiento de las empresas. Entre las tres componentes, lógicamente se recoge el 100 % de la *comunalidad* o varianza global.

Los coeficientes o **cargas** de cada componente están en la pieza `cargas`:

```
componentes$cargas
```

	PC1	PC2	PC3
IDIVERSE	0.601	0.273	0.752
IFIDE	0.544	-0.828	-0.135
IDIG	0.586	0.490	-0.646

Tabla 4.6

En la tabla, se muestran las cargas (*loads*), que son los coeficientes que intervienen en las combinaciones lineales que definen cada componente, a partir de las variables originales (tipificadas). Por tanto, con base en las cargas se pueden explicitar las ecuaciones correspondientes a cada componente. Por ejemplo, para la primera componente, la ecuación será:

$$\text{CP}_{i1} = 0.6006 \cdot \text{IDIVERSE}_{i1} + 0.5442 \cdot \text{IFIDE}_{i1} + 0.5858 \cdot \text{IDIG}_{i1}$$

Puede observarse que, en cuanto a la primera componente, que es la que especialmente nos interesa como *indicador* de la "preparación de las diferentes compañías de transporte para afrontar el futuro", las 3 cargas tienen signo positivo, lo que implica que, cuanto mayores sean los valores de una empresa en las variables **IDIVERSE** (*índice de diversificación*), **IFIDE** (*índice de fidelidad*) e **IDIG** (*índice de digitalización*), mayor será el valor del indicador y, por tanto, su preparación. Además, como las variables fueron tipificadas, los valores de las cargas son comparables. De este modo, vemos cómo, dentro de la primera componente, que es la que adoptamos como indicador, la mayor importancia la tiene **IDIVERSE**, seguido de **IDIG** y, por último, **IFIDE**.

4.7 Retención de componentes.

La etapa de retención de componentes consiste en decidir cuántas de las componentes generadas (recordemos que, en un principio, se calculan tantas componentes como variables originales) consideramos que resumen de un modo aceptable la información contenida en las variables originales. Estas **componentes "retenidas" se convertirán en las componentes principales**.

La primera componente siempre es retenida y, por tanto, es una "componente principal". El resto, que van capturando proporciones cada vez menores de la varianza común de las variables originales (*comunalidad*), podrán o no retenerse; aunque, siempre, la retención de una componente implica que se han retenido todas las anteriores. En este caso práctico, buscamos un único indicador de la "preparación de las diferentes compañías de transporte para afrontar el futuro", por lo que solo vamos a "retener" la primera componente. En otras aplicaciones, podría ser necesario retener varias para recoger la suficiente comunalidad.

Hay varios procedimientos o criterios para decidir cuántas componentes retener. Uno de ellos, comúnmente aplicado, es el de **retener aquellas componentes cuyo autovalor es mayor que 1** (suponiendo que se ha trabajado con las variables en sus versiones tipificadas). Los autovalores son el cuadrado de las desviaciones típicas de las componentes. `lite_acp()` los representa en un gráfico de barras, junto con el porcentaje de varianza acumulada al ir reteniendo las sucesivas componentes:

```
componentes$retencion
```

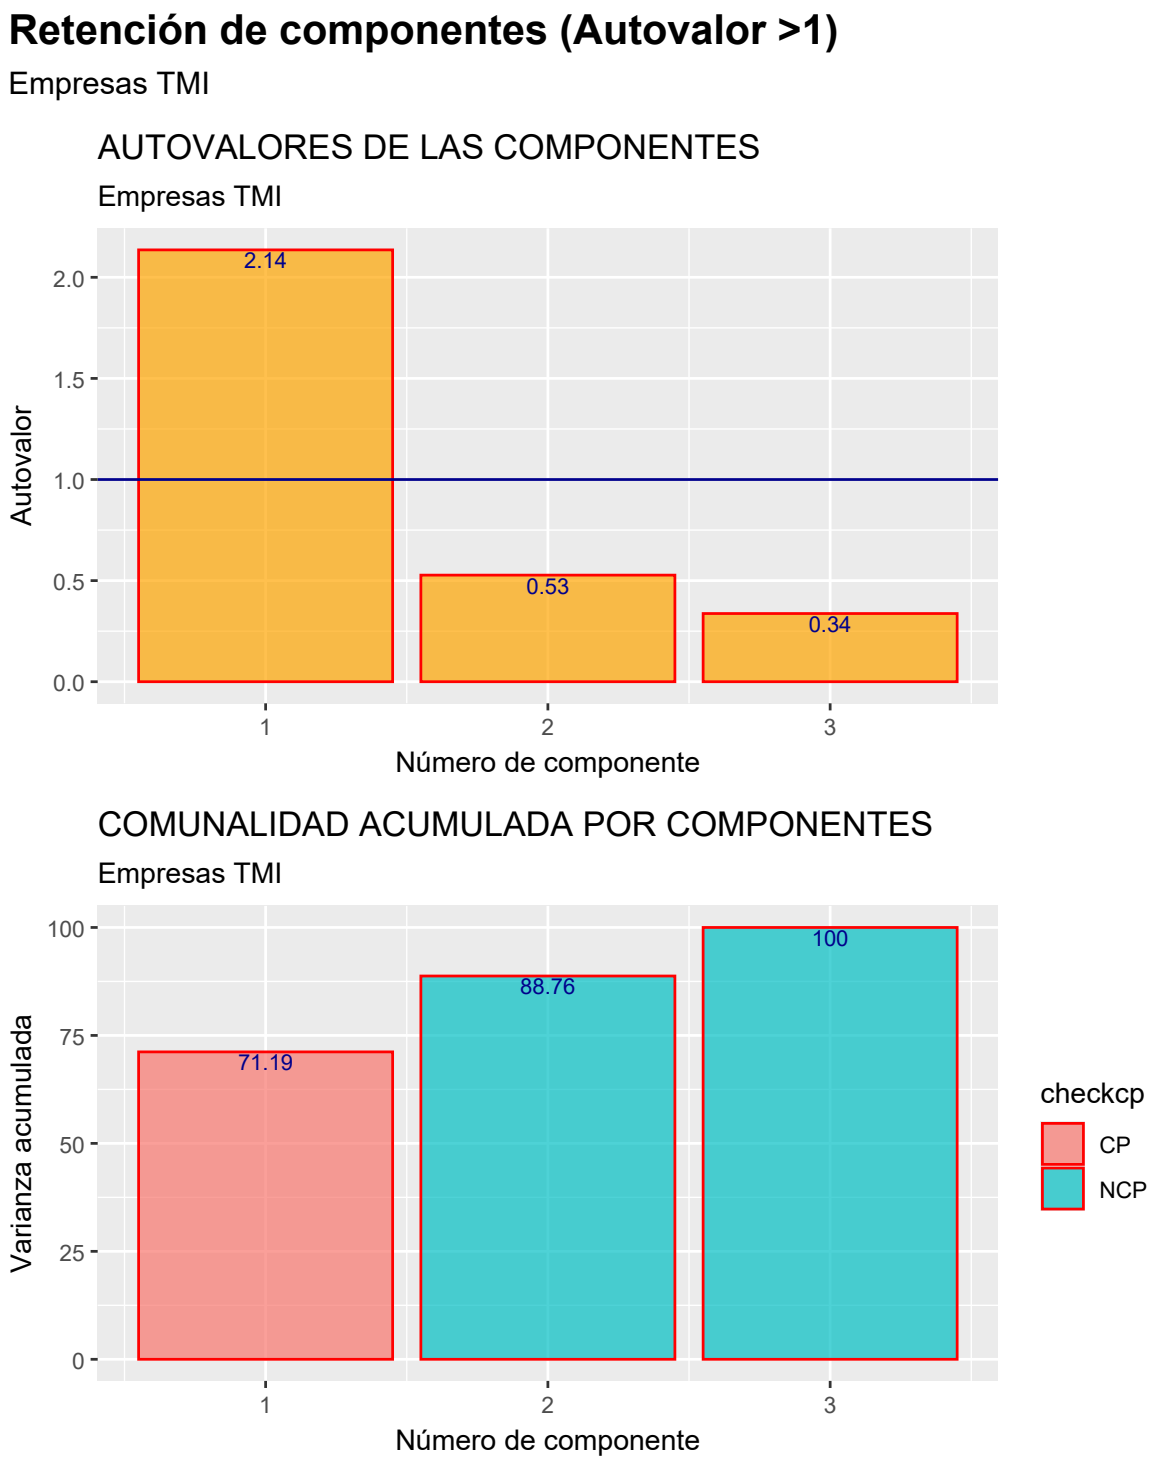


Figura 4.9

En el gráfico superior, las componentes cuyas barras atraviesan la línea que pasa por el valor "1" son las que deberían ser retenidas, ya que son las componentes que resumen de modo suficiente la información ofrecida sobre el comportamiento de los casos por las variables originales. En este caso, basta con retener solo la primera componente (por lo tanto, solo contamos con una **componente principal**). Este es un resultado favorable cara a nuestro propósito, ya que nos indica que podemos usar como indicador solo una componente, la primera, y con ella

resumiremos suficientemente las tres variables originales. Por tanto, es un buen indicador, en ese sentido.

El gráfico inferior muestra el porcentaje de varianza total (comunalidad) acumulada, un resultado que ya se obtuvo en forma de tabla. Las barras de las componentes que cumplen el criterio aparecen marcadas como "CP" (componente principal) y las demás, como "NCP".

Una vez confirmado el hecho de que la primera componente es suficiente para contar con un buen indicador de "preparación de las diferentes compañías de transporte para afrontar el futuro", considerando los aspectos de *digitalización*, *diversificación* y *fidelización* de clientes, pasaremos a estudiar qué casos concretos ofrecen mejores (mayores) valores en el indicador, para lo cual hemos de calcular sus puntuaciones.

4.8 Puntuaciones de los casos (scores).

Las puntuaciones de cada caso (empresa) en el indicador de "preparación de las diferentes compañías de transporte para afrontar el futuro" (nuestra componente principal, que coincide con la primera componente) se obtienen con la función `lite_acp_ranking()`, que ordena las empresas de mayor a menor puntuación y presenta las 10 primeras:

```
# Puntuaciones (scores) y ranking
ranking <- lite_acp_ranking(componentes)
```

```
ranking$ranking
```

Caso	Puntuación	IDIVERSE	IFIDE	IDIG
shuttlepod movers	2.662	40.677	43.071	28.098
kamino movers	2.550	26.602	44.526	32.715
icarus star transport	2.447	35.055	41.709	32.762
mirror universe cargo	2.407	43.021	41.104	28.170
sith transport corp.	2.326	33.559	41.863	31.774
hoth haulage	2.263	46.547	42.946	18.875
adama transport	2.251	42.547	40.666	27.549
star gate logistics	1.982	40.135	40.740	25.417
assimilator haulage	1.942	23.746	44.533	26.489
dagobah freightlines	1.835	16.902	46.864	23.744

Tabla 4.7

```
ranking$grafico
```

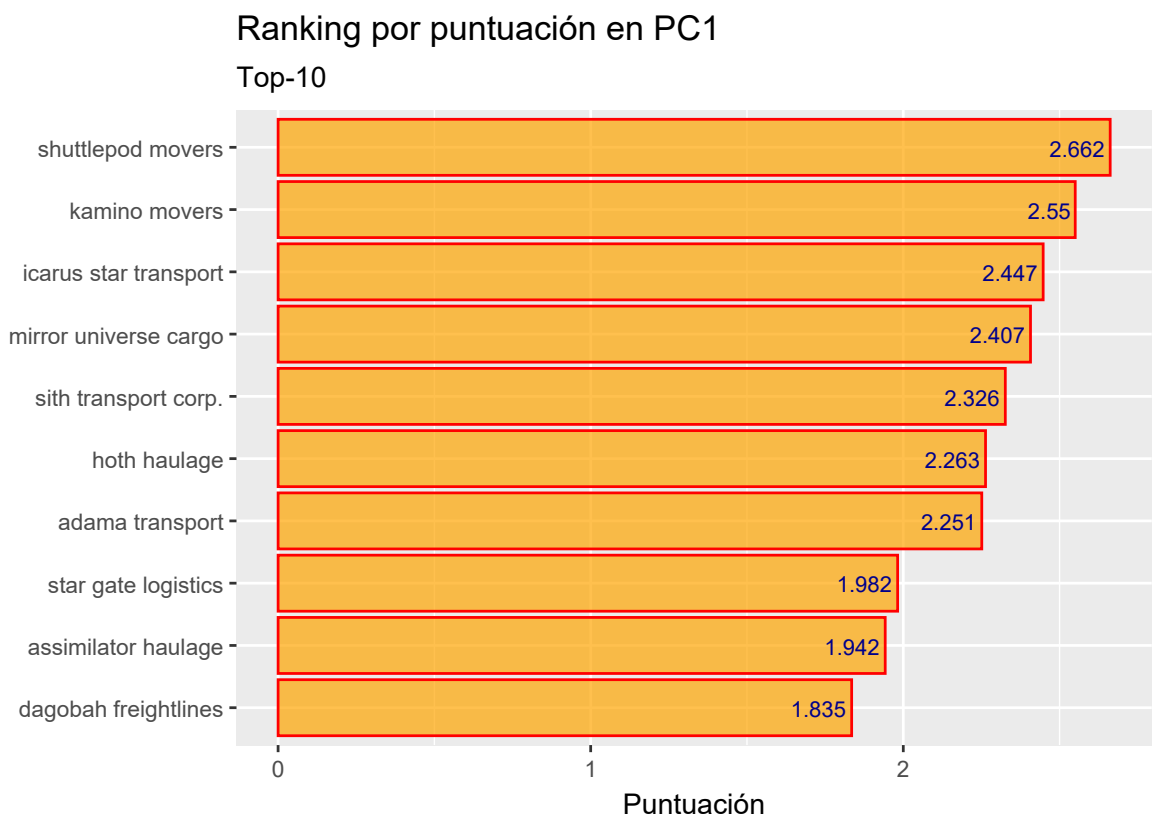


Figura 4.10

De la tabla y gráfico anteriores podemos concluir que las empresas más preparadas para afrontar el futuro, según nuestro indicador (primera componente del análisis PCA) son, por este orden, *Shuttlepod Movers*, *Kamino Movers* e *Ícarus Star Transport*.

¿Seguro?

Este *ranking* se ha elaborado a partir de las compañías que formaron la muestra para realizar el análisis de componentes principales. Estas empresas eran aquellas que tenían dato en las tres variables originales y que **no habían sido calificadas como *outliers***. Los *outliers* se apartaron de la muestra para evitar distorsiones y sesgos en el análisis. Pero una cuestión que podríamos plantearnos es si, una vez calculadas las combinaciones lineales que son las *componentes* sin su influencia, podrían ser ahora, en virtud de esas componentes calculadas, puntuadas. Que una compañía se comporte como *outlier* en una o varias de las variables originales, y no se cuente con ella a la hora de calcular las componentes; no quiere decir necesariamente que no sea una buena candidata a ser la elegida para ser adquirida por su preparación para afrontar el futuro (incluso podría concluirse que en algún aspecto está "especialmente preparada").

Para puntuarlas basta con indicar a `lite_acp_ranking()`, con el argumento `datos`, el *data frame* que todavía conserva a los *outliers* ("seleccion"):

```
# Puntuando también a los outliers
ranking_todas <- lite_acp_ranking(componentes, datos = seleccion)
```

```
ranking_todas$ranking
```

Caso	Puntuación	IDIVERSE	IFIDE	IDIG
arrakis freight	10.695	38.881	73.302	58.510
chakotay cargo systems	8.580	54.368	64.260	42.720
hyperdrive express	7.695	35.790	68.148	33.662
home one cargo	4.834	22.176	46.776	60.833
andromeda cargo	4.516	46.054	44.989	44.342
shuttlepod movers	2.662	40.677	43.071	28.098
kamino movers	2.550	26.602	44.526	32.715
icarus star transport	2.447	35.055	41.709	32.762
mirror universe cargo	2.407	43.021	41.104	28.170
sith transport corp.	2.326	33.559	41.863	31.774

Tabla 4.8

Vemos como el *ranking* cambia radicalmente, y pasa a estar encabezado por las compañías ***Arrakis Freight***, ***Chakotay Cargo Systems*** e ***Hyperdrive Express***. Si un análisis particularizado de estas empresas por parte del equipo encargado del estudio da como resultado que sus datos son correctos, serían, seguramente, las candidatas para ser adquiridas por el magnate *Arg-Us Korp*.

4.9 Efecto de los *outliers* en las puntuaciones.

Cabe hacerse una pregunta antes de cerrar esta historia. ¿Qué hubiera ocurrido si se hubieran calculado las componentes sin eliminar los *outliers* previamente? ¿Hubieran cambiado los resultados? ¿era tan relevante el efecto de estos casos sobre los resultados, como comentamos al comienzo del tema, en la parte teórica?

Con `{MATlite}` es muy sencillo comprobarlo: basta con repetir el cálculo sobre el *data frame* "seleccion", que conserva los *outliers*:

```
# Componentes calculadas CON los outliers
componentes2 <- lite_acp(seleccion, subtitulo = "Empresas TMI (con outliers)")
ranking2 <- lite_acp_ranking(componentes2)
```

```
ranking2$ranking
```

Caso	Puntuación	IDIVERSE	IFIDE	IDIG
arrakis freight	5.999	38.881	73.302	58.510
chakotay cargo systems	4.962	54.368	64.260	42.720
hyperdrive express	4.044	35.790	68.148	33.662
home one cargo	2.930	22.176	46.776	60.833
andromeda cargo	2.892	46.054	44.989	44.342
shuttlepod movers	1.606	40.677	43.071	28.098
mirror universe cargo	1.526	43.021	41.104	28.170
icarus star transport	1.491	35.055	41.709	32.762
adama transport	1.431	42.547	40.666	27.549
kamino movers	1.391	26.602	44.526	32.715

Tabla 4.9

Como puede repararse, los cambios, en este caso, no parecen ser relevantes. Solo a partir de la séptima posición se registran cambios en el orden de las empresas.

4.10 La decisión de *Arg-Us Korp*.

¿Cuál de los rankings elegiríamos? La elección no es trivial, y depende de la confianza que tengamos en la calidad de los datos.

Conviene reparar, eso sí, en que **el primer ranking no es comparable con los demás**. Se elaboró únicamente sobre las 89 compañías que entraron en el cálculo, de modo que las trece calificadas como atípicas no podían figurar en él: no es que obtuvieran peores puntuaciones, es que sencillamente no se las puntuó. Por eso lo encabezan *Shuttlepod Movers*, *Kamino Movers* e *Ícarus Star Transport*, que son las mejor preparadas **del núcleo** del sector.

En cuanto se permite puntuar a todas las compañías —ya sea aplicándoles las componentes calculadas sin ellas, ya sea incluyéndolas en el propio cálculo—, el panorama cambia, y lo hace de forma consistente: ***Arrakis Freight*** encabeza la clasificación, seguida de ***Chakotay Cargo Systems*** y de ***Hyperdrive Express***. No es casualidad que Arrakis lidere: *Arrakis Freight* presenta valores muy por encima de la media del sector en las tres dimensiones consideradas —diversificación, fidelización y digitalización—, y es justamente esa combinación excepcional la que la había convertido en un caso atípico.

La conclusión metodológica es, quizá, la más valiosa del capítulo: **la decisión sobre los *outliers* no es un detalle de depuración previa, sino que determina la respuesta**. Si *Korp* se niega a considerar a las empresas atípicas, su candidata es *Shuttlepod Movers*; si acepta considerarlas, una vez verificado que sus datos son correctos, su candidata es *Arrakis Freight*.

Queda, con todo, una última lección, y esta ya no es estadística. Un *ranking* **ordena**; no decide. El indicador que hemos construido mide la preparación de cada compañía para afrontar el futuro, pero no sabe nada de quién está dispuesto a vender, ni a qué precio, ni de qué encaja con lo que el comprador ya tiene. Esas restricciones no están en los datos, y son precisamente las que convierten una clasificación en una operación.

Cuentan las crónicas que *Arg-us Korp*, con el informe de su equipo sobre la mesa —los *rankings* que puntuaban a todas las compañías—, fue tachando nombres de arriba abajo:

- ***Arrakis Freight***, la primera, no estaba en venta ni lo iba a estar: pertenece a ***Romulus Steiner***, el único magnate del sector con una fortuna comparable a la de *Korp* y un temperamento notoriamente peor. Dicen que respondió a la oferta con un mensaje de tres palabras que la agencia nunca ha hecho público.
- ***Chakotay Cargo Systems***, la segunda, es una cooperativa de tripulaciones: sus estatutos prohíben la venta de la compañía a un propietario único, y su extraordinario índice de fidelización se sostiene justamente sobre ese modelo de propiedad. Comprarla habría significado destruir aquello que la hacía valiosa.
- ***Hyperdrive Express***, la tercera, tiene **arrendada la totalidad de su flota**. Su puntuación es legítima —fideliza, diversifica y digitaliza—, pero adquirirla equivalía a comprar una cartera de contratos de alquiler más que una naviera.
- La siguiente, cuarta en los *rankings*, era ***Home One Cargo***. Y ahí se detuvo *Korp*.

La elección no fue un premio de consolación. El grupo de *Korp* ya era grande y diversificado: lo que le faltaba no eran rutas ni clientes, sino **tecnología**. Y *Home One Cargo* posee el **mayor índice de digitalización de toda la muestra** (60,8 puntos, frente a una media sectorial de 18,2), sostenido por una plataforma propia de gestión de flotas desplegable en el resto del grupo. Su diversificación moderada, que en el *ranking* la penalizaba, dejaba de ser un defecto en este contexto: la diversificación la ponía el comprador.

Así que *Arg-us Korp* —siguiendo los consejos de su equipo de analistas, armados con R y un buen análisis de componentes principales— **adquirió *Home One Cargo*** pocas semanas después. El precio de la operación no se ha hecho público, pero los analistas del sector coinciden en que fue una compra inteligente: pagó por una compañía que ningún *ranking* subía al podio y se llevó exactamente la pieza que le faltaba. Korp, fiel a su estilo, cerró la reunión de adquisición antes de que nadie más pudiera hablar.

4.11 Materiales para realizar las prácticas del capítulo.

En esta sección se muestran los links de acceso a los diferentes materiales (*scripts*, datos...) necesarios para llevar a cabo los contenidos prácticos del capítulo.

Datos (en formato Microsoft® Excel®):

- interestelar_100.xlsx (obtener aquí), o bien, desde R: `lite_datos("interestelar_100")`.

Script:

- componentes_lite.R (obtener aquí)

CAPÍTULO 5

Análisis clúster jerárquico.



Figura 5.1. GRUPOS DE CARGUEROS EN TRAVESÍA.

5.1 Introducción.

El análisis de conglomerados —o análisis de clústeres (AC)— agrupa casos con características similares en función de un conjunto de variables clasificadoras. El objetivo es que:

- Los casos de un mismo clúster sean lo más homogéneos posible entre sí.
- Los clústeres entre sí sean lo más heterogéneos posible, de acuerdo con las variables consideradas.

En general, el proceso de determinación de los grupos, conglomerados o clústeres de casos es el siguiente:

- Se parte de un conjunto de **n** casos, y para cada uno de ellos se cuenta con el valor de **m** variables clasificadoras.
- Se establece una **medida de distancia** que cuantifica lo que dos casos se parecen, **considerando en conjunto** los valores que poseen para las variables clasificadoras.

- Se crean los grupos, conglomerados o clústeres con los casos que poseen entre sí una **menor distancia**.
- Finalmente, se **caracterizan** los grupos, conglomerados o clústeres obtenidos, y se comparan unos con otros para extraer conclusiones.

En lo que respecta a la medida de **distancia** entre los casos, la medida más habitual es la **distancia euclídea**. Así, la distancia euclídea entre dos casos, i e i', para las m variables clasificadoras x, será:

$$d(i,i') = \sqrt{\sum_{j=1}^{m}(x_{ij} - x_{i'j})^2}$$

Esta distancia es muy sensible a la escala de las variables clasificadoras. Para evitar este inconveniente, se trabaja con las variables previamente **tipificadas**.

5.1.1 Clasificación de los métodos de análisis clúster.

En la literatura actual (Kaufman y Rousseeuw 1990; Xu y Wunsch 2005; Jain 2010; Aggarwal 2015), los métodos de análisis clúster se clasifican en cinco grandes familias:

- **Métodos jerárquicos.** Van formando sucesivamente grupos como agrupación de otros grupos precedentes (métodos aglomerativos: *Ward*, *single linkage*, *complete linkage*...) o dividen recursivamente un único grupo inicial (métodos divisivos). Producen una estructura piramidal (dendrograma).
- **Métodos de partición o basados en centroides.** Asignan los casos a un número prefijado de grupos, minimizando la varianza intra-clúster. El más representativo es ***k-medias***.
- **Métodos basados en densidad.** Detectan regiones densamente pobladas del espacio de variables y las declaran clústeres, dejando fuera los casos aislados como ruido. El más representativo es ***DBSCAN***.
- **Métodos basados en modelos.** Suponen que los datos provienen de una mezcla de distribuciones (típicamente gaussianas).
- **Métodos basados en cuadrículas o en grafos.** Discretizan el espacio en celdas o construyen grafos de similitud.

En este capítulo abordaremos el primero de ellos, los **métodos jerárquicos**, en concreto el **método de Ward**, muy adecuado cuando el número de casos es reducido y se quiere clasificar a **todos** ellos. Los métodos de *k-medias* y DBSCAN se desarrollan en el capítulo 7 de *R-Stars: La Guía*.

5.2 El Informe *Bluebird*.



Figura 5.2. Agencia Interplanetaria del Transporte de Mercancías.

La *Agencia Interplanetaria de Transporte de Mercancías* (AITM) tiene entre sus cometidos el estudio del sector desde una perspectiva de segmentación. La doctora ***Xelia Bluebird*** (en la imagen), investigadora sénior de la agencia, es la responsable del informe anual de segmentación empresarial que lleva su nombre.



Figura 5.3. Xelia Bluebird, investigadora de la AITM.

Este año, el primer encargo del ***Informe Bluebird*** es un **panel de candidatas premium**. Tras la reciente compra de *Home One Cargo* por *Arg-us Korp*, la AITM ha seleccionado un panel de **25 empresas top** para ofrecerles un programa de consultoría personalizada. Bluebird debe agrupar estas 25 candidatas en un número reducido de perfiles y ubicar en qué grupo queda encuadrada *Home One Cargo* junto a otras empresas de referencia. Al ser una muestra pequeña, donde nos interesa clasificar **todos los casos** —incluidos los eventuales *outliers*—, se aplicará un **método jerárquico** (algoritmo de Ward).



VÍDEO

Preparando el Informe Bluebird.

https://youtu.be/I-lKgEEJUUk

Las variables clasificadoras son los índices de **fidelización de clientes (IFIDE)**, **diversificación del negocio (IDIVERSE)** y **digitalización de la compañía (IDIG)**.

5.3 Análisis jerárquico: el método de Ward.

En los **métodos jerárquicos aglomerativos**, se van formando sucesivamente grupos como agrupación de otros grupos precedentes, hasta llegar a un único grupo que recoge a todos los individuos; tomando el proceso una **estructura piramidal**. Estos métodos son especialmente adecuados cuando hay un número reducido de casos y se quieren clasificar **todos los casos** —incluidos los *outliers*—, así como cuando se desconoce a priori el número de grupos a formar.

Entre los métodos jerárquicos aglomerativos más extendidos figuran:

- **Vecino más cercano (single linkage):** distancia entre grupos = distancia entre sus elementos más próximos.
- **Vecino más lejano (complete linkage):** distancia entre grupos = distancia entre sus elementos más lejanos.
- **Método de Ward:** se unen los grupos que dan lugar a otro grupo con menor varianza intra-clúster (menor suma de cuadrados respecto al centroide).

En la práctica, el **método de Ward** es uno de los más utilizados porque proporciona grupos muy homogéneos. Será el que apliquemos al panel de 25 candidatas premium.

5.3.1 Preparación de los datos.

Vamos a suponer que trabajamos dentro de un **proyecto** que hemos creado previamente, de nombre **"cluster"**. Dentro de la carpeta del proyecto guardaremos el *script* "cluster_lite.R" y el archivo de Microsoft® Excel® "interestelar_25.xlsx", con diferentes variables económicas y financieras de las 25 empresas del panel.

Comenzaremos con los pasos habituales: limpiar el *Global Environment*, cargar `{MATlite}`, importar los datos y seleccionar las variables clasificadoras:

```
### CLUSTER jerárquico 25 empresas TMI.###

# Limpiando el Global Environment
rm(list = ls())

# Cargando el paquete de la asignatura
library(MATlite)

## DATOS
interestelar_25 <- lite_importa("interestelar_25.xlsx")

# Seleccionando las variables clasificadoras
seleccion <- interestelar_25 %>% select(IDIVERSE, IFIDE, IDIG)
lite_resumen(seleccion)
```

seleccion: 25 casos × 3 variables

Variable	Tipo	Categorías	Ausentes (%)	Media	Mediana	Desv. típica
IDIVERSE	Métrica		0.0	24.84	22.18	13.02
IFIDE	Métrica		0.0	39.79	39.59	6.58
IDIG	Métrica		0.0	19.39	15.15	13.06

Tabla 5.1

Para el diagnóstico de los *missing values* aplicamos la función `lite_na()`:

```
# Diagnóstico y filtrado de missing values.
seleccion <- lite_na(seleccion, accion = "eliminar")
```

No se ha localizado ninguna observación con *missing values* (la función lo indica con un mensaje en la consola), luego no se ha de realizar ningún tipo de tratamiento.

El siguiente paso es la **identificación de *outliers***. Como contamos con 3 variables métricas, `lite_outliers()` calculará la ***distancia de Mahalanobis*** de cada caso y le aplicará la regla de 1,5 veces el rango intercuartílico. En esta ocasión **no** indicamos `accion = "eliminar"`, porque no queremos eliminar los *outliers*, sino solo identificarlos:

```
# Diagnóstico de outliers (sin eliminarlos).
lite_outliers(seleccion,
              titulo    = "DISTANCIA DE MAHALANOBIS",
              subtitulo = "IDIVERSE, IFIDE, IDIG. Empresas TMI.")
```

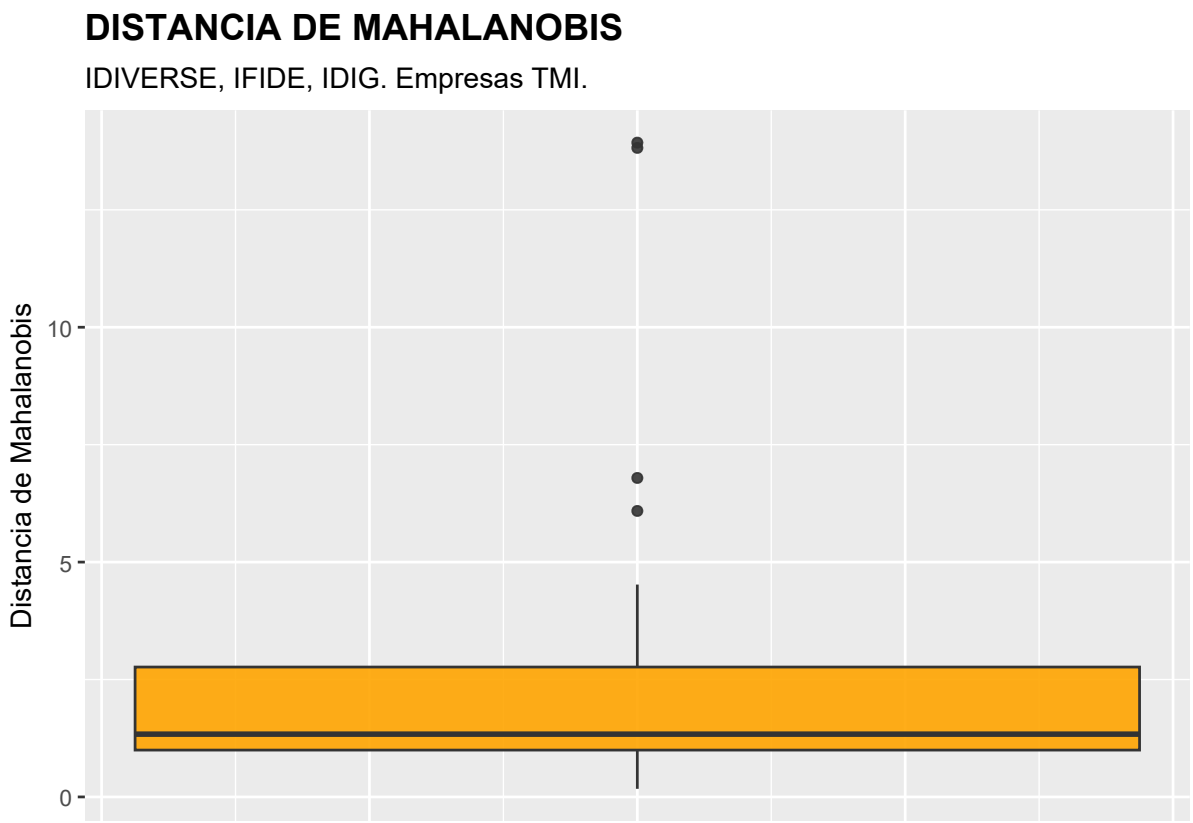


Figura 5.4

	MAHALANOBIS	IDIVERSE	IFIDE	IDIG
chakotay cargo systems	13.930441	54.36815	64.26013	42.719724
home one cargo	13.818423	22.17602	46.77635	60.832514
tannhäuser freight	6.791335	47.88846	42.64052	8.209292
io star transport	6.088895	38.02063	33.82858	35.117771

Tabla 5.2

De la tabla anterior se desprende que los *outliers* identificados son las empresas *Chakotay Cargo Systems*, *Home One Cargo*, y de modo más moderado, *Tannhäuser Freight* e *Io Star Transport*. Estos son, en definitiva, los 4 casos en los que nos fijaremos específicamente más adelante, al analizar los resultados del análisis clúster.

Estas empresas cuentan con un valor atípico en la distancia de Mahalanobis, lo que, a su vez, implica que muestren valores atípicos en una o varias de las variables originales (IDIVERSE, IFIDE, IDIG). En el desarrollo de otras técnicas, en este punto localizaríamos y eliminaríamos los *outliers*. En este caso **no** lo vamos a hacer, ya que queremos agrupar **todos los casos** que tenemos en el análisis. Precisamente, si hay algún caso que permanece aislado, sin agruparse con otros en el proceso de agrupación hasta las últimas etapas, quizá se trate de un candidato a *outlier*, por lo que el análisis clúster **también puede considerarse una técnica de localización de casos atípicos**.

5.3.2 El criterio del método de *Ward*.

Antes de aplicarlo, conviene detenerse en **cómo decide** el método de Ward qué grupos fusionar en cada etapa, porque es lo que explica que produzca conglomerados tan compactos.

En cada paso del proceso hay varias fusiones posibles. Ward las evalúa **todas** y se queda con la que da lugar al grupo resultante **más compacto**: aquel cuyos casos presentan la **menor suma de los cuadrados de sus distancias al centroide** del grupo. Dicho de otro modo, en cada etapa se escoge la unión que menos aumenta la varianza interna.

Veámoslo con un ejemplo mínimo. Supongamos que, en una etapa intermedia, el proceso ha formado ya **tres grupos** (A, B y C) y debe fusionar dos de ellos, dejando el tercero suelto. Hay, por tanto, tres opciones:

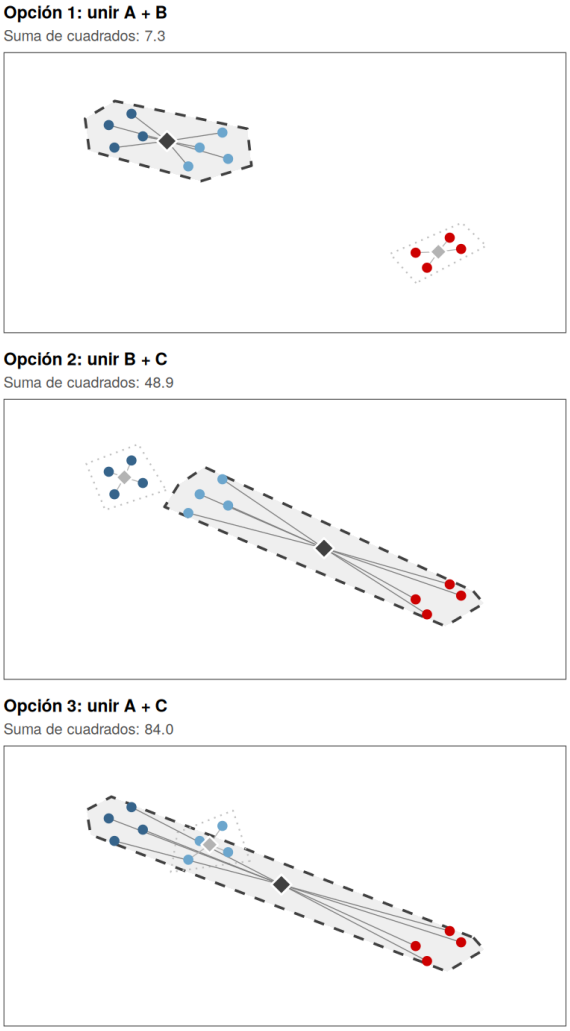


Figura 5.5. Criterio del método de Ward: las tres fusiones posibles de tres grupos previos y la suma de cuadrados de cada una. Se elige la de menor suma (opción 1).

En los tres paneles los **casos son los mismos y ocupan las mismas posiciones**; lo único que cambia es qué dos grupos quedan envueltos juntos por la línea discontinua. Los **rombos** son los centroides —el oscuro, el del grupo fusionado; el gris, el del grupo que queda aparte— y los radios finos unen cada caso con el centroide de su grupo: la suma de sus cuadrados es justamente la cifra del subtítulo.

El algoritmo elige la **Opción 1**, con diferencia la de menor suma. Y el resultado es intuitivo: A y B están próximos entre sí, de modo que fusionarlos produce un grupo apretado, mientras que arrastrar a C —que está lejos— a cualquiera de los otros dos generaría un conglomerado enorme y disperso.

5.3.3 Aplicación del método de *Ward*: exploración.

Todo el análisis se realiza con la función `lite_cluster_ward()`, en **dos fases**. En la primera, de **exploración**, la llamamos sin indicar el número de grupos. La función:

- **tipifica** las variables, ya que la distancia euclídea es sensible a sus unidades de medida;
- calcula la **matriz de distancias** entre los casos;
- aplica el **método de Ward** y dibuja el **dendrograma**;
- y sugiere un número de grupos mediante el **método de la silueta**, que explicaremos enseguida.

```
# Fase 1. Exploración
exploracion <- lite_cluster_ward(seleccion)
```

Veamos primero la matriz de distancias, representada como un *gráfico de temperatura*:

```
exploracion$distancias
```

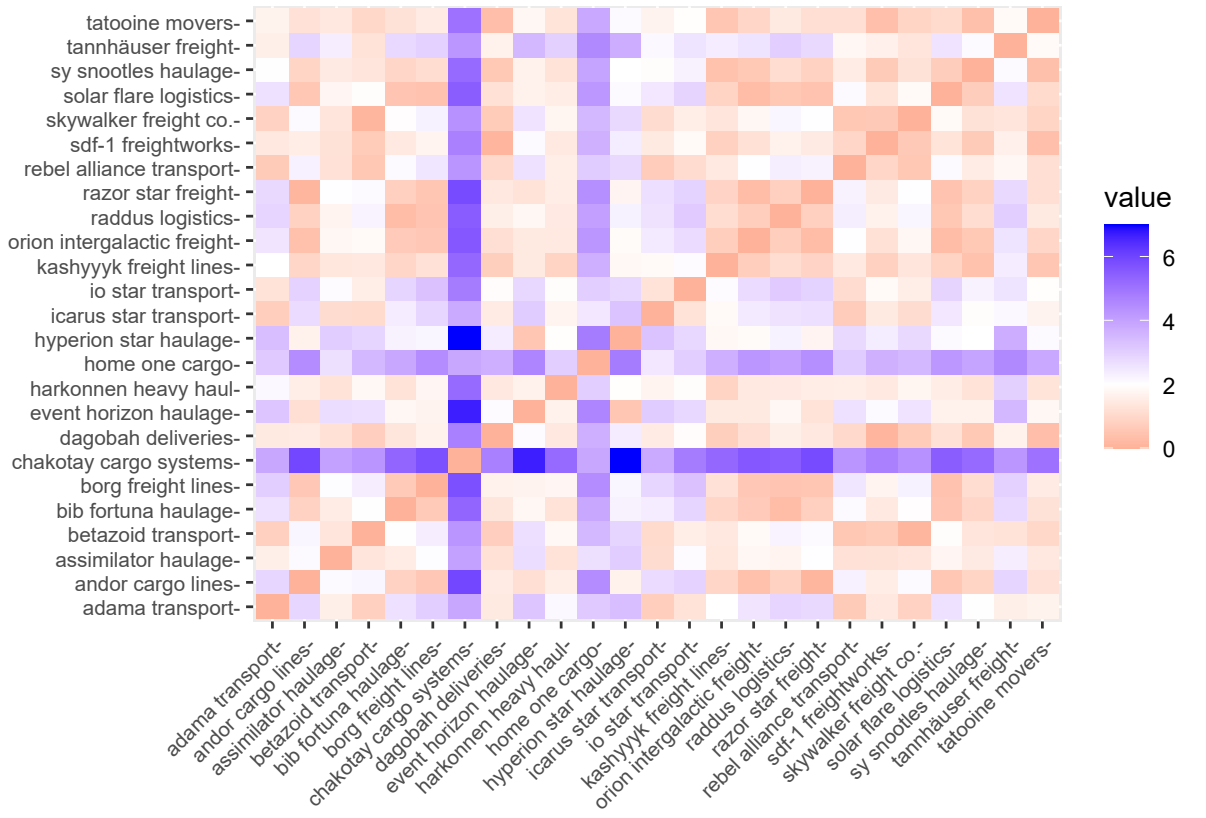


Figura 5.6

Los casos con intersecciones en tonos anaranjados tenderán a agruparse con mayor facilidad (o a agruparse antes); mientras que los casos cuyas intersecciones están en tonos azulados tenderán a pertenecer a grupos diferentes (o a agruparse más tarde). Cabe destacar los colores azulados asociados a las empresas *Chakotay Cargo Systems*, *Home One Cargo*, que precisamente eran las dos compañías identificadas más claramente como *outliers*.

El resultado del método de Ward se resume en el ***dendrograma***:

```
exploracion$dendrograma
```

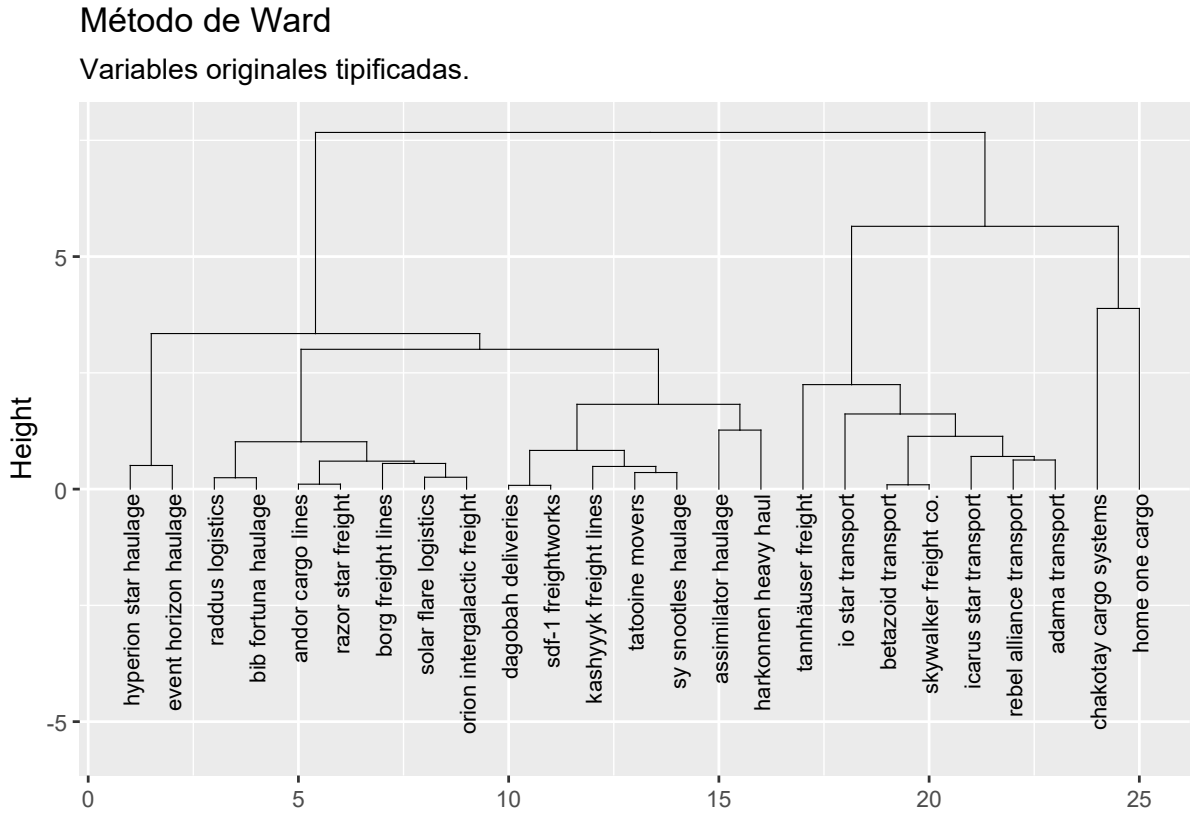


Figura 5.7

El eje vertical del *dendrograma* recoge las distancias entre casos y grupos que se van agrupando sucesivamente. En el método de Ward, esta escala refleja la suma de cuadrados de la distancia de los casos dentro del clúster.

Cabe observar que las empresas *Chakotay Cargo Systems* y *Home One Cargo* —los *outliers* identificados antes— permanecen sin agruparse hasta el final del proceso, lo que confirma su perfil diferenciado. En cambio, empresas como *Betazoid Transport* y *Skywalker Freight Co.* se unen muy pronto, indicando su gran similitud.

Una cuestión importante consiste en determinar con **cuántos grupos** hemos de quedarnos. Aunque existen algoritmos que aconsejan un número, a veces puede ser preferible que el propio investigador decida el número de grupos a crear, mediante la observación del dendrograma, y de acuerdo a los objetivos de su propia investigación.

Dentro de los métodos *objetivos*, uno muy extendido es el del *método de la anchura media de silueta*. Para cada observación i, la **anchura de la silueta** s_i se calcula como:

$$s_i = \frac{b_i - a_i}{\text{máx}(a_i, b_i)}$$

Donde:

- a_i es la distancia promedio de la observación i a todas las demás observaciones dentro de su propio clúster.
- b_i es la distancia promedio de la observación i al clúster más cercano.

Conviene visualizar estas dos distancias, porque de su comparación sale todo lo demás. En el ejemplo siguiente hay dos grupos, A (en azul) y B (en rojo), y se han destacado en negro **tres casos asignados al grupo A** de naturaleza muy distinta. Las líneas discontinuas azules son las distancias que promedia a_i; las rojas, las que promedia b_i:

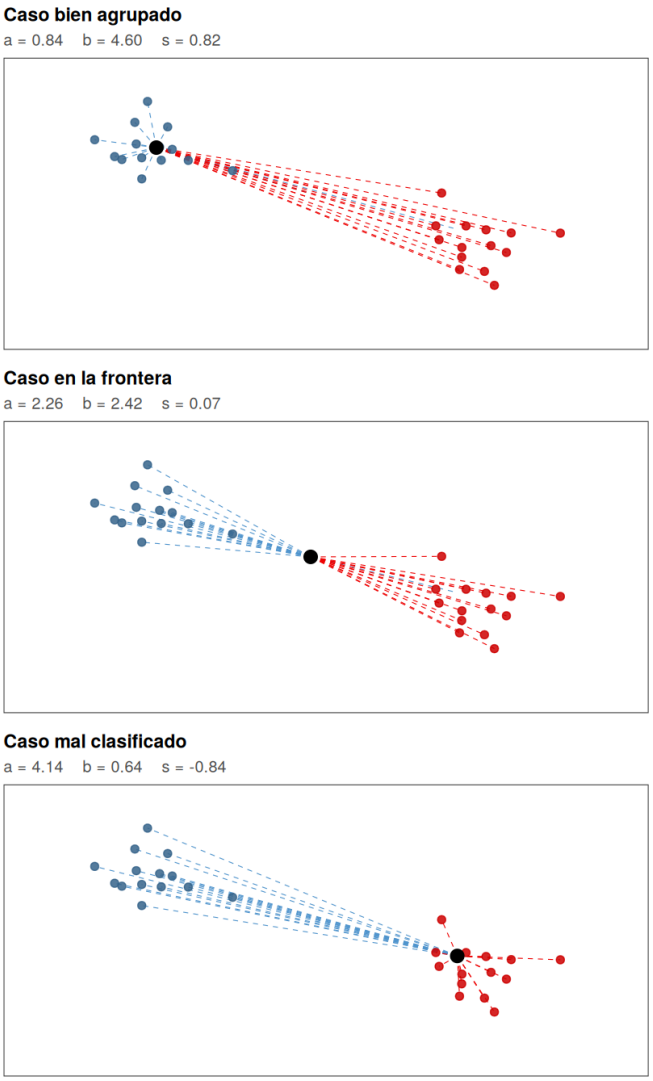


Figura 5.8. CÁLCULO DEL ANCHO DE SILUETA PARA TRES CASOS DE DISTINTA NATURALEZA: BIEN AGRUPADO, EN LA FRONTERA Y MAL CLASIFICADO.

La lectura de los tres paneles resume el significado del indicador:

- En el **primer caso**, a es pequeña y b es grande: el caso está rodeado de los suyos y lejos del grupo vecino. El numerador $b - a$ es casi tan grande como el propio b, de modo que s se aproxima a 1.
- En el **segundo**, a y b son prácticamente iguales: el caso está a medio camino entre los dos grupos y le resulta indiferente pertenecer a uno o a otro. El numerador se anula y s ronda el 0.
- En el **tercero**, b es mucho menor que a: el caso está de lleno dentro del grupo vecino, pese a haber sido asignado al propio. El numerador se vuelve negativo y s también.

La anchura de la silueta varía entre **-1 y 1.** Un valor cercano a 1 indica que la observación está bien agrupada dentro de su clúster; un valor cercano a 0 quiere decir que la observación está en el límite entre dos clústeres; y un valor negativo implica que la observación podría estar mal clasificada en su clúster actual. De este modo, para evaluar cuál es el mejor número de conglomerados a retener:

1. Se prueban diferentes valores de k (número de clústeres).
2. Se calcula el promedio de los valores de silueta para cada k.
3. Se selecciona el k que maximiza el **promedio de la silueta**, lo que indica que la partición es más adecuada.

De todos modos, es necesario insistir en que estos métodos no llevan a una conclusión única ni irrevocable; por lo que puede ser preferible que el **propio investigador** decida el número de grupos a crear, tomando los métodos cuantitativos solo como **orientación**. En nuestro caso, el gráfico del *método de la silueta* es:

```
exploracion$silueta
```

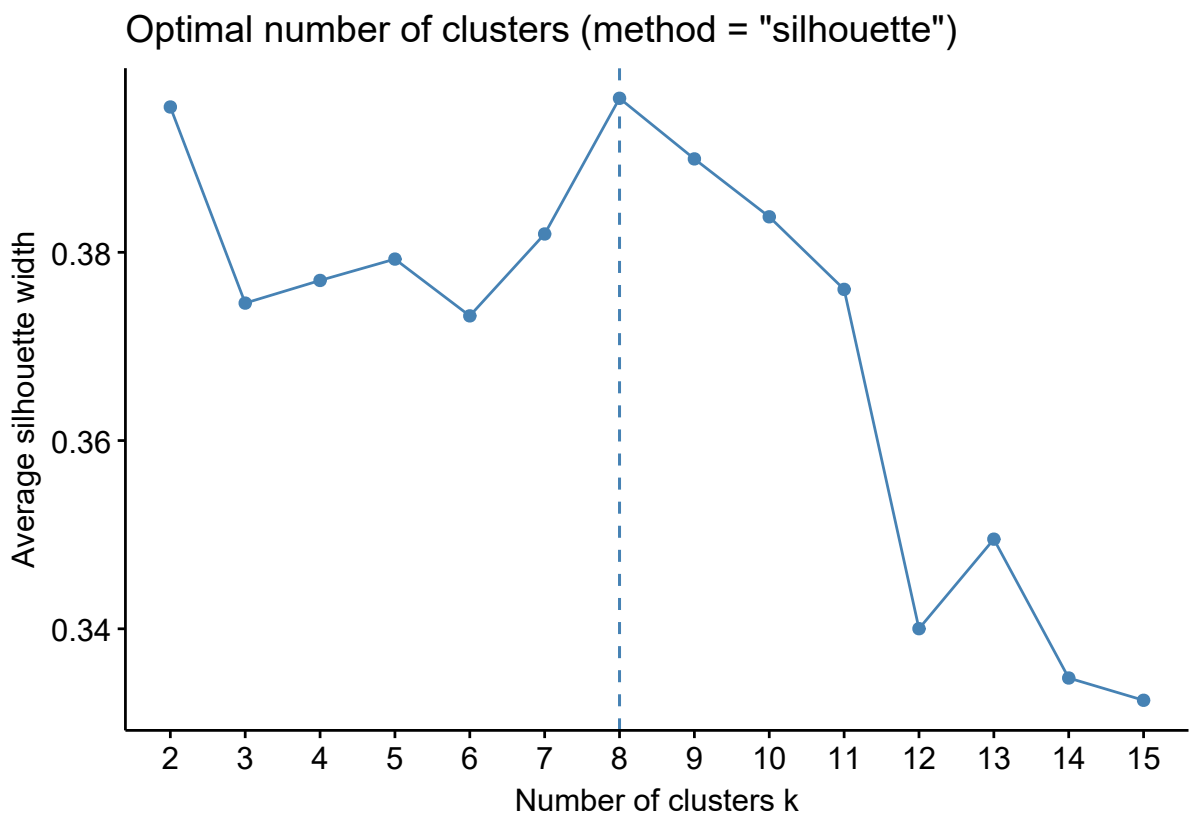


Figura 5.9

El método aconseja una división de los casos en 8 grupos o conglomerados diferentes (la función lo indica también con un mensaje en la consola). Sin embargo, parece un número excesivo si se quieren caracterizar posteriormente los grupos e incidir en sus diferencias. Un segundo número de grupos apropiado según el método es 2; pero podría ocurrir lo contrario que el caso anterior: sería un valor demasiado bajo, lo que provocaría que tan solo se distinguiese un grupo con los dos outliers de otro con los 23 casos restantes. Así, el investigador puede decidir qué número de grupos parece equilibrado y se ajusta a sus intereses. En este ejemplo, **un número de grupos razonable podría ser 5**, que contaría con el aval de mantener individualizadas a 2 de las empresas etiquetadas como *outliers*.

5.3.4 Aplicación del método de *Ward*: resultados.

Decidido el número de grupos, llamamos de nuevo a `lite_cluster_ward()`, indicándolo ahora con el argumento `k`:

```
# Fase 2. Resultados con el número de grupos decidido
grupos <- lite_cluster_ward(seleccion, k = 5, subtitulo_graficos = "Empresas TMI.")
```

El dendrograma muestra ahora los grupos formados:

```
grupos$dendrograma
```

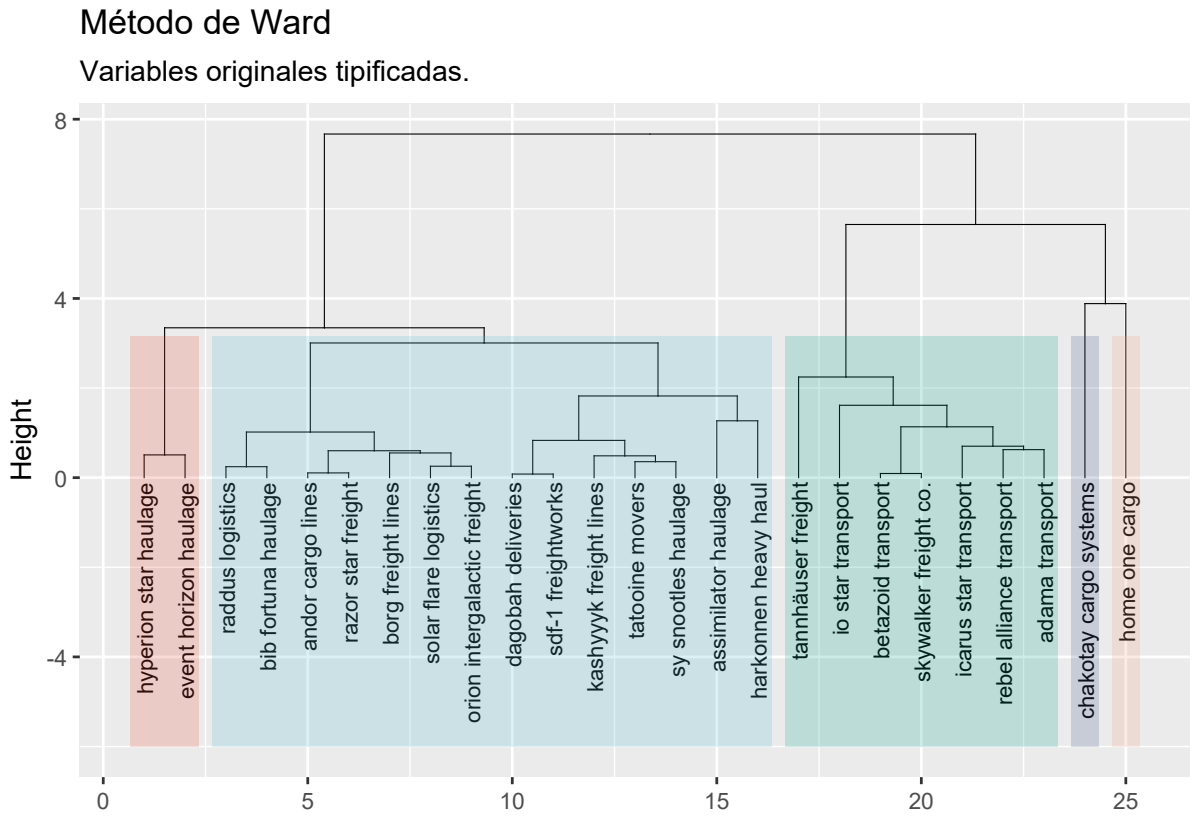


Figura 5.10

Del gráfico se pueden extraer varios conglomerados: dos empresas destacadas (*Hyperion Star Haulage* y *Event Horizon Haulage*) forman un grupo con perfil claramente diferenciado; un grupo central numeroso agrupa compañías con comportamientos homogéneos, que representan el segmento "medio" del sector; un tercer grupo reúne empresas ligeramente más avanzadas; y, finalmente, las dos empresas más singulares (*Chakotay Cargo Systems* y *Home One Cargo*), identificadas como *outliers* en el análisis previo, quedan aisladas cada una en su propio clúster.

Los grupos se numeran de izquierda a derecha, en el mismo orden en que aparecen en el dendrograma.

5.3.5 Caracterización de los grupos o conglomerados.

Para **caracterizar** los grupos, `lite_cluster_ward()` calcula el número de empresas de cada uno y las medias de cada variable original (sin tipificar), es decir, sus **centroides**:

```
grupos$centroides
```

Clúster	Observaciones	IDIVERSE	IFIDE	IDIG
1	2	10.877	28.039	13.206
2	14	17.945	39.253	13.301
3	7	38.788	39.712	24.083
4	1	54.368	64.260	42.720
5	1	22.176	46.776	60.833

Tabla 5.3

Las medias de cada variable se comparan también en gráficos de barras:

```
grupos$graficos_centroides
```

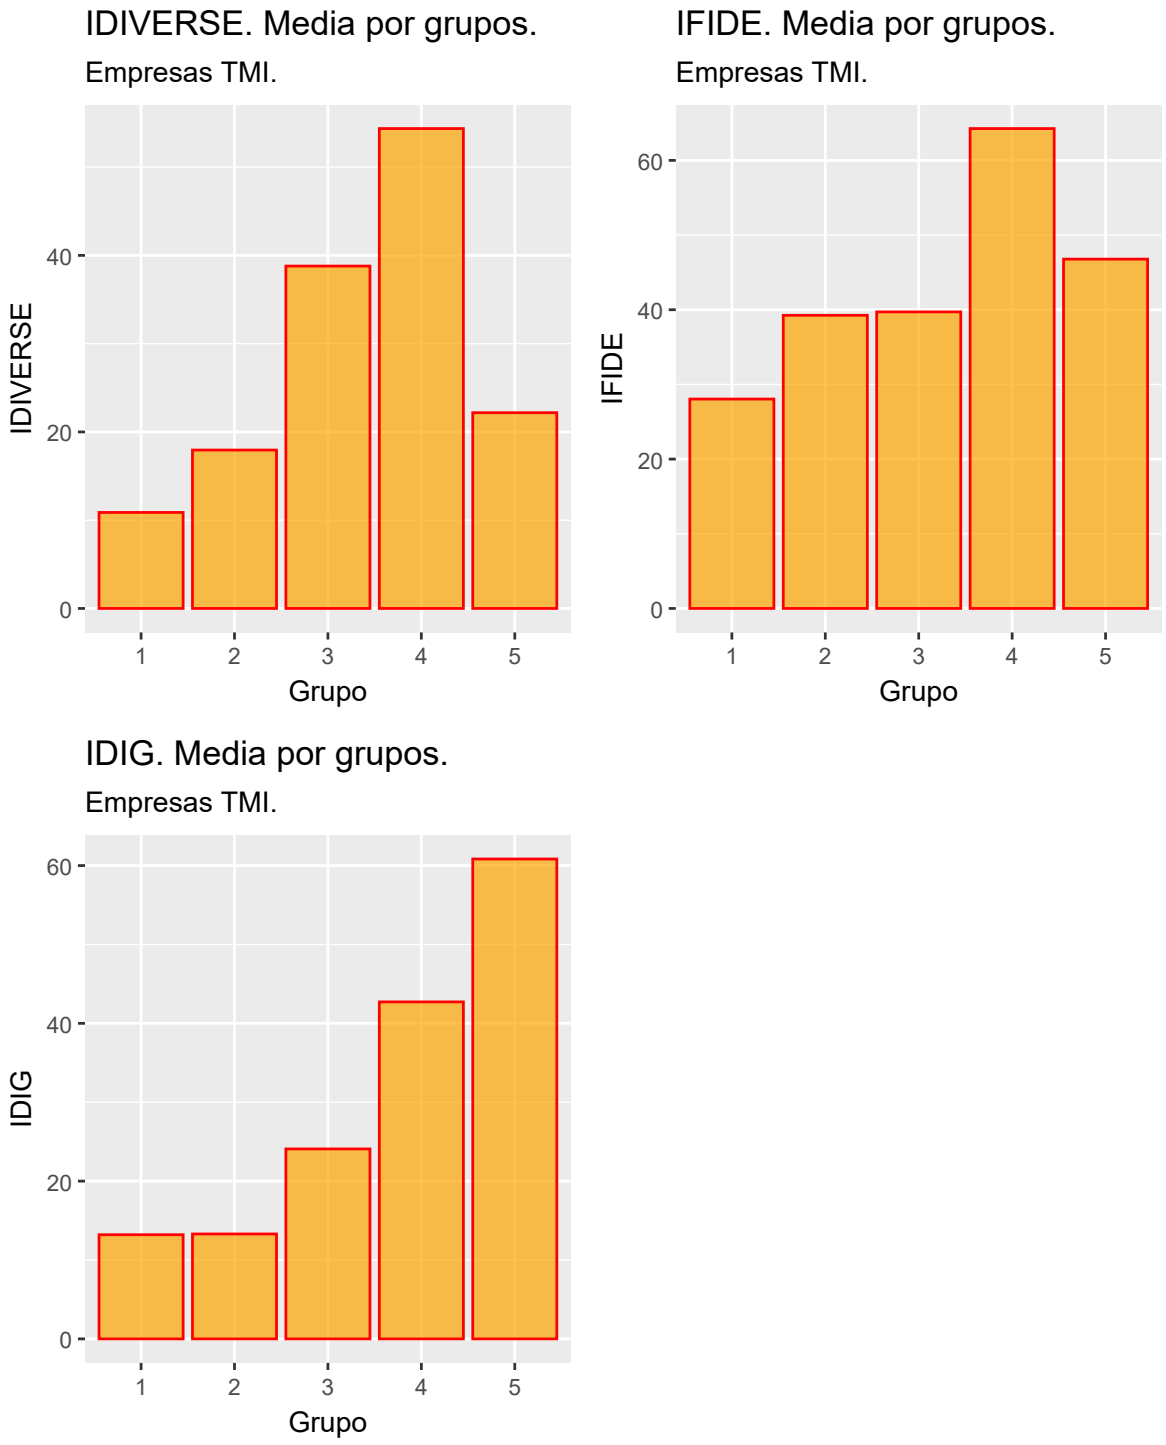


Figura 5.11

Hablando siempre en términos de la media (centroides), puede comprobarse cómo el grupo 4 (compañía *Chakotay Cargo Systems*) destaca por su alto valor en el índice de diversificación y en el Fidelización, quedando en segunda posición en el índice de digitalización. El otro grupo de una única compañía, el grupo 5, que contiene a la empresa *Home One Cargo*, destaca por poseer el mayor índice de digitalización. En adición, ocupa la segunda posición en el índice de fidelización. Por último, en cuanto al índice de diversificación, ocupa una posición media. En cuanto al grupo 3, en promedio es un conglomerado formado por empresas con índices de

fidelización y digitalización medios, mientras que en cuando a la diversificación ocupa una destacada segunda posición, solo por detrás del grupo 4. Por su parte, las empresas del grupo 2, en promedio, presentan un índice de fidelización medio, mientras que los índices de diversificación y digitalización son más bien bajos. Por último, el grupo 1, compuesto por las compañías *Hyperion Star Haulage* y *Event Horizon Haulage*, se caracteriza por mostrar los menores valores medios en los tres indicadores.

La **composición** de cada grupo, con los valores de sus empresas, está en la pieza `composicion`, que contiene una tabla por grupo. Escribiendo `grupos$composicion` las veríamos todas seguidas; para ver la de un grupo concreto, añadiremos su número entre dobles corchetes:

```
grupos$composicion[[1]]   # Grupo 1
```

	IDIVERSE	IFIDE	IDIG
hyperion star haulage	11.715	26.444	13.741
event horizon haulage	10.039	29.634	12.671

Tabla 5.4

```
grupos$composicion[[2]]   # Grupo 2
```

	IDIVERSE	IFIDE	IDIG
assimilator haulage	23.746	44.533	26.489
harkonnen heavy haul	15.384	37.327	26.764
raddus logistics	8.859	41.290	11.198
bib fortuna haulage	11.699	41.293	12.653
kashyyyk freight lines	20.016	37.426	16.311
solar flare logistics	14.649	39.952	7.764
dagobah deliveries	28.546	39.594	15.146
tatooine movers	26.202	38.074	14.075
orion intergalactic freight	15.535	38.370	8.449
andor cargo lines	12.282	36.643	7.138
sy snootles haulage	22.086	38.396	12.017
sdf-1 freightworks	29.387	39.361	15.577
borg freight lines	9.758	40.071	5.452
razor star freight	13.079	37.215	7.178

Tabla 5.5

```
grupos$composicion[[3]]   # Grupo 3
```

	IDIVERSE	IFIDE	IDIG
io star transport	38.021	33.829	35.118
icarus star transport	35.055	41.709	32.762
rebel alliance transport	35.200	39.025	26.189
adama transport	42.547	40.666	27.549
tannhäuser freight	47.888	42.641	8.209
betazoid transport	36.825	40.267	19.507
skywalker freight co.	35.983	39.847	19.243

Tabla 5.6

```
grupos$composicion[[4]]   # Grupo 4
```

	IDIVERSE	IFIDE	IDIG
chakotay cargo systems	54.368	64.26	42.72

Tabla 5.7

```
grupos$composicion[[5]]   # Grupo 5
```

	IDIVERSE	IFIDE	IDIG
home one cargo	22.176	46.776	60.833

Tabla 5.8

Para representar los grupos gráficamente, tenemos la dificultad de contar con más de dos variables clasificadoras. Una idea es dibujar los **gráficos de dispersión de todos los pares de variables**, con los casos coloreados de modo diferente según el grupo de pertenencia:

```
grupos$dispersion
```

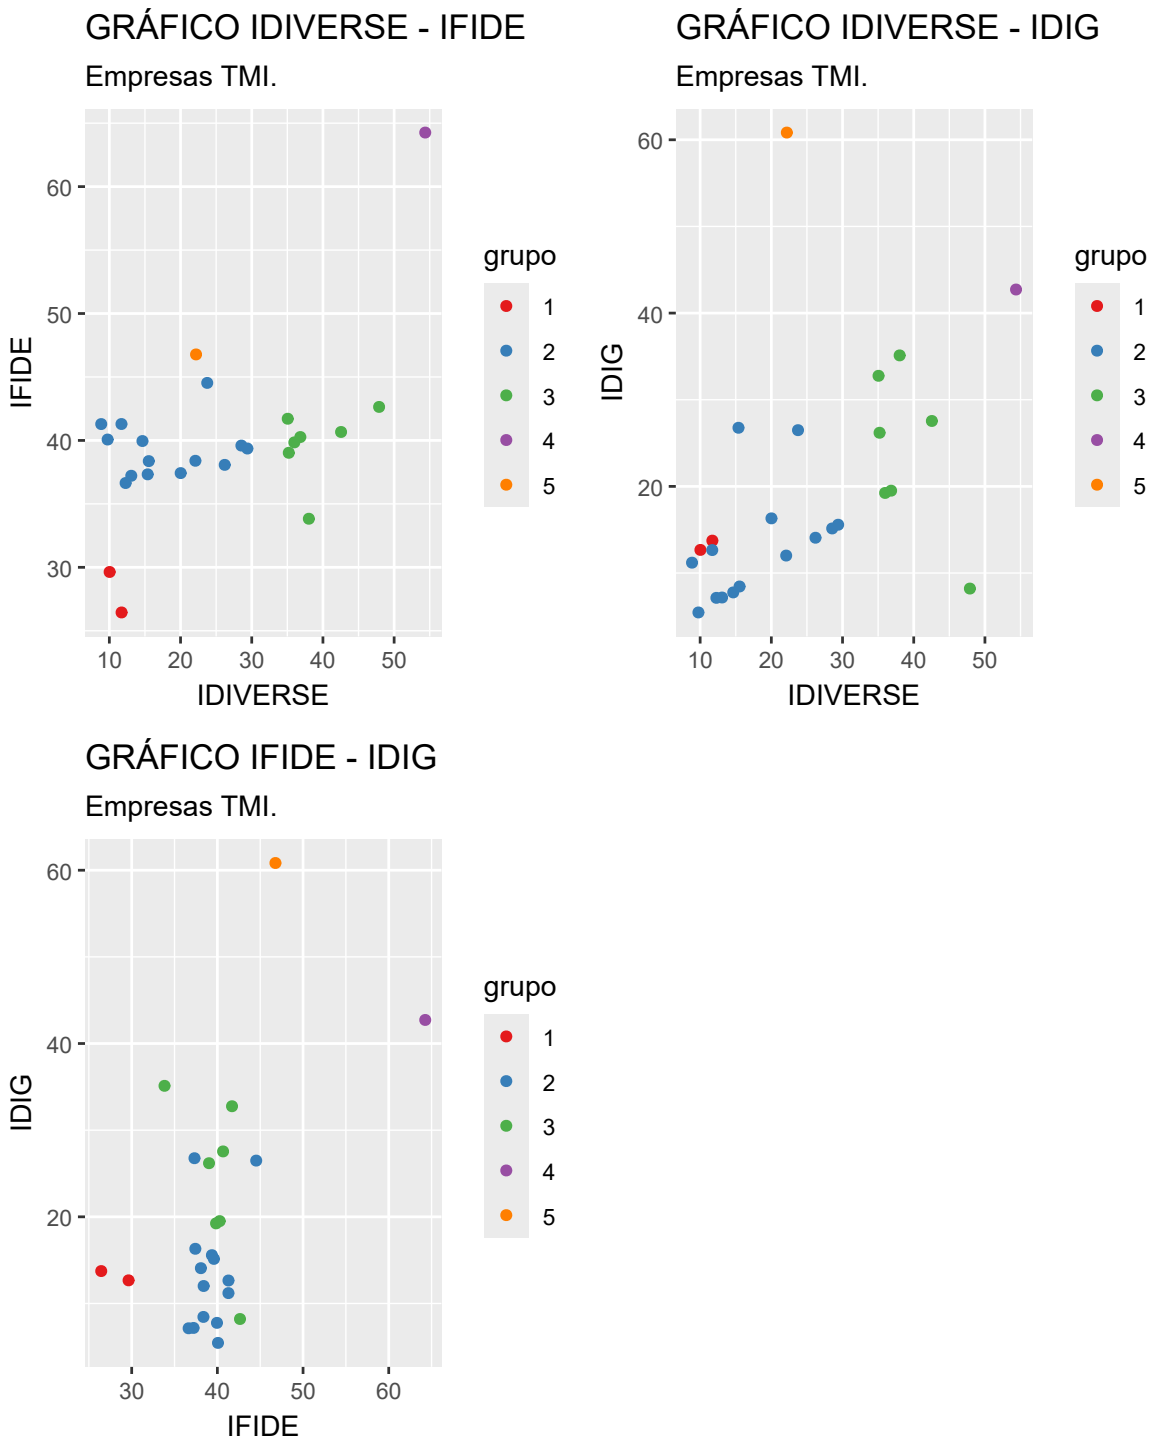


Figura 5.12

Los gráficos de dispersión ratifican los perfiles: los clústeres 1 y 2 se sitúan en la parte baja del eje de diversificación, con las empresas más tradicionales; el clúster 3 reúne a las compañías equilibradas y en fase de modernización; y los clústeres 4 (*Chakotay Cargo Systems*) y 5 (*Home One Cargo*), pese a formar cada uno una empresa aislada, muestran comportamientos muy distintos entre sí: la primera es una empresa muy diversificada y con alta fidelidad; la segunda destaca por su altísima digitalización. En cuanto a las relaciones entre las variables, se aprecia una correlación positiva leve entre diversificación y fidelidad, algo más marcada en los grupos

avanzados; la digitalización no siempre acompaña a la diversificación, salvo en los perfiles más maduros; y la fidelidad no depende directamente del grado de digitalización, sino que refleja otros factores como la calidad del servicio y la trayectoria de la empresa.

Por último, la pieza `datos` contiene el *data frame* original con una nueva columna, "grupo", que indica el conglomerado al que pertenece cada empresa. Podemos guardarlo para utilizarlo en análisis posteriores:

```
# Data frame con el grupo de cada empresa
seleccion_grupos <- grupos$datos
```

Cierre del Informe Bluebird. El panel de 25 candidatas premium queda encuadrado en cinco perfiles nítidos. *Home One Cargo* ha resultado ser una empresa singular: un perfil altamente digitalizado, pero de diversificación moderada. La AITM concluye que la reciente adquisición por parte de *Arg-us Korp* aporta al grupo del magnate una compañía de perfil tecnológicamente avanzado y especializado, que difícilmente hubiera podido encontrarse dentro del segmento medio del sector.

5.4 Materiales para realizar las prácticas del capítulo.

En esta sección se muestran los links de acceso a los diferentes materiales (*scripts*, datos...) necesarios para llevar a cabo los contenidos prácticos del capítulo.

Datos (en formato Microsoft® Excel®):

- interestelar_25.xlsx (obtener aquí), o bien, desde R: `lite_datos("interestelar_25")`.

Script:

- cluster_lite.R (obtener aquí)

CAPÍTULO 6

Modelos de elección discreta.



Figura 6.1. CONCEDIDA O DENEGADA: LA DECISIÓN COMO VARIABLE.

6.1 Introducción.

En muchas situaciones reales del entorno empresarial, la variable que deseamos explicar no es una magnitud continua (una rentabilidad, unas ventas, un beneficio), sino **categórica**: un banco concede o deniega un crédito, un consumidor compra o no un producto, una empresa pertenece a un sector u otro, un regulador otorga o rechaza una licencia. En todos estos casos, el resultado de la decisión es una **categoría**, no una cifra. La variable dependiente toma un número finito de valores discretos que representan las alternativas posibles, y lo que interesa modelizar es la **probabilidad de que un individuo o caso pertenezca a una u otra categoría** en función de un conjunto de variables explicativas.

La necesidad de interpretar económicamente estas pautas de comportamiento de los agentes económicos ha originado el desarrollo de la **modelización microeconométrica**. Los modelos microeconométricos ayudan a explicar las decisiones que los agentes del entorno de la empresa toman ante diferentes estímulos concretados en variables o atributos. En definitiva, intentan objetivar la toma de decisiones de los agentes económicos.

6.2 Clasificación de los modelos de elección discreta.

Los modelos de elección discreta constituyen una familia amplia de técnicas que se clasifican según las características de la variable dependiente:

- **Modelos de respuesta binaria:** la variable dependiente presenta solo dos alternativas, codificadas como 0 y 1. Por ejemplo: conceder o no un crédito, comprar o no un producto, obtener o no una licencia. Son los modelos más sencillos y frecuentes.
- **Modelos de respuesta múltiple:** la variable dependiente admite más de dos categorías. A su vez, se subdividen en:
  - *Multinomiales:* las categorías no tienen un orden natural (por ejemplo, elegir entre tres marcas).
  - *Ordenados:* las categorías responden a una escala ordinal (por ejemplo, grado de satisfacción: bajo, medio, alto).

En este capítulo nos centraremos en los **modelos de respuesta binaria** y, dentro de ellos, en el **modelo logit binomial**, que es el más utilizado en la práctica por la facilidad de su especificación, estimación e interpretación.

6.3 El modelo de respuesta binaria.

6.3.1 Planteamiento general.

Supongamos una variable dependiente categórica Y que puede tomar valores 0 ó 1, y un conjunto de k variables explicativas $X_1, X_2, \dots, X_k$. El objetivo es determinar:

$$P[Y = 1 \,/\, X_1, X_2, \dots, X_k]$$

Es decir, la probabilidad de que la variable dependiente tome el valor 1 (pertenencia al grupo de interés) condicionada a los valores de las variables explicativas. Naturalmente, $P[Y = 0 \,/\, X_1, \dots, X_k] = 1 - P[Y = 1 \,/\, X_1, \dots, X_k]$.

Para relacionar la probabilidad con el valor de las variables explicativas, construimos una **función de enlace** que incorpora una función de distribución de probabilidad subyacente:

$$P[Y = 1 \,/\, X_1, X_2, \dots, X_k] = f(X_1, X_2, \dots, X_k; \beta)$$

donde β es el vector de los k parámetros estructurales del modelo. En la función de enlace supondremos que las variables independientes actúan siguiendo un esquema lineal:

$$f(X_1, X_2, \dots, X_k; \beta) = f(X_1\beta_1 + X_2\beta_2 + \cdots + X_k\beta_k)$$

y el modelo a estimar será:

$$y = f(X_1\beta_1 + X_2\beta_2 + \cdots + X_k\beta_k) + \varepsilon$$

donde y es la variable dependiente (0 ó 1) y ε es la perturbación aleatoria.

6.3.2 La función de enlace: logit y probit.

La forma funcional concreta de la función de enlace depende de la distribución de probabilidad que asumamos para el comportamiento de la variable Y. Aunque la verdadera naturaleza de Y es discreta, asumimos para ella una distribución de probabilidad continua:

- **Modelo logit:** suponemos que la variable dependiente sigue una distribución de probabilidad que se ajusta a una **curva logística**.
- **Modelo probit:** suponemos que la variable dependiente sigue una distribución de probabilidad que se ajusta a una **distribución normal**.

En general, ambos modelos aportan soluciones similares en la mayoría de los casos. A nivel práctico, suelen utilizarse más los modelos logit, al ser menos dificultosa su especificación e interpretación de resultados. Por ello, el resto del capítulo se centrará en el modelo logit.

6.4 El modelo logit binomial.

6.4.1 Especificación.

En el modelo logit binomial, la función de enlace adopta la forma de la **función logística**:

$$y_i = \frac{1}{1 + e^{-(\alpha + x_i\beta)}} + \varepsilon_i$$

Bajo las hipótesis básicas habituales (el error sigue una distribución normal de media cero, tiene varianza constante y no está autocorrelacionado), la probabilidad de que la variable dependiente tome el valor 1 viene dada por:

$$P(y_i = 1 \,/\, x_i) = E(Y) = \frac{1}{1 + e^{-(\alpha + x_i\beta)}}$$

y la probabilidad estimada, una vez obtenidos los parámetros del modelo, será:

$$\hat{P}(y_i = 1 \,/\, x_i) = \frac{1}{1 + e^{-(\hat{\alpha} + x_i\hat{\beta})}}$$

Los parámetros se estiman mediante el método de **máxima verosimilitud**, a diferencia de la regresión lineal, donde se emplea mínimos cuadrados ordinarios (MCO).

6.4.2 Contraste de significación individual: contraste de Wald.

Para contrastar si un parámetro individual es significativamente distinto de cero, se utiliza el **contraste de Wald**, que desempeña en el modelo logit un papel análogo al del contraste *t* en la regresión lineal. La hipótesis nula es $H_0 : \beta_j = 0$, y el estadístico de contraste es:

$$z = \frac{\hat{\beta}_j}{\text{SE}(\hat{\beta}_j)}$$

que, bajo H_0, sigue una distribución normal estándar. Si el p-valor asociado es inferior al nivel de significación elegido (por ejemplo, 0,05), se rechaza H_0 y se concluye que la variable es estadísticamente significativa.

Cuando una variable explicativa es un **factor con más de dos niveles** (por ejemplo, EFLO con tres categorías: ANTIGUA, MADURA, RENOVADA), el modelo genera varias variables *dummy*. Es posible que ninguna de ellas sea individualmente significativa, pero que el factor en su conjunto sí lo sea. Para comprobarlo, se aplica el **contraste de Wald conjunto**, que evalúa simultáneamente la hipótesis $H_0 : \beta_{\text{MADURA}} = \beta_{\text{RENOVADA}} = 0$.

6.4.3 Medidas de la bondad del ajuste.

La evaluación de la calidad de un modelo logit difiere de la regresión lineal. No existe un R^2 clásico, pero sí varios indicadores alternativos:

- **Porcentaje de predicciones correctas:** se compara la clasificación predicha por el modelo (asignando al grupo 1 los casos con probabilidad estimada superior a 0,5) con la pertenencia real. Es una medida intuitiva, pero puede ser engañosa cuando los grupos están muy desbalanceados.
- **Pseudo** R^2 de Nagelkerke: es una adaptación del coeficiente de determinación para modelos estimados por máxima verosimilitud. Se calcula a partir de las log-verosimilitudes del modelo completo (L_1) y del modelo nulo (L_0):

$$R^2_{\text{Nagelkerke}} = \frac{1 - \exp\left(-\frac{2}{n}(L_1 - L_0)\right)}{1 - \exp\left(\frac{2}{n} L_0\right)}$$

Sus valores oscilan entre 0 y 1, y se interpreta de forma análoga al R^2: valores más altos indican mejor ajuste.

- **Criterio de información de Akaike (AIC):** permite comparar modelos con distinto número de variables. Cuanto menor sea el AIC, mejor es la especificación del modelo.
- **Comparación de la devianza:** la devianza mide la discrepancia entre el modelo estimado y un modelo saturado. La diferencia entre la devianza del modelo nulo y la del modelo completo se distribuye como una χ^2 y permite contrastar la significación conjunta del modelo.

6.4.4 *Odd ratios*: interpretación económica de los coeficientes.

En la regresión lineal, cada coeficiente indica directamente cuánto varía la variable dependiente cuando la explicativa se incrementa en una unidad. En el modelo logit, la interpretación no es tan directa, porque la relación entre las variables explicativas y la probabilidad no es lineal. Sin embargo, existe una transformación que facilita enormemente la lectura: el ***odd ratio***.

El *odd* (o *ventaja*) del suceso $Y = 1$ frente al suceso $Y = 0$ se define como el cociente entre sus probabilidades:

$$\frac{P(y_i = 1)}{P(y_i = 0)} = e^{\alpha + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_k x_{ik}}$$

Cuando una variable x_k se incrementa en una unidad (manteniendo las demás constantes), la nueva ventaja se divide por la antigua, obteniéndose:

$$\frac{\text{Ventaja nueva}}{\text{Ventaja antigua}} = e^{\beta_k}$$

El valor e^{β_k} se denomina ***odd ratio*** de la variable x_k, y es el **factor por el que se multiplica la ventaja** cuando la variable se incrementa en una unidad:

- Si $\beta_k > 0$ (parámetro positivo), entonces $e^{\beta_k} > 1$: la ventaja **aumenta** cuando aumenta la variable.
- Si $\beta_k < 0$ (parámetro negativo), entonces $e^{\beta_k} < 1$: la ventaja **disminuye** cuando aumenta la variable.

El cambio porcentual en la ventaja se calcula como $(e^{\beta_k} - 1) \times 100\,\%$.

6.5 Práctica: ¿qué determina la concesión de licencias en el sector interestelar?

6.5.1 La ruta Coruscant–Arrakis.

La ruta comercial entre los planetas *Coruscant* (en la Galaxia de Andrómeda) y *Arrakis* (en la Gran Nube de Magallanes) se ha consolidado en los últimos años como una de las más rentables del sector del transporte interestelar de mercancías. La expansión del tráfico comercial entre ambos planetas —impulsada por el crecimiento de la demanda de *especia* y componentes tecnológicos— ha atraído el interés de numerosas compañías navieras.

La **Autoridad Galáctica de Transporte Interestelar (AGTI)**, organismo regulador del sector, gestiona la concesión de licencias de operación para esta ruta. De las 100 compañías que solicitaron operar en la ruta Coruscant–Arrakis, la AGTI concedió la licencia a **40** y la denegó a **60**, basándose en una evaluación de múltiples indicadores financieros, operativos y de calidad de servicio.

Ante la previsión de que se convoque un nuevo concurso de licencias para atender la creciente demanda, un equipo de analistas de la consultora *Data-Evidence*, bajo la supervisión de su directora ejecutiva, **Li Ti-Oh**, ha decidido construir un **modelo logit binomial** que permita identificar qué factores determinan la concesión o denegación de la licencia. Este modelo será útil tanto para las compañías que deseen evaluar sus posibilidades como para la propia AGTI como herramienta de apoyo a la decisión.

6.5.2 Preparación de los datos.

Para llevar a cabo la práctica, necesitamos en la carpeta de nuestro proyecto el archivo de datos **licencias_100.xlsx**, con los datos de las 100 compañías solicitantes; el archivo **escenarios_logit_rstars.xlsx**, que utilizaremos para la simulación de escenarios; y el *script* **logit_lite.R**, con el código que iremos ejecutando paso a paso.

Como es habitual, comenzamos limpiando la memoria, cargando `{MATlite}` e importando los datos:

```
# Limpiando el Global Environment
rm(list = ls())

# Cargando el paquete de la asignatura
library(MATlite)

# Importando datos desde Excel
LICENCIAS <- lite_importa("licencias_100.xlsx")
lite_resumen(LICENCIAS)
```

LICENCIAS: 100 casos × 11 variables

Variable	Tipo	Categorías	Ausentes (%)	Media	Mediana	Desv. típica
SEDE	Categórica	30	0.0			
GALAXIA	Categórica	5	0.0			
EFLO	Categórica	3	0.0			
SOLVENCIA	Métrica		0.0	183.71	180.73	30.32
FLOTA	Métrica		0.0	24.21	22.00	13.01
RUTAS	Métrica		0.0	398.42	361.00	257.36
IFIDE	Métrica		0.0	39.41	39.57	7.36
IPUNT	Métrica		0.0	60.69	59.48	12.64
TINCID	Métrica		0.0	7.90	8.22	3.43
EXPERIENCIA	Métrica		0.0	9.58	10.00	4.80
LICENCIA	Métrica		0.0	0.40	0.00	0.49

Tabla 6.1

6.5.3 Detección de valores perdidos.

Como paso previo a cualquier análisis, comprobamos la presencia de valores perdidos (*missing values*):

```
LICENCIAS <- lite_na(LICENCIAS, accion = "eliminar",
                     titulo    = "Modelo logit binomial.",
                     subtitulo = "Licencias de operación - Ruta Coruscant-Arrakis")
```

La función confirma, con un mensaje en la consola, que la base de datos está completa: no se detectan valores perdidos en ninguna de las 100 observaciones. No obstante, al haber utilizado `accion = "eliminar"`, si se hubieran detectado casos con `NA`, habrían quedado automáticamente excluidos del *data frame* de trabajo.

6.5.4 Conversión de variables categóricas.

Una vez confirmada la integridad de los datos, es imprescindible convertir las variables categóricas en **factores** (recordemos el capítulo 2). La variable EFLO (estado de la flota) tiene tres niveles, y fijamos como nivel de referencia la categoría ANTIGUA, de modo que los coeficientes de MADURA y RENOVADA indicarán la mejora respecto a ese nivel base. La variable LICENCIA es la variable dependiente binaria (0 = denegada, 1 = concedida). La función `lite_factor()` realiza la conversión; con el argumento `niveles` indicamos el orden de las categorías, y la primera actúa como referencia:

```
# Conversión de variables categóricas a factor
LICENCIAS <- lite_factor(LICENCIAS, EFLO, niveles = c("ANTIGUA", "MADURA", "RENOVADA"))
```

```
## Codificación (contrastes) de EFLO:
##          MADURA RENOVADA
## ANTIGUA       0        0
## MADURA        1        0
## RENOVADA      0        1
```

```
LICENCIAS <- lite_factor(LICENCIAS, LICENCIA)
```

```
## Codificación (contrastes) de LICENCIA:
##   1
## 0 0
## 1 1
```

La función muestra la codificación de las variables *dummy* (los *contrastes*): para EFLO, la categoría ANTIGUA es la referencia (la fila de ceros), y se crean dos indicadores para MADURA y RENOVADA. Para LICENCIA, el valor 0 es la referencia y el valor 1 el evento de interés.

6.5.5 Análisis descriptivo previo.

Antes de estimar el modelo, conviene examinar las diferencias descriptivas entre los dos grupos (licencia concedida vs. denegada). Esto nos permitirá anticipar qué variables podrían ser relevantes. Todo ello lo hace la función `lite_logit_descriptivo()`, a la que indicamos la variable dependiente y, si queremos, unas etiquetas para sus dos categorías:

```
# Análisis descriptivo previo
descriptivo <- lite_logit_descriptivo(LICENCIAS, LICENCIA,
                                      etiquetas = c("0" = "Denegada", "1" = "Concedida"))
```

La función analiza todas las variables del *data frame* salvo las categóricas con demasiadas categorías, como SEDE, el planeta de la sede (avisa de ello en la consola). Comenzamos con la distribución de la variable dependiente:

```
descriptivo$dependiente
```

LICENCIA	Frecuencia	Porcentaje
0	60	60
1	40	40

Tabla 6.2

Para las variables categóricas, obtenemos una tabla cruzada con la dependiente. La de EFLO es:

```
descriptivo$cruzadas$EFLO
```

	0	1	% Concedida
ANTIGUA	15	5	25.00
MADURA	31	14	31.11
RENOVADA	14	21	60.00

Tabla 6.3

La tabla cruzada revela un patrón sugerente: entre las compañías con flota RENOVADA, el 60 % obtuvieron la licencia, frente al 31 % de las MADURA y el 25 % de las ANTIGUA. Esto sugiere que el estado de la flota podría ser un factor relevante, aunque habrá que confirmar si este efecto se mantiene tras controlar por las demás variables.

Visualizamos la relación entre las variables categóricas (EFLO y GALAXIA) y la concesión de la licencia mediante gráficos de barras apiladas porcentuales, que muestran la proporción de concesión y denegación dentro de cada categoría:

```
descriptivo$graficos_categoricas
```

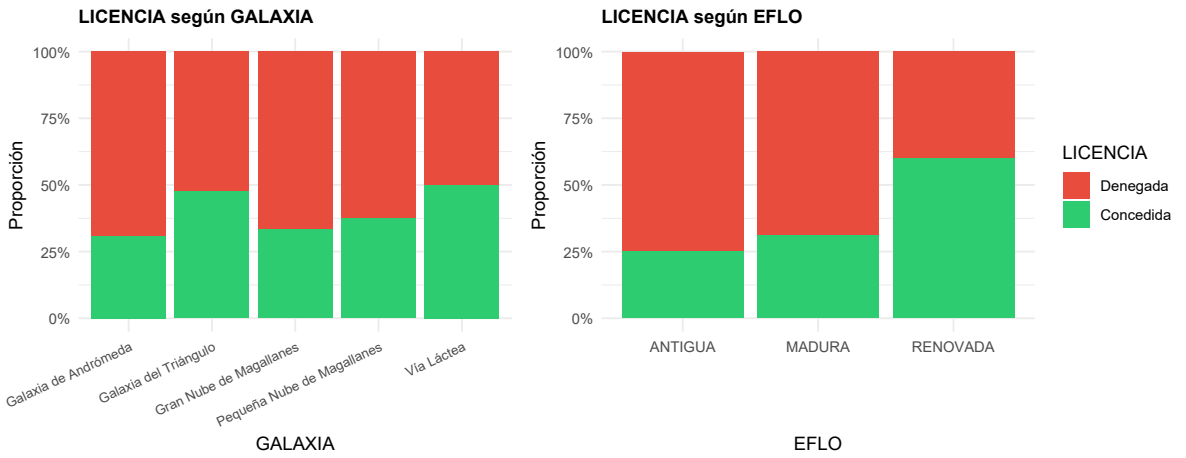


Figura 6.2

El gráfico de EFLO confirma visualmente la asociación ya detectada en la tabla cruzada: la proporción de licencias concedidas crece de forma clara al pasar de flotas antiguas a renovadas. En cuanto a GALAXIA, las diferencias son menos marcadas, lo que anticipa que la galaxia de operación probablemente no será una variable determinante en el modelo.

Veamos ahora las medias de las variables métricas en cada grupo, tanto en formato tabla como en formato gráfico:

```
descriptivo$medias
```

LICENCIA	SOLVENCIA	FLOTA	RUTAS	IFIDE	IPUNT	TINCID	EXPERIENCIA
0	176.63	23.42	341.1	37.54	58.15	8.96	8.48
1	194.33	25.40	484.4	42.21	64.49	6.29	11.22

Tabla 6.4

Los gráficos de medias se reparten en dos paneles; la pieza `graficos_metricas` es una lista, y mostramos cada elemento por separado:

```
descriptivo$graficos_metricas[[1]]
```

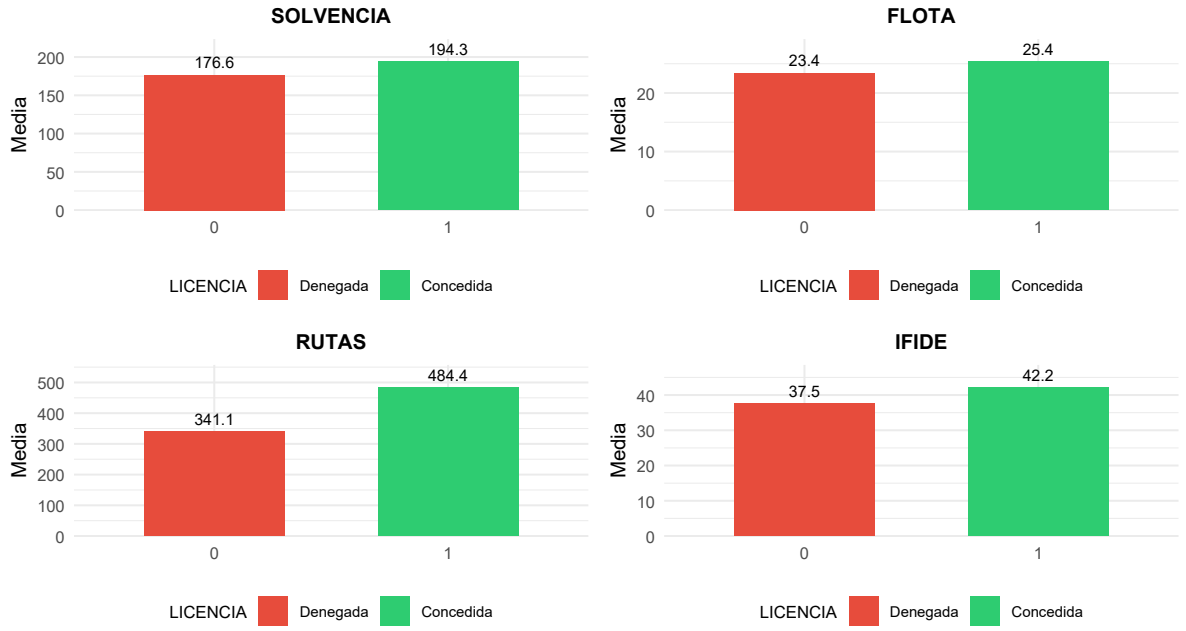


Figura 6.3

```
descriptivo$graficos_metricas[[2]]
```

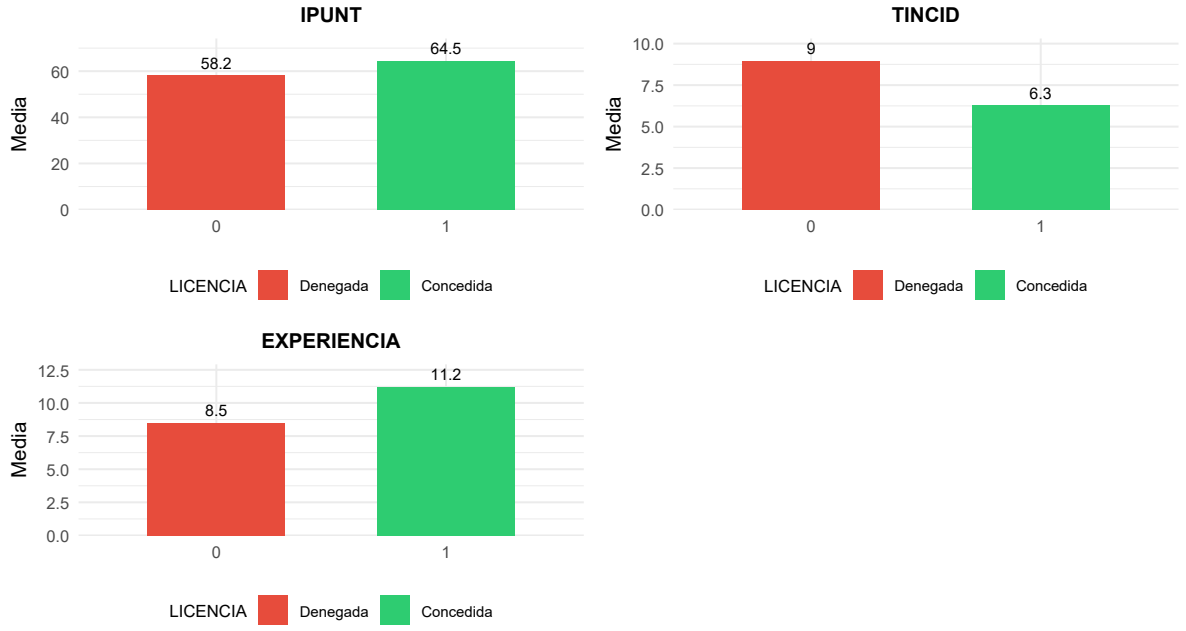


Figura 6.4

Los gráficos permiten apreciar de un vistazo las diferencias entre los dos grupos. Las variables que muestran contrastes más acusados son IPUNT (puntualidad), TINCID (tasa de incidencias) y, en menor medida, SOLVENCIA: las compañías que obtuvieron la licencia son, en promedio, más puntuales, registran muchas menos incidencias y tienen mayor solvencia financiera.

RUTAS y EXPERIENCIA también presentan diferencias apreciables. En cambio, FLOTA muestra medias muy similares en ambos grupos, lo que anticipa que probablemente no será una variable significativa en el modelo.

6.5.6 Partición en muestra de estimación y muestra de test.

Para evaluar la capacidad predictiva del modelo sobre datos no vistos, dividimos la muestra en dos subconjuntos: una **muestra de estimación** (80 observaciones) con la que se ajustarán los parámetros del modelo, y una **muestra de test** (20 observaciones) que se reserva exclusivamente para la validación. La función `lite_particion()` toma los 80 primeros casos para estimar y deja el resto para el test:

```
muestras <- lite_particion(LICENCIAS, n_estimacion = 80, dependiente = LICENCIA)
```

```
muestras$resumen
```

Muestra	Casos	LICENCIA = 0	LICENCIA = 1
Estimación	80	52	28
Test	20	8	12

Tabla 6.5

Las dos muestras quedan guardadas en `muestras$estimacion` y `muestras$test`. Si quisiéramos que los casos de cada muestra se eligieran al azar, bastaría con añadir el argumento `aleatoria = TRUE`.

6.5.7 Estimación del modelo logit completo.

Con los datos preparados, estimamos el modelo logit binomial completo con la función `lite_logit()`. Le indicamos la muestra de estimación, la variable dependiente, las variables explicativas y, para evaluar después su capacidad predictiva, la muestra de test:

```
completo <- lite_logit(muestras$estimacion, LICENCIA,
                       explicativas = c(SOLVENCIA, IPUNT, TINCID, IFIDE,
                                        FLOTA, RUTAS, EXPERIENCIA, EFLO),
                       test = muestras$test)
```

```
## Modelo estimado: LICENCIA ~ SOLVENCIA + IPUNT + TINCID + IFIDE + FLOTA + RUTAS +
 ↪  EXPERIENCIA + EFLO
## Probabilidad modelizada: P(LICENCIA = 1).  Casos de estimación: 80.  Casos de test:
 ↪  20.
```

La función nos informa de la **especificación** del modelo que ha estimado, escrita en la notación habitual de R: la variable dependiente, el símbolo ~ (que se lee "en función de") y las variables

explicativas separadas por +. Nos recuerda, además, que la probabilidad que se modeliza es la de LICENCIA = 1, es decir, la de obtener la licencia.

La primera tabla recoge los **coeficientes** estimados, sus errores estándar, el estadístico z del contraste de Wald individual y los p-valores:

```
completo$coeficientes
```

Variable	Coeficiente	Desv. Típica	Estadístico z	p-valor	Sig.
(Intercept)	-10.20972	3.4299	-2.9767	0.0029	**
SOLVENCIA	0.02173	0.0114	1.9098	0.0562	·
IPUNT	0.06541	0.0274	2.3841	0.0171	*
TINCID	-0.27346	0.1018	-2.6865	0.0072	**
IFIDE	0.07260	0.0720	1.0081	0.3134	
FLOTA	-0.01848	0.0311	-0.5951	0.5518	
RUTAS	0.00182	0.0021	0.8624	0.3885	
EXPERIENCIA	0.05001	0.1004	0.4981	0.6184	
EFLOMADURA	-0.03347	0.9748	-0.0343	0.9726	
EFLORENOVADA	0.28391	1.1437	0.2482	0.8040	

Tabla 6.6

6.5.8 Interpretación de los resultados.

A nivel individual, el contraste de Wald revela que **dos variables son estadísticamente significativas al 5 %**, y una tercera lo es al 10 %:

1. **TINCID** (tasa de incidencias): es la variable más significativa del modelo. Su coeficiente es negativo, lo que indica que cuanto mayor es la tasa de incidencias de una compañía, menor es su probabilidad de obtener la licencia. Cada incidencia adicional por cada 1.000 años-luz reduce sustancialmente la ventaja (*odds*) de la concesión.
2. **IPUNT** (índice de puntualidad): su coeficiente positivo indica que la puntualidad favorece la concesión. Cada punto adicional en el índice de puntualidad aumenta la ventaja de obtener la licencia.
3. **SOLVENCIA**: su p-valor (0,056) queda ligeramente por encima de 0,05, de modo que solo es significativa al 10 %. Su coeficiente positivo apunta a que las compañías con mayor capacidad financiera tienen más probabilidad de obtener la licencia.

Las demás variables (IFIDE, FLOTA, RUTAS, EXPERIENCIA y EFLO) **no son estadísticamente significativas** a los niveles habituales. Esto no significa que carezcan de relación con la concesión de la licencia —el análisis descriptivo mostró que sí la tienen—, sino que su efecto queda absorbido por las variables significativas una vez que estas se incluyen en el modelo.

Un resultado especialmente interesante es el de **EFLO**: en el análisis descriptivo, el estado de la flota mostraba una asociación clara con la licencia (60 % de concesión en flotas renovadas

frente a 25 % en antiguas). Sin embargo, en el modelo multivariante, EFLO pierde significación. La explicación radica en que las compañías con flota renovada tienden a tener también mejor puntualidad y menor tasa de incidencias, que son las variables que verdaderamente capturan el efecto. Este hallazgo ilustra un principio fundamental del análisis multivariante: **una asociación bivariante puede desaparecer cuando se controla por otras variables** que median o confunden la relación.

6.5.9 Contraste de Wald para el factor EFLO.

Dado que EFLO genera dos variables *dummy* (EFLOMADURA y EFLORENOVADA), es posible que ninguna sea individualmente significativa pero que el factor en su conjunto sí lo sea. `lite_logit()` realiza automáticamente el **contraste de Wald conjunto** para cada factor con más de dos categorías:

```
completo$wald_factores
```

Factor	χ^2	g.l.	p-valor	Decisión
EFLO	0.1801	2	0.9139	No se rechaza H0 (coeficientes nulos) al 5 %

Tabla 6.7

El resultado del contraste confirma lo que ya anticipaban los contrastes individuales: el factor EFLO no es conjuntamente significativo una vez que IPUNT y TINCID están incluidos en el modelo. Esto refuerza la interpretación de que el efecto aparente de la renovación de la flota opera a través de la puntualidad y la seguridad operativa, no de forma directa.

6.5.10 Interpretación de los *odd ratios*.

La tabla de *odd ratios* muestra, para cada variable, el factor por el que se multiplica la ventaja del suceso LICENCIA = 1 cuando la variable se incrementa en una unidad, manteniendo las demás constantes:

```
completo$odds
```

Variable	Coeficiente	Odd Ratio (e^β)	Cambio en ventaja (%)
(Intercept)	-10.2097	0.0000	-99.9963
SOLVENCIA	0.0217	1.0220	2.1971
IPUNT	0.0654	1.0676	6.7600
TINCID	-0.2735	0.7607	-23.9258
IFIDE	0.0726	1.0753	7.5302
FLOTA	-0.0185	0.9817	-1.8310
RUTAS	0.0018	1.0018	0.1821
EXPERIENCIA	0.0500	1.0513	5.1286
EFLOMADURA	-0.0335	0.9671	-3.2914
EFLORENOVADA	0.2839	1.3283	32.8315

Tabla 6.8

La lectura de esta tabla permite trasladar los resultados estadísticos a un lenguaje económico directo. Por ejemplo, el *odd ratio* de TINCID es inferior a 1 (con un cambio negativo en la ventaja): cada incidencia adicional por cada 1.000 años-luz reduce la ventaja de obtener la licencia en el porcentaje que indica la columna "Cambio en ventaja (%)", en torno a un 24 %. El *odd ratio* de IPUNT, en cambio, es superior a 1: cada punto adicional de puntualidad multiplica la ventaja por ese factor, es decir, la aumenta en torno a un 7 %.

6.5.11 Bondad del ajuste.

La tabla de **bondad del ajuste** recoge el pseudo R^2 de Nagelkerke, el AIC y las devianzas del modelo nulo y del estimado:

```
completo$ajuste
```

R^2 Nagelkerke	AIC	Devianza nula	g.l.	Devianza residual	g.l.	n
0.4425	92.5858	103.5915	79	72.5858	70	80

Tabla 6.9

Podemos evaluar, además, la mejora del modelo frente al modelo nulo (un modelo sin ninguna variable explicativa) mediante el **análisis de la devianza**, que muestra cuánto reduce la devianza cada variable al incorporarse sucesivamente al modelo:

```
completo$devianza
```

Variable	g.l.	Devianza	g.l. residuales	Devianza residual	p-valor
NULL	NA	NA	79	103.5915	NA
SOLVENCIA	1	5.0458	78	98.5456	0.0247
IPUNT	1	5.6617	77	92.8839	0.0173
TINCID	1	7.4691	76	85.4148	0.0063
IFIDE	1	9.7145	75	75.7003	0.0018
FLOTA	1	0.0781	74	75.6222	0.7799
RUTAS	1	2.2601	73	73.3621	0.1327
EXPERIENCIA	1	0.5964	72	72.7658	0.4400
EFLO	2	0.1799	70	72.5858	0.9140

Tabla 6.10

También resulta ilustrativo comparar el **AIC** del modelo estimado con el del modelo nulo:

```
completo$aic
```

Modelo	Parámetros	AIC
Nulo (solo constante)	1	105.5915
Estimado	10	92.5858

Tabla 6.11

La reducción sustancial del AIC confirma que las variables explicativas aportan información relevante para explicar la concesión de licencias.

6.6 Capacidad predictiva del modelo.

6.6.1 Predicción *in-sample*.

La **matriz de confusión** compara las clasificaciones realizadas por el modelo (basadas en un umbral de probabilidad de 0,5) con las pertenencias reales:

```
completo$confusion
```

Observado \ Predicho	0	1
0	47	5
1	11	17
% Correctas: 80 %		

Tabla 6.12

El porcentaje de predicciones correctas sobre la muestra de estimación da una primera indicación de la calidad del modelo. Sin embargo, esta medida puede ser optimista, ya que el modelo ha sido ajustado sobre esos mismos datos.

6.6.2 Predicción sobre la muestra de test.

La verdadera prueba de la capacidad predictiva de un modelo es su comportamiento sobre **datos que no ha visto durante la estimación**. Como indicamos la muestra de test al estimar el modelo, `lite_logit()` ha calculado también su matriz de confusión:

```
completo$confusion_test
```

Observado \ Predicho	0	1
0	8	0
1	4	8
% Correctas: 80 %		

Tabla 6.13

El porcentaje de acierto sobre la muestra de test permite evaluar de forma honesta si el modelo es capaz de generalizar sus predicciones a nuevos casos.

6.7 Simulación de escenarios.

Una vez estimado y validado el modelo, podemos utilizarlo para simular la probabilidad de obtener la licencia bajo diferentes perfiles de compañía. Esto resulta especialmente útil para las empresas que estén considerando presentarse al próximo concurso de licencias: pueden evaluar *ex ante* sus posibilidades y, en su caso, identificar qué indicadores deberían mejorar para maximizar su probabilidad de concesión.

Los escenarios se definen en el archivo de Microsoft® Excel® **escenarios_logit_rstars.xlsx**, en su hoja “Escenarios”. Se plantean tres perfiles ficticios:

- **Candidata fuerte:** alta solvencia, alta puntualidad, pocas incidencias, flota renovada y amplia experiencia.
- **Candidata débil:** solvencia baja, puntualidad deficiente, alta tasa de incidencias, flota antigua y escasa experiencia.
- **Candidata media:** valores intermedios en todos los indicadores y flota madura.

	A	B	C	D	E	F	G	H	I
1	ESCENARIO	SOLVENCIA	IPUNT	TINCID	IFIDE	FLOTA	RUTAS	EXPERIENCIA	EFLO
2	Candidata fuerte	210	78	2,5	50	25	600	18	RENOVADA
3	Candidata débil	145	40	14	25	8	150	2	ANTIGUA
4	Candidata media	180	60	7	40	15	350	9	MADURA

Figura 6.5. Escenarios de empresas candidatas a obtención de licencia.

La función `lite_logit_escenarios()` calcula, para cada perfil, la **probabilidad estimada** de obtener la licencia, un **intervalo de confianza** sobre dicha probabilidad y una **clasificación** según el umbral de 0,5:

```
escenarios <- lite_logit_escenarios(completo, "escenarios_logit_rstars.xlsx")
```

```
escenarios$tabla
```

ESCENARIO	SOLVENCIA	IPUNT	TINCID	IFIDE	FLOTA	RUTAS	EXPERIENCIA	EFLO	.prob	.prob_lwr	.prob_upr	.se_link	.clasif	.level	.umbral
Candidata débil	145	40	14.0	25	8	150	2	ANTIGUA	0.002	0.000	0.042	1.589	0	0.95	0.5
Candidata fuerte	210	78	2.5	50	25	600	18	RENOVADA	0.985	0.868	0.999	1.189	1	0.95	0.5
Candidata media	180	60	7.0	40	15	350	9	MADURA	0.353	0.140	0.645	0.615	0	0.95	0.5

Tabla 6.14

En la tabla, la columna “.prob” es la probabilidad estimada; “.prob_lwr” y “.prob_upr”, los límites del intervalo de confianza al 95 %; “.clasif”, la clasificación (1 = concedida, 0 = denegada); y las tres últimas recogen el error estándar en la escala del modelo, el nivel de confianza y el umbral empleados.

Los resultados de la simulación ilustran de forma elocuente el poder discriminante del modelo. La candidata fuerte obtiene una probabilidad muy elevada de concesión, coherente con sus buenos indicadores de puntualidad, seguridad y solvencia. La candidata débil, con perfil opuesto, tiene una probabilidad muy baja. La candidata media se sitúa en una zona intermedia, lo que refleja que sus indicadores no son suficientes para asegurar la licencia pero tampoco descartan la posibilidad.

Para las compañías que deseen mejorar sus posibilidades, el modelo señala con claridad dónde concentrar los esfuerzos: **reducir la tasa de incidencias y mejorar la puntualidad** son las dos palancas con mayor impacto sobre la probabilidad de concesión, seguidas de la mejora de la solvencia financiera.

6.8 Selección automática de la especificación.

Existe un procedimiento automático, el algoritmo *step*, que busca una especificación más parsimoniosa: elimina iterativamente las variables que no aportan al modelo según el criterio de información de Akaike (AIC). Lo aplica la función `lite_logit_seleccion()`, que muestra en la consola cada paso del proceso:

```
reducido <- lite_logit_seleccion(completo)
```

```
## Start:  AIC=92.59
## LICENCIA ~ SOLVENCIA + IPUNT + TINCID + IFIDE + FLOTA + RUTAS +
##     EXPERIENCIA + EFLO
##
##               Df Deviance    AIC
## - EFLO         2   72.766 88.766
## - EXPERIENCIA  1   72.836 90.836
## - FLOTA        1   72.942 90.942
## - RUTAS        1   73.374 91.374
## - IFIDE        1   73.678 91.678
## <none>             72.586 92.586
## - SOLVENCIA    1   76.441 94.441
## - IPUNT        1   79.559 97.559
## - TINCID       1   81.362 99.362
##
## Step:  AIC=88.77
## LICENCIA ~ SOLVENCIA + IPUNT + TINCID + IFIDE + FLOTA + RUTAS +
##     EXPERIENCIA
##
##               Df Deviance    AIC
## - FLOTA        1   73.278 87.278
## - EXPERIENCIA  1   73.362 87.362
## - RUTAS        1   73.672 87.672
## - IFIDE        1   74.074 88.074
## <none>             72.766 88.766
## - SOLVENCIA    1   76.705 90.705
## - IPUNT        1   79.833 93.833
## - TINCID       1   82.093 96.093
##
```

```
## Step:  AIC=87.28
## LICENCIA ~ SOLVENCIA + IPUNT + TINCID + IFIDE + RUTAS + EXPERIENCIA
##
##               Df Deviance    AIC
## - RUTAS        1   73.743 85.743
## - EXPERIENCIA  1   74.252 86.252
## - IFIDE        1   74.523 86.523
## <none>             73.278 87.278
## - SOLVENCIA    1   77.098 89.098
## - IPUNT        1   80.474 92.474
## - TINCID       1   82.920 94.920
##
## Step:  AIC=85.74
## LICENCIA ~ SOLVENCIA + IPUNT + TINCID + IFIDE + EXPERIENCIA
##
##               Df Deviance    AIC
## - EXPERIENCIA  1   75.700 85.700
## <none>             73.743 85.743
## - IFIDE        1   77.238 87.238
## - SOLVENCIA    1   77.306 87.306
## - IPUNT        1   80.622 90.622
## - TINCID       1   83.042 93.042
##
## Step:  AIC=85.7
## LICENCIA ~ SOLVENCIA + IPUNT + TINCID + IFIDE
##
##             Df Deviance    AIC
## <none>           75.700 85.700
## - SOLVENCIA  1   79.025 87.025
## - IPUNT      1   81.682 89.682
## - IFIDE      1   85.415 93.415
## - TINCID     1   85.688 93.688


## Modelo seleccionado: LICENCIA ~ SOLVENCIA + IPUNT + TINCID + IFIDE
```

En cada paso, la tabla muestra el AIC que resultaría de eliminar cada variable (filas "-") o de no eliminar ninguna (""); el algoritmo elimina la variable cuya salida reduce más el AIC, y se detiene cuando ninguna eliminación lo mejora. El modelo seleccionado conserva cuatro variables: SOLVENCIA, IPUNT, TINCID e IFIDE. Sus coeficientes son:

```
reducido$coeficientes
```

Variable	Coeficiente	Desv. Típica	Estadístico z	p-valor	Sig.
(Intercept)	-11.10383	3.4889	-3.1827	0.0015	**
SOLVENCIA	0.01962	0.0111	1.7696	0.0768	·
IPUNT	0.05783	0.0260	2.2266	0.0260	*
TINCID	-0.27807	0.0974	-2.8557	0.0043	**
IFIDE	0.13861	0.0539	2.5724	0.0101	*

Tabla 6.15

En el modelo reducido, TINCID, IPUNT e IFIDE resultan significativas al 5 %, y SOLVENCIA, al 10 %. La pieza `comparacion` enfrenta ambos modelos:

```
reducido$comparacion
```

Modelo	Variables	AIC	R^2 Nagelkerke	% aciertos (estimación)	% aciertos (test)
Completo	8	92.5858	0.4425	80.00	80
Reducido (step)	4	85.7003	0.4054	76.25	80

Tabla 6.16

El modelo reducido mejora el AIC y mantiene la misma capacidad predictiva sobre la muestra de test, con la ventaja de ser más sencillo. En coherencia con el **principio de parsimonia**, el modelo reducido es preferible: explica lo mismo con menos complejidad. Todas las demás tablas del modelo reducido (*odd ratios*, ajuste, matrices de confusión...) están disponibles en el objeto "reducido", con las mismas piezas que el modelo completo.

6.9 Cierre: el veredicto de *Data-Evidence*.

El equipo de *Data-Evidence* entrega su informe a la Autoridad Galáctica de Transporte Interestelar (AGTI) y a las compañías interesadas en la ruta Coruscant–Arrakis con tres conclusiones principales:

1. **El modelo logit binomial identifica con claridad los factores determinantes de la concesión de licencias.** La puntualidad, la tasa de incidencias y la solvencia financiera son las variables con mayor peso en la decisión de la AGTI. El estado de la flota, pese a su clara asociación con la licencia en el análisis descriptivo, no aporta información adicional una vez tenidos en cuenta los demás factores.

2. **La capacidad predictiva del modelo es elevada**, tanto sobre los datos de estimación como sobre la muestra de test, lo que valida su utilidad como herramienta de apoyo a la decisión. La selección automática produce un modelo más parsimonioso sin pérdida apreciable de precisión.

3. **La simulación de escenarios ofrece a las compañías candidatas una guía accionable.** Una empresa con buenas prácticas operativas (baja tasa de incidencias, alta puntualidad) y solidez financiera tiene una probabilidad muy alta de obtener la licencia, independientemente de otros factores. Para las compañías en zona intermedia, el modelo señala con precisión dónde invertir esfuerzos para maximizar sus posibilidades.

Cuentan las crónicas que, tras la publicación del informe, varias compañías del sector invirtieron en mejorar sus protocolos de seguridad y puntualidad. Y que *Arg-us Korp*, siempre atento a las oportunidades del sector, murmuró al leer los resultados: *"Interesante... muy interesante"*.

6.10 Materiales para realizar las prácticas del capítulo.

En esta sección se muestran los links de acceso a los diferentes materiales (*scripts*, datos...) necesarios para llevar a cabo los contenidos prácticos del capítulo.

Datos (en formato Microsoft® Excel®):

- licencias_100.xlsx (obtener aquí), o bien, desde R: `lite_datos("licencias_100")`.
- escenarios_logit_rstars.xlsx (obtener aquí), o bien, desde R: `lite_datos("escenarios_logit_rstars")`.

Script:

- logit_lite.R (obtener aquí)

CAPÍTULO 7

Tablas de contingencia.

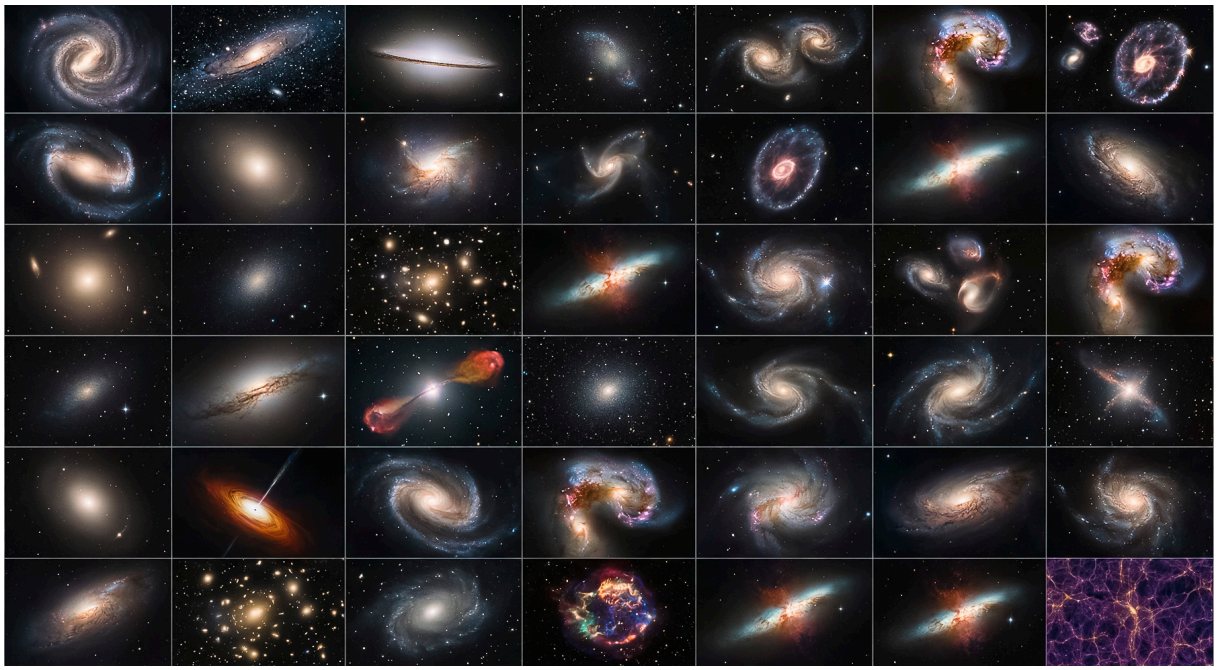


Figura 7.1. GALAXIAS QUE RECORRER...

7.1 Introducción.

En numerosas ocasiones los datos con los que el analista debe enfrentarse son de naturaleza **cualitativa**, esto es, la información se recoge en características de los individuos no numéricas o **atributos** (o factores o variables categóricas o cualitativas). Cuando ocurre esto, es necesario recurrir a técnicas de explotación específicas para este tipo de datos.

En estos casos, la información suele sintetizarse y presentarse mediante las denominadas **tablas de contingencia**. En este tipo de tablas, se muestran las frecuencias conjuntas, es decir, el número de casos que comparten los distintos niveles o categorías de los diferentes factores.

Cuando se trabaja con varios factores o atributos, representados en su correspondiente tabla de contingencia, uno de los análisis más interesantes es determinar si existe **asociación** entre los factores o atributos, es decir, si se aprecia algún tipo de relación estadística entre estas variables categóricas, en el sentido de si se puede afirmar que el hecho de que los casos de la muestra tomen ciertos niveles o categorías en unos factores hace que estos mismos casos tiendan a tomar ciertos niveles o categorías de otro u otros factores.

7.2 Asociación entre dos atributos: la prueba ji-cuadrado.

Existen diferentes pruebas para verificar la posible existencia de asociación entre dos factores. La más habitual es el **contraste o prueba de asociación de Pearson**. Este contraste se basa en un estadístico que, bajo la hipótesis nula de que no existe asociación, sigue una distribución ji-cuadrado. El estadístico es, en realidad, una medida global de **lo distante que está la tabla de contingencia observada (sus frecuencias conjuntas) respecto a la estructura "ideal" que tendría que tener si existiera independencia** "total" entre ambos atributos:

$$\chi^2 = \sum_{i=1}^{r} \sum_{j=1}^{c} \frac{(n_{ij} - E_{ij})^2}{E_{ij}}$$

donde:

- n_{ij} es la frecuencia observada en la celda (i, j).
- E_{ij} es la frecuencia esperada en la celda (i, j) bajo independencia, calculada como $E_{ij} = \frac{R_i \cdot C_j}{N}$.
- R_i es el total de la fila i, C_j el total de la columna j, y N el total general de observaciones.

En este contraste, la hipótesis nula (H_0) establece que **no existe asociación entre las dos variables categóricas**, es decir, que son estadísticamente **independientes**. La hipótesis alternativa (H_1) plantea que **sí existe asociación**, de modo que la distribución conjunta difiere significativamente de la esperada. El estadístico tiene $(r-1)(c-1)$ grados de libertad, siendo r y c el número de filas y columnas de la tabla.

Si se rechaza la independencia, conviene saber **qué celdas** son las responsables. Para ello se emplean los **residuos estandarizados ajustados**, que miden la desviación de cada frecuencia observada respecto a la esperada:

$$r_{ij} = \frac{n_{ij} - E_{ij}}{\sqrt{E_{ij}\left(1 - \frac{R_i}{N}\right)\left(1 - \frac{C_j}{N}\right)}}$$

Como se distribuyen aproximadamente según una normal estándar, los residuos con valor absoluto superior a 1,96 indican celdas que se desvían significativamente (al 5 %) de lo esperado bajo independencia: un residuo positivo señala que esa combinación de categorías aparece **más** de lo esperado, y uno negativo, **menos**.

7.3 Medidas de asociación.

La prueba ji-cuadrado responde a la pregunta de **si** existe asociación, pero no a la de **cuán intensa** es. El valor del estadístico χ^2 no sirve para medir la intensidad, porque crece con el tamaño de la muestra: con muchos casos, asociaciones muy débiles resultan significativas. Para medir la intensidad se utilizan los **coeficientes de asociación**, que relativizan el χ^2 y toman valores entre 0 (independencia) y, como máximo, 1:

- **Coeficiente de contingencia de Pearson (*C*)**:

$$C = \sqrt{\frac{\chi^2}{\chi^2 + N}}$$

Su inconveniente es que no alcanza el valor 1 ni siquiera con asociación perfecta: su máximo depende del tamaño de la tabla, $C_{\text{máx}} = \sqrt{\frac{k-1}{k}}$, siendo k el menor entre el número de filas y de columnas. Por eso suele calcularse también el **coeficiente de contingencia corregido**, $C/C_{\text{máx}}$, que sí puede llegar a 1.

- **V de Cramér**:

$$V = \sqrt{\frac{\chi^2}{N\,(k-1)}}$$

Es la medida más utilizada, porque varía entre 0 y 1 con independencia del tamaño de la tabla, lo que permite comparar tablas distintas. Como orientación, valores de *V* por debajo de 0,1 suelen considerarse una asociación despreciable; entre 0,1 y 0,3, débil; entre 0,3 y 0,5, moderada; y por encima de 0,5, fuerte.

- **Coeficiente Phi** ($\phi = \sqrt{\chi^2/N}$): solo tiene sentido en tablas de 2 × 2, en las que coincide con la *V* de Cramér.

Conviene leer siempre conjuntamente el contraste y las medidas: el contraste dice si la asociación es estadísticamente distinguible del azar; las medidas, si es relevante en la práctica.

7.4 Práctica: el entramado comercial del cosmos.

7.4.1 El encargo.

En el inmenso mapa del espacio conocido, las distintas galaxias no solo se distinguen por la luz de sus estrellas, sino también por la forma en que sus habitantes organizan el comercio, la política y la vida empresarial. Las naves que surcan los corredores hiperespaciales transportan minerales, piezas de ingeniería cuántica, alimentos sintéticos y cualquier cosa que pueda venderse entre sistemas planetarios. Pero detrás de cada nave hay una empresa, y detrás de cada empresa, una historia.

El presente análisis forma parte de un informe solicitado por la *Agencia Interplanetaria de Transporte de Mercancías*, preocupada por comprender cómo ciertos factores estructurales influyen en la operativa y organización de las empresas de transporte interestelar. En concreto, se plantean dos cuestiones:

1. Si la galaxia donde opera la sede de las empresas (GALAXIA) influye en su forma jurídica (FJUR).
2. Si el estado de renovación de la flota (EFLO) depende de la forma jurídica.

7.4.2 Preparación de los datos.

Necesitamos en la carpeta del proyecto el archivo de datos **interestelar_300.xlsx**, con información de 300 empresas dedicadas a los servicios de transporte interestelar de mercancías, y el *script* **contingencia_lite.R**. Importamos los datos y seleccionamos los tres atributos del análisis:

```
# Limpiando el Global Environment
rm(list = ls())

# Cargando el paquete de la asignatura
library(MATlite)

# Importando datos y seleccionando los atributos del análisis
interestelar_300 <- lite_importa("interestelar_300.xlsx")
seleccion <- interestelar_300 %>% select(GALAXIA, FJUR, EFLO)
lite_resumen(seleccion)
```

seleccion: 300 casos × 3 variables

Variable	Tipo	Categorías	Ausentes (%)	Media	Mediana	Desv. típica
GALAXIA	Categórica	5	0.0			
FJUR	Categórica	3	0.0			
EFLO	Categórica	3	0.0			

Tabla 7.1

Comprobamos la existencia de *missing values* y, como los nombres de las galaxias son muy largos (lo que dificultaría la lectura de tablas y gráficos), los abreviamos con la función `lite_recodifica()`. Basta con indicarle la variable y una lista de cambios con la forma `"nombre antiguo" = "nombre nuevo"`; las categorías que no se mencionan (aquí, "Vía Láctea") se mantienen tal cual:

```
seleccion <- lite_na(seleccion, accion = "eliminar",
                     titulo    = "Tablas de contingencia.",
                     subtitulo = "Transporte de mercancías interestelar")
```

```
seleccion <- lite_recodifica(seleccion, GALAXIA,
  c("Gran Nube de Magallanes"    = "GN Magallanes",
    "Pequeña Nube de Magallanes" = "PN Magallanes",
    "Galaxia de Andrómeda"       = "Andrómeda",
    "Galaxia del Triángulo"      = "Triángulo"))
```

```
## GALAXIA: 216 casos recodificados. Categorías: Andrómeda, GN Magallanes, PN
 ↪  Magallanes, Triángulo, Vía Láctea.
```

No se ha localizado ninguna observación con *missing values*, luego no se ha de realizar ningún tipo de tratamiento.

7.4.3 La sospecha institucional (GALAXIA × FJUR).

En el sector del transporte interestelar existe la percepción generalizada de que las condiciones institucionales y regulatorias de cada galaxia influyen en la forma en que las empresas se constituyen jurídicamente. La Vía Láctea, con un marco fiscal estable y maduro, tiende a favorecer sociedades mercantiles de gran tamaño, mientras que otras galaxias, como la Gran y la Pequeña Nube de Magallanes, han desarrollado sistemas legales más flexibles o con incentivos específicos para determinadas estructuras empresariales. Esta heterogeneidad normativa sugiere que la elección de la forma jurídica (FJUR) podría estar condicionada por la galaxia de operación (GALAXIA), lo cual justifica el análisis estadístico de su posible asociación.

Todo el análisis lo realiza la función `lite_contingencia()`, a la que indicamos el *data frame*, el atributo que irá en las filas, el que irá en las columnas y, opcionalmente, un título y subtítulo para los gráficos:

```
galaxia_fjur <- lite_contingencia(seleccion, GALAXIA, FJUR,
                                  titulo    = "Galaxia y Forma Jurídica",
                                  subtitulo = "Empresas TMI")
```

```
## Contraste ji-cuadrado: χ² = 18.209, g.l. = 8, p-valor = 0.01971. Se rechaza H0
 ↪  (independencia) al 5 %.
```

La función adelanta en la consola el resultado del contraste. Vamos a examinar sus piezas una a una, comenzando por la **tabla de contingencia**, con las frecuencias marginales (sumas de filas y columnas):

```
galaxia_fjur$tabla
```

GALAXIA	FJUR			
	CG	SAG	SLG	Sum
Andrómeda	20	29	35	84
GN Magallanes	23	12	17	52
PN Magallanes	4	7	22	33
Triángulo	10	17	20	47
Vía Láctea	25	22	37	84
Sum	82	87	131	300

Tabla 7.2

La tabla de contingencia muestra cómo se distribuyen las formas jurídicas de las empresas (CG, SAG y SLG) en cada galaxia del estudio. Se observa que **Andrómeda** y **Vía Láctea** son las que concentran el mayor número de compañías (84 cada una), mientras que **PN Magallanes** es la menos representada. La forma jurídica **SLG** es la más frecuente en el conjunto del sector y también dentro de cada galaxia, con una excepción llamativa: en **GN Magallanes** la forma dominante es **CG** (23 empresas, frente a 17 SLG). El predominio de las SLG es, en cambio, especialmente acusado en **PN Magallanes**, donde representa dos tercios de las empresas. En conjunto, la tabla sugiere posibles diferencias estructurales entre galaxias, lo que motiva la necesidad de un análisis formal de asociación.

La tabla también se puede representar gráficamente mediante un **gráfico de mosaico**, con lo que se percibirá mejor la magnitud de las frecuencias conjuntas. A mayor frecuencia, mayor área del rectángulo correspondiente:

```
galaxia_fjur$mosaico
```

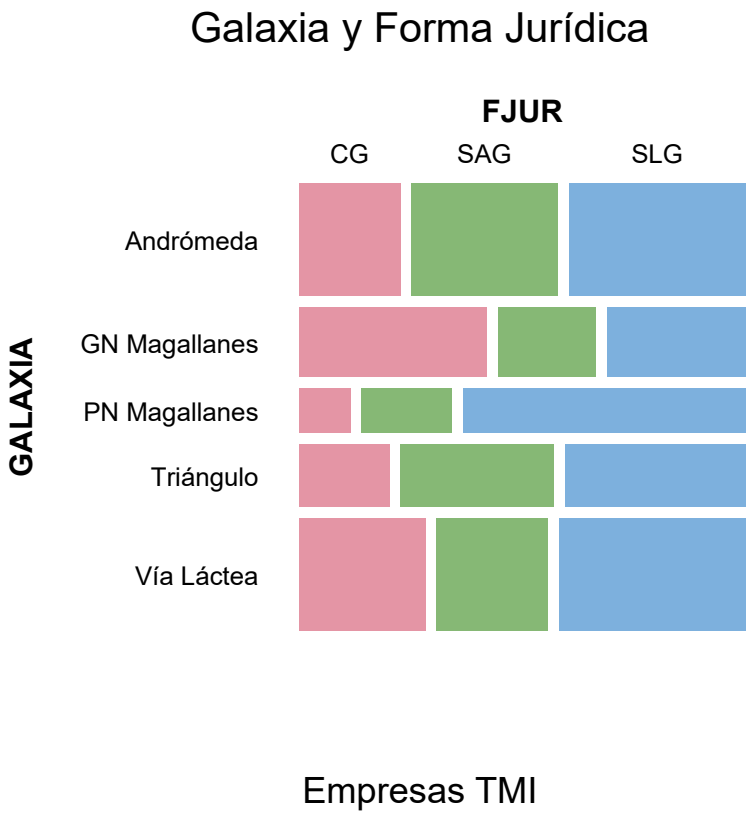


Figura 7.2

Cada fila del mosaico corresponde a una galaxia y su anchura refleja el número total de empresas que operan en ella; dentro de cada fila, las columnas representan las formas jurídicas (CG, SAG y SLG) en proporción a su frecuencia dentro de esa galaxia. Puede verse, por ejemplo, que Andrómeda y la Vía Láctea albergan un mayor número total de empresas, y que en la mayoría de galaxias predominan las SLG. La disposición y el tamaño de los rectángulos facilitan comparar visualmente cómo varía la composición jurídica entre galaxias.

Otro modo de visualizar la estructura de la tabla es mediante gráficos de barras que muestren las **frecuencias marginales** de cada atributo, diferenciando en cada barra los casos que pertenecen a las categorías del otro:

```
galaxia_fjur$barras
```

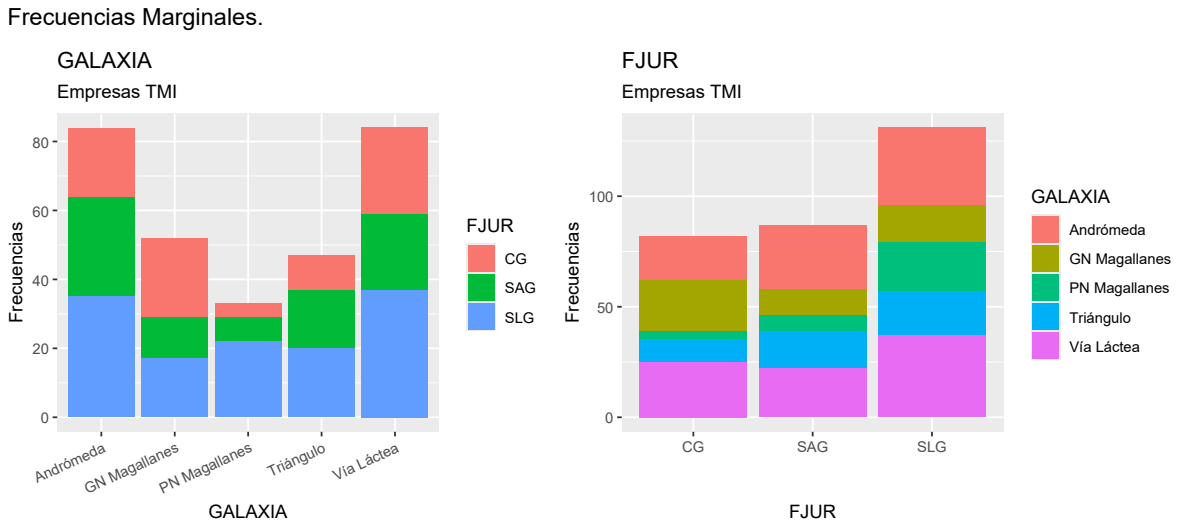


Figura 7.3

En el gráfico de la izquierda se observa cuántas empresas operan en cada **galaxia**, con las barras apiladas según su **forma jurídica**. En el de la derecha se muestra la distribución inversa: las frecuencias de cada **forma jurídica**, apiladas según la galaxia. Las SLG son la forma jurídica más habitual en el conjunto del sector, y las galaxias contribuyen en proporciones diferentes a cada forma, lo que refuerza visualmente la idea de posibles diferencias estructurales.

Pasamos ahora a la cuestión central: **¿existe asociación entre ambos atributos?** La pieza `chi2` recoge la prueba de asociación de Pearson:

```
galaxia_fjur$chi2
```

Contraste	χ^2	g.l.	p-valor	Decisión
Ji-cuadrado de Pearson	18.209	8	0.0197	Se rechaza H0 (independencia) al 5 %

Tabla 7.3

El resultado de la prueba ofrece un estadístico $\chi^2 = 18{,}209$ con 8 grados de libertad y un **p-valor de 0,0197**, inferior al nivel habitual de significación del 5 %. Esto implica que **rechazamos la hipótesis nula de independencia** entre GALAXIA y FJUR. En consecuencia, concluimos que **sí existe evidencia estadística de asociación** entre la galaxia donde se sitúa la sede de la empresa y su forma jurídica.

Si tenemos curiosidad por saber cuáles serían las frecuencias de la tabla en caso de independencia total, `galaxia_fjur$esperadas` las muestra. Para saber **qué celdas son responsables** de la asociación, examinamos los residuos estandarizados ajustados; las celdas significativas aparecen resaltadas en naranja:

```
galaxia_fjur$residuos
```

	CG	SAG	SLG
Andrómeda	-0.85	1.31	-0.44
GN Magallanes	**3.01**	-1.04	-1.75
PN Magallanes	**-2.08**	-1.05	**2.82**
Triángulo	-1.01	1.18	-0.17
Vía Láctea	0.59	-0.67	0.08

Tabla 7.4

La misma información se ofrece de forma gráfica en el **gráfico de asociación**, en el que cada barra representa el residuo de una celda: hacia arriba si la combinación aparece más de lo esperado, hacia abajo si aparece menos, y coloreada en naranja si la desviación es significativa:

```
galaxia_fjur$asociacion
```

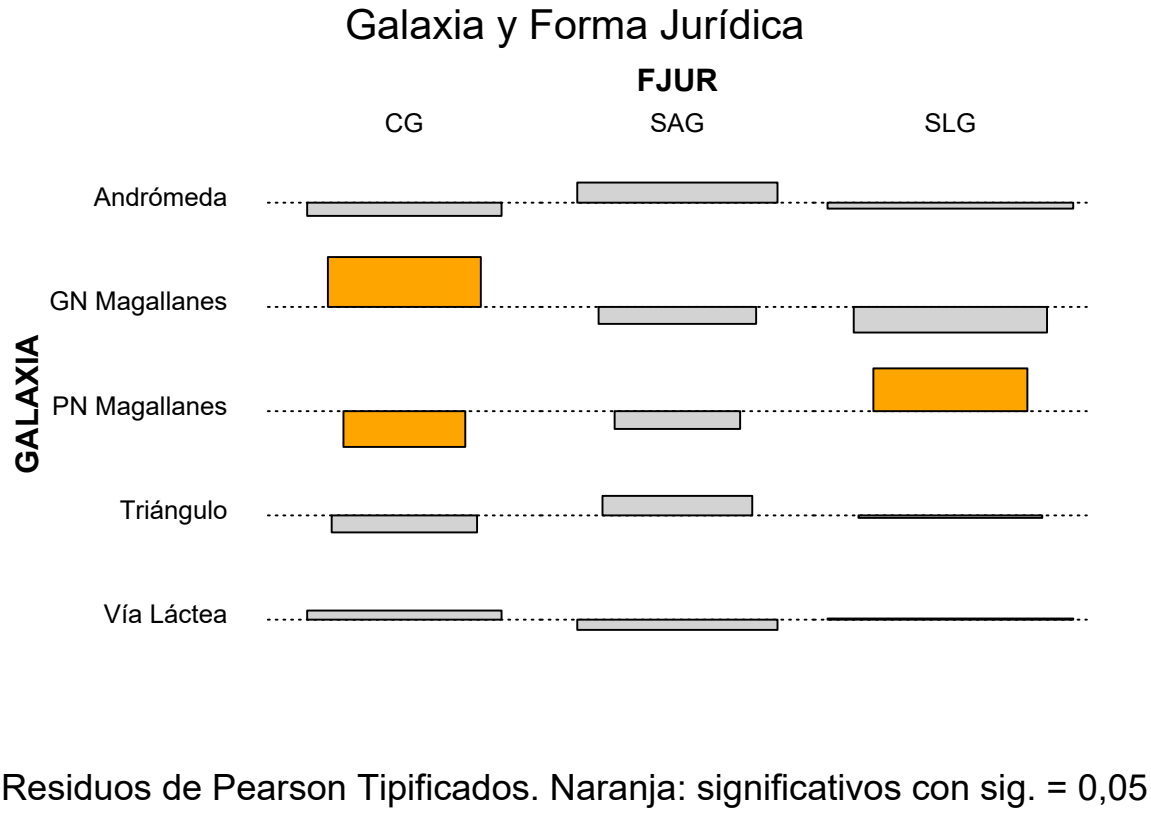


Figura 7.4

Solo unas pocas celdas muestran desviaciones significativas: **CG en la Gran Nube de Magallanes** (más compañías de las esperadas), y **CG** (menos de las esperadas) y **SLG** (más) en la **Pequeña Nube de Magallanes**. Estos resultados confirman que **la distribución de formas jurídicas no es uniforme entre galaxias**, tal como apuntaba la prueba ji-cuadrado: ciertas galaxias albergan un número inusualmente alto o bajo de determinadas formas jurídicas, lo que sugiere **diferencias reales en los entornos institucionales, normativos o económicos** de cada galaxia.

Por último, ¿**es intensa** esta asociación? Lo dicen las **medidas de asociación**:

```
galaxia_fjur$medidas
```

Medida	Valor
Coeficiente de contingencia C	0.239
C máximo posible en esta tabla	0.816
C corregido (C / C máximo)	0.293
V de Cramér	0.174

Tabla 7.5

El coeficiente de contingencia vale 0,239. Como la tabla tiene 3 columnas, su valor máximo posible es 0,816, de modo que el coeficiente corregido es 0,293. La V de Cramér, de 0,174, indica una **asociación débil**. La lectura conjunta es, pues, que la galaxia y la forma jurídica están asociadas de forma estadísticamente significativa, pero que esa asociación es de intensidad modesta: se concentra en unas pocas combinaciones de categorías (las dos Nubes de Magallanes), mientras que en el resto de galaxias la composición jurídica es bastante parecida.

7.4.4 ¿Se refleja la estructura jurídica en la renovación de la flota? (FJUR × EFLO).

En la segunda fase de la investigación se examina si el **estado de la flota de las empresas (EFLO)** —renovada, madura o antigua— presenta alguna relación sistemática con su **forma jurídica (FJUR)**. Aunque las estructuras legales pueden variar entre empresas, el mantenimiento y renovación de las flotas suele estar condicionado por **normativas técnicas y ciclos de actualización comunes** en todo el sector del transporte interestelar. Por ello, resulta razonable plantear que el estado de la flota no dependa de la forma jurídica de la empresa, sino de factores operativos y tecnológicos homogéneos.

El código es el mismo que en la fase anterior, cambiando únicamente los atributos:

```
fjur_eflo <- lite_contingencia(seleccion, FJUR, EFLO,
                               titulo    = "Forma Jurídica y Estado de la Flota",
                               subtitulo = "Empresas TMI")
```

```
## Contraste ji-cuadrado: χ² = 3.859, g.l. = 4, p-valor = 0.4255. No se rechaza H0
 ↪  (independencia) al 5 %.
```

```
fjur_eflo$tabla
```

FJUR	EFLO			
	ANTIGUA	MADURA	RENOVADA	Sum
CG	34	28	20	82
SAG	42	26	19	87
SLG	72	36	23	131
Sum	148	90	62	300

Tabla 7.6

A primera vista, las diferencias entre categorías son relativamente proporcionales: tanto CG como SAG y SLG presentan una mayor concentración de empresas con flotas **antiguas**, seguidas de **maduras** y, en menor medida, **renovadas**. Aunque las SLG muestran valores absolutos más altos debido a su mayor presencia total, la proporción interna entre estados de flota es muy similar a la observada en CG y SAG. El mosaico lo muestra con claridad:

```
fjur_eflo$mosaico
```

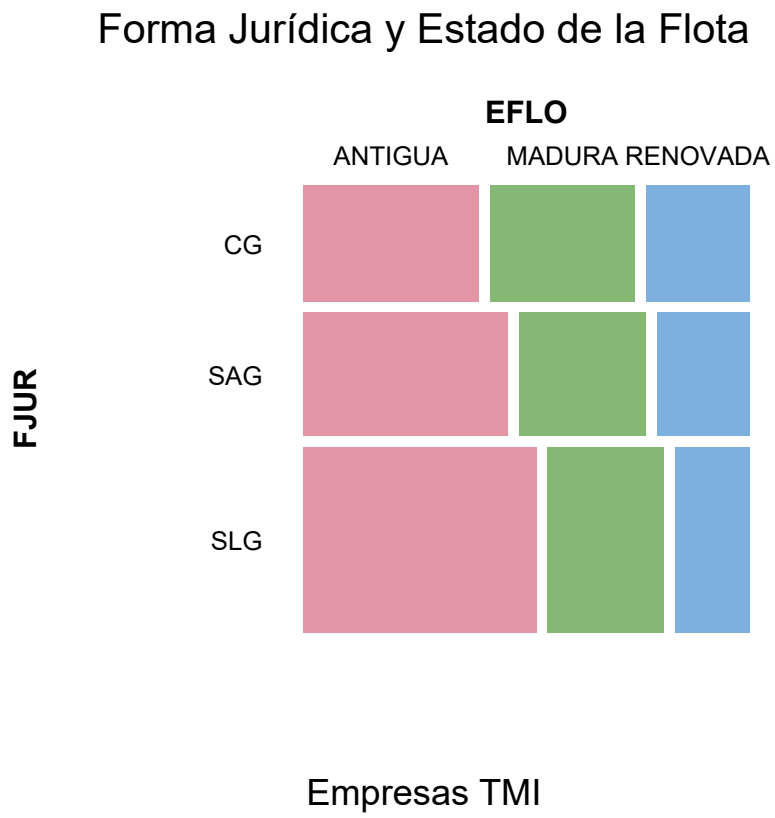


Figura 7.5

La estructura de las barras es prácticamente paralela en CG, SAG y SLG, lo que indica que la composición de estados de flota apenas varía entre tipos de empresa, anticipando un escenario de **independencia**. El contraste lo confirma:

```
fjur_eflo$chi2
```

Contraste	χ^2	g.l.	p-valor	Decisión
Ji-cuadrado de Pearson	3.859	4	0.4255	No se rechaza H0 (independencia) al 5 %

Tabla 7.7

El contraste ji-cuadrado de Pearson arroja un estadístico χ^2 = 3,859 con 4 grados de libertad y un **p-valor de 0,4255**, muy superior al nivel de significación habitual del 5 %. Esto implica

que **no podemos rechazar la hipótesis nula de independencia entre la forma jurídica de las empresas (FJUR) y el estado de su flota (EFLO)**. En otras palabras, las diferencias observadas en la tabla de contingencia pueden explicarse por el azar.

El gráfico de asociación lo ratifica visualmente: todas las barras aparecen en **gris**, de modo que **ningún residuo es estadísticamente significativo**:

```
fjur_eflo$asociacion
```

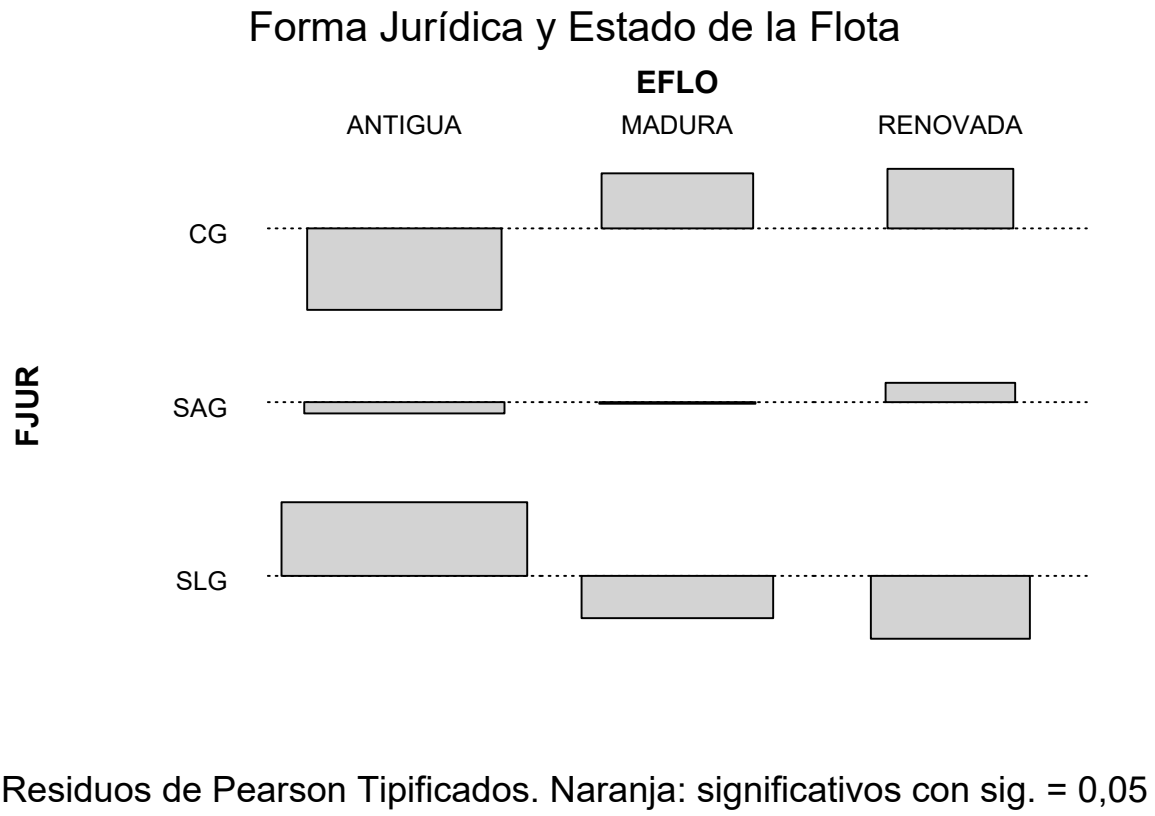


Figura 7.6

Y las medidas de asociación, con una V de Cramér de 0,080, se sitúan en la zona de asociación despreciable:

```
fjur_eflo$medidas
```

Medida	Valor
Coeficiente de contingencia C	0.113
C máximo posible en esta tabla	0.816
C corregido (C / C máximo)	0.138
V de Cramér	0.080

Tabla 7.8

Así, **no existe un patrón sistemático que vincule la forma jurídica de las empresas con el estado de sus flotas**. Esta segunda fase ofrece un ejemplo claro de ausencia de relación entre variables categóricas, y sirve como contrapunto a la primera.

7.4.5 Conclusiones del informe.

El informe para la *Agencia Interplanetaria de Transporte de Mercancías* puede resumirse en dos conclusiones:

1. **La galaxia de la sede y la forma jurídica están asociadas**, aunque de forma débil. La asociación se debe sobre todo a las dos Nubes de Magallanes: en la Gran Nube abundan más de lo esperado las CG, y en la Pequeña Nube, las SLG. Es razonable pensar que los marcos normativos de esas galaxias favorecen determinadas formas de organización empresarial.
2. **El estado de la flota no depende de la forma jurídica.** Las empresas de todo tipo presentan perfiles de renovación de flota muy similares, coherentes con unas normas técnicas y unos ciclos de actualización comunes en todo el sector.

7.5 Materiales para realizar las prácticas del capítulo.

En esta sección se muestran los links de acceso a los diferentes materiales (*scripts*, datos...) necesarios para llevar a cabo los contenidos prácticos del capítulo.

Datos (en formato Microsoft® Excel®):

- interestelar_300.xlsx (obtener aquí), o bien, desde R: `lite_datos("interestelar_300")`.

Script:

- contingencia_lite.R (obtener aquí)

CAPÍTULO 8

Escalado multidimensional.



Figura 8.1. ¿Cómo nos ven? El mapa de las percepciones.

8.1 Introducción: los mapas perceptuales.

En capítulos anteriores hemos utilizado diversas técnicas para describir, clasificar o explicar el comportamiento de un conjunto de variables. Todas ellas comparten un rasgo: parten de datos objetivos —cifras de ventas, ratios financieros, índices de satisfacción— y aplican procedimientos estadísticos para extraer conclusiones. Sin embargo, en el ámbito de la estrategia empresarial y el marketing, existe una pregunta que los datos objetivos, por sí solos, no responden: **¿cómo perciben los clientes nuestro servicio en relación con los de la competencia?**

Esta pregunta es esencialmente **subjetiva**, y para abordarla necesitamos una herramienta capaz de traducir las percepciones humanas en una representación visual interpretable. Esa herramienta es el **mapa perceptual**.

Un mapa perceptual es una **representación gráfica de las percepciones** que tienen los clientes (o cualquier grupo de evaluadores) sobre las **relaciones entre un conjunto de casos** —productos, servicios, marcas, empresas— en un espacio de pocas dimensiones (habitualmente dos). Su objetivo es revelar las **estructuras ocultas** que subyacen en los datos de percepción: qué casos se consideran similares, cuáles se perciben como diferentes, y qué ejes o dimensiones latentes organizan esas percepciones en la mente de los encuestados.

Los mapas perceptuales permiten responder a interrogantes fundamentales para la toma de decisiones empresariales:

- ¿Quiénes son nuestros **competidores** más directos, desde el punto de vista del cliente?
- ¿Cuál es nuestra **posición en el mercado** respecto a la competencia?
- ¿Cómo podemos **reposicionar** nuestra marca o servicio?
- ¿A qué **segmento** debemos dirigir nuestros esfuerzos?
- ¿Cuáles son nuestras **fortalezas y debilidades** percibidas?
- ¿Existe algún **nicho** de mercado no cubierto?

Para construir estos mapas a partir de datos de percepción, se han desarrollado diversas técnicas estadísticas, entre las cuales destaca la familia de métodos conocida como **Escalado Multidimensional** (EMD).

8.2 Escalado Multidimensional: concepto y tipos.

El **Escalado Multidimensional** (*Multidimensional Scaling*, MDS) es una técnica que permite descubrir estructuras o patrones dentro de una **matriz de proximidades** entre casos. Su objetivo es doble:

1. Determinar la **dimensión del modelo** (el número de ejes) que proporcione un ajuste satisfactorio.
2. Obtener las **coordenadas de los casos** en esas dimensiones, de manera que las distancias entre los puntos en el mapa reflejen fielmente las proximidades percibidas: cuanto más cercanos sean dos puntos, más similares serán las opiniones de los encuestados sobre esos dos casos.

Una ventaja importante del EMD frente a otras técnicas multivariantes es que los **resultados no dependen de los juicios del investigador** sobre qué variables o características incluir: las dimensiones que emergen del análisis proceden directamente de los **juicios globales de los encuestados sobre la similitud entre los casos**.

Dicho esto, en la práctica aplicada es frecuente que los datos de partida no sean juicios directos de similitud, sino **valoraciones de los casos en un conjunto de atributos** (por ejemplo, mediante escalas Likert). En estos casos, la matriz de proximidades se **deriva** de los datos de valoración, como veremos más adelante.

8.2.1 Proximidades y distancias.

El concepto central del EMD es la **proximidad** entre dos casos: un valor que indica cuán similares o diferentes los perciben los encuestados. Cuando se habla de proximidad en este contexto, nos referimos a una «distancia perceptual» entre los casos.

El procedimiento más directo para obtener datos de proximidad es **preguntar a las personas** acerca del parecido que perciben entre cada par de casos. Sin embargo, este enfoque resulta costoso cuando el número de casos es elevado (con n casos hay $n(n-1)/2$ pares distintos), y en la práctica se recurre con frecuencia a un procedimiento indirecto: pedir a los encuestados que **valoren cada caso en una serie de atributos** mediante una escala tipo Likert, y calcular después la distancia entre los perfiles de valoración.

Formalmente, la **matriz de proximidades** Δ recoge las distancias δ_{ij} entre todos los pares de casos i y j. Esta matriz es simétrica ($\delta_{ij} = \delta_{ji}$) y tiene ceros en la diagonal ($\delta_{ii} = 0$). El objetivo del EMD es encontrar, a partir de Δ, una **matriz de coordenadas** X, de n filas (casos) y p columnas (dimensiones), que represente cada caso como un punto en un espacio de p dimensiones, de modo que las distancias entre los puntos sean lo más coherentes posible con las proximidades originales.

8.2.2 EMD métrico y no métrico.

La diferencia entre ambos tipos radica en el **nivel de exigencia** con que se pide que las distancias en el mapa reproduzcan las proximidades originales:

- **EMD métrico (clásico):** exige que las distancias en el mapa sean **proporcionales** a las proximidades originales. Es decir, si la distancia entre A y B es el doble que la distancia entre C y D en los datos, también debe serlo en el mapa.
- **EMD no métrico (ordinal):** exige únicamente que las distancias en el mapa preserven el **orden** de las proximidades originales. Si A y B están más cerca que C y D en los datos, también deben estarlo en el mapa, pero no importa cuánto más cerca.

El EMD no métrico es el más utilizado en Ciencias Sociales y en investigación de mercados, porque los datos de encuesta (escalas Likert, valoraciones ordinales) no tienen un significado métrico estricto: la diferencia entre un 4 y un 5 en una escala de satisfacción no es necesariamente la misma que la diferencia entre un 6 y un 7. En este capítulo nos centraremos en el **EMD no métrico**.

8.3 El algoritmo SMACOF y el Stress.

8.3.1 SMACOF.

Para pasar de la matriz de proximidades a la matriz de coordenadas, se han desarrollado diversos algoritmos. Uno de los más utilizados en EMD no métrico es **SMACOF** (*Scaling by Majorizing a Complicated Function*), implementado en el paquete `{smacof}` de R, que es el que utilizan internamente las funciones de `{MATlite}`.

SMACOF busca iterativamente las coordenadas de los casos que minimizan una medida de desajuste denominada **Stress**. El proceso es conceptualmente sencillo: parte de una configuración inicial y la va refinando en sucesivas iteraciones hasta que el Stress deja de mejorar apreciablemente.

8.3.2 El Stress como medida de bondad del ajuste.

El **Stress** cuantifica la discrepancia entre las proximidades originales y las distancias obtenidas en la configuración. Su valor oscila entre 0 (ajuste perfecto) y valores positivos que indican grados crecientes de desajuste. Kruskal (1964) propuso la siguiente escala orientativa para interpretarlo:

Stress	Calidad de la representación
$> 0{,}20$	Pobre
$0{,}10 - 0{,}20$	Razonable
$0{,}05 - 0{,}10$	Buena
$0{,}025 - 0{,}05$	Excelente
$0 - 0{,}025$	Perfecta

Tabla 8.1

La elección del número de dimensiones p se basa en un equilibrio entre parsimonia (pocas dimensiones, fáciles de interpretar) y calidad del ajuste (Stress bajo). La herramienta visual para esta decisión es el **gráfico de codo** del Stress: se representan los valores obtenidos para $p = 1, 2, 3, \ldots$ y se busca el punto a partir del cual añadir una dimensión más produce una mejora reducida.

8.3.3 El diagrama de Shepard.

Además del Stress, disponemos de una herramienta visual para evaluar la calidad del ajuste: el **diagrama de Shepard**. Este gráfico enfrenta en el eje horizontal las proximidades originales y en el eje vertical las distancias obtenidas en la configuración. Si el ajuste es bueno, los puntos se alinearán sobre una función **monótona creciente** (en el caso no métrico). Los puntos muy alejados de la tendencia general señalan pares de casos cuya distancia en el mapa no se corresponde con su proximidad original.

8.4 Práctica: el mapa perceptual del sector interestelar.

8.4.1 La imagen del sector.

La **Asociación Sectorial de Transporte Interestelar (ASTI)** ha detectado una tendencia preocupante entre las pequeñas y medianas empresas que contratan servicios de transporte de mercancías: muchos clientes consideran que «todas las compañías navieras son iguales» y eligen transportista basándose casi exclusivamente en el precio. Esto está erosionando los márgenes de todo el sector y dificultando que las compañías con mejor servicio puedan diferenciarse.

Para combatir esta dinámica, la ASTI ha encargado a la consultora *Data-Evidence* un estudio que responda a dos preguntas clave: **¿cómo perciben realmente los clientes a las distintas compañías del sector?** y **¿existen dimensiones latentes de diferenciación que el sector no está comunicando adecuadamente?**

El equipo de *Data-Evidence* diseña un cuestionario con seis atributos clave del servicio de transporte de mercancías —fiabilidad, puntualidad, seguridad de la carga, relación calidad-precio, atención al cliente e innovación tecnológica— y recoge las valoraciones de 30 clientes frecuentes sobre 15 de las principales compañías del sector, utilizando una escala Likert de 1 (muy deficiente) a 7 (excelente). Con estos datos, construirá un **mapa perceptual** mediante Escalado Multidimensional no métrico.

8.4.2 Preparación de los datos.

Necesitamos en la carpeta del proyecto el archivo de datos **percepcion_interestelar.xlsx**, cuya hoja "Datos" contiene las valoraciones medias de cada empresa en cada uno de los seis atributos, y el *script* **emd_lite.R**. Las 15 compañías pertenecen al universo de 300 empresas de la Base de Datos Interestelar, y presentan perfiles muy diversos: desde grandes corporaciones con flota renovada como *Arrakis Freight* o *Excalibur Freight Systems*, hasta compañías pequeñas con flota antigua como *Sandworm Freight* o *First Order Cargo*, pasando por empresas de tamaño medio con flota madura como *Shuttlepod Movers* o *Defiant Cargo*:

```
# Limpiando el Global Environment
rm(list = ls())

# Cargando el paquete de la asignatura
library(MATlite)

# Importando datos desde Excel
PERCEPCION <- lite_importa("percepcion_interestelar.xlsx")
lite_resumen(PERCEPCION)
```

PERCEPCION: 15 casos × 6 variables

Variable	Tipo	Categorías	Ausentes (%)	Media	Mediana	Desv. típica
FIABILIDAD	Métrica		0.0	5.30	5.43	0.72
PUNTUALIDAD	Métrica		0.0	4.11	3.97	1.12
SEGURIDAD	Métrica		0.0	4.48	3.90	1.31
PRECIO	Métrica		0.0	4.68	5.40	1.49
ATENCION	Métrica		0.0	4.48	4.13	0.94
INNOVACION	Métrica		0.0	3.36	2.90	1.48

Tabla 8.2

El *data frame* resultante tiene 15 filas (una por empresa) y 6 columnas (una por atributo), con los nombres de las empresas como nombres de fila. Las valoraciones oscilan entre 1 y 7, como corresponde a la escala Likert utilizada en la encuesta.

8.4.3 Exploración y número de dimensiones.

La función `lite_emd_dimensiones()` realiza toda la fase exploratoria: muestra los perfiles de valoración, calcula la matriz de proximidades (distancias euclídeas entre los perfiles de cada par de empresas) y estima el EMD no métrico con 1 a 6 dimensiones para ayudarnos a elegir cuántas utilizar. Si no indicamos el argumento `variables`, utiliza todas las columnas del *data frame*:

```
exploracion <- lite_emd_dimensiones(PERCEPCION)
```

Antes de calcular proximidades, conviene examinar los perfiles de valoración de las compañías. La tabla de perfiles recoge los datos de partida:

```
exploracion$tabla_perfiles
```

	FIABILIDAD	PUNTUALIDAD	SEGURIDAD	PRECIO	ATENCION	INNOVACION
arrakis freight	5.43	6.30	5.70	1.80	5.77	6.20
excalibur freight systems	6.43	5.53	6.40	2.20	6.67	5.27
kaiju haulage co.	5.63	5.90	6.43	2.70	5.97	5.80
mothership movers	5.83	4.53	6.03	3.53	4.73	4.10
corellian freightworks	6.40	4.70	6.20	3.70	4.37	4.40
shuttlepod movers	5.67	3.97	3.90	5.13	4.20	3.43
defiant cargo	5.67	3.83	3.87	5.03	4.13	2.90
ragnar freight lines	5.10	4.10	4.83	5.57	4.27	3.17
rebel alliance transport	4.17	4.10	3.47	5.67	4.13	2.87
prometheus transport	5.20	3.53	3.93	5.40	3.70	2.50
dark star haulage	4.83	3.47	2.83	5.83	3.90	1.97
starfighter logistics	5.00	3.23	3.33	5.87	4.07	1.93
endor express	5.47	3.13	3.67	5.53	4.07	1.90
first order cargo	4.90	2.90	2.90	5.70	3.97	1.97
sandworm freight	3.80	2.37	3.77	6.50	3.20	1.93

Tabla 8.3

Un gráfico de **coordenadas paralelas** permite visualizar simultáneamente los seis atributos para cada empresa, revelando patrones de similitud a simple vista:

```
exploracion$perfiles
```

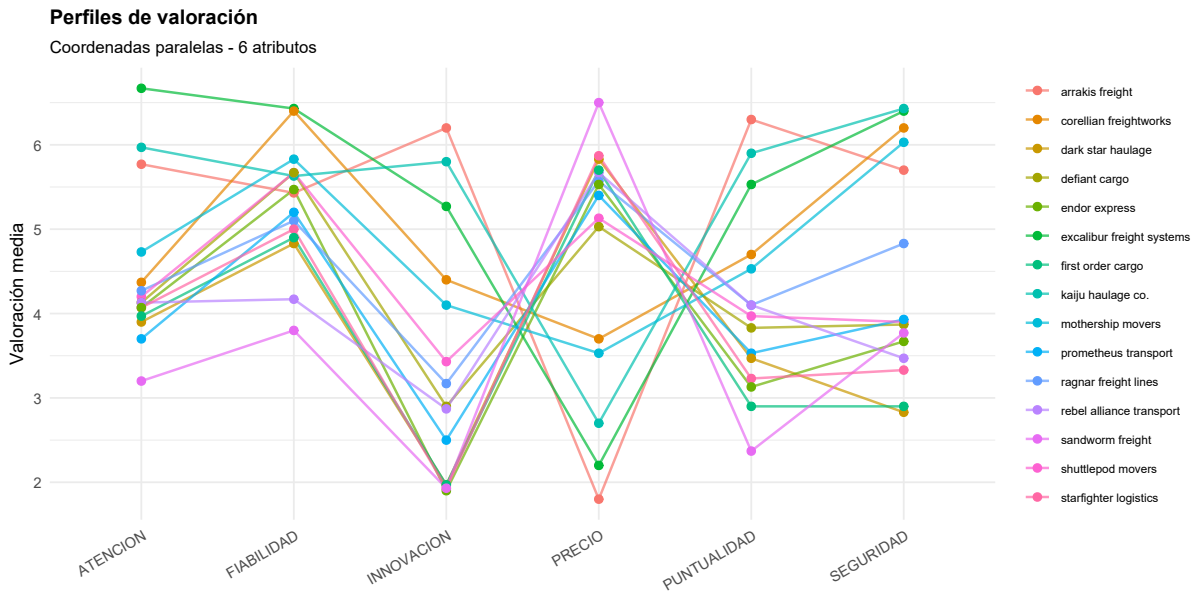


Figura 8.2

El gráfico ya permite intuir la existencia de grupos de empresas con perfiles similares. Se aprecia, por ejemplo, que las compañías con flota renovada (*Arrakis Freight*, *Excalibur Freight Systems*, *Kaiju Haulage Co.*) comparten un perfil característico: valoraciones altas en atención, fiabilidad, innovación y seguridad, pero bajas en precio (son percibidas como caras). En el extremo opuesto, compañías como *Sandworm Freight* o *First Order Cargo* muestran el patrón inverso. Sin embargo, la maraña de líneas resulta difícil de interpretar con 15 compañías. Precisamente para eso sirve el mapa perceptual.

La **matriz de proximidades** contiene las $15 \times 14/2 = 105$ distancias entre todos los pares de empresas, y se visualiza como un **mapa de calor**, donde los tonos anaranjados indican proximidad (empresas percibidas como similares) y los tonos azulados indican distancia:

```
exploracion$distancias
```

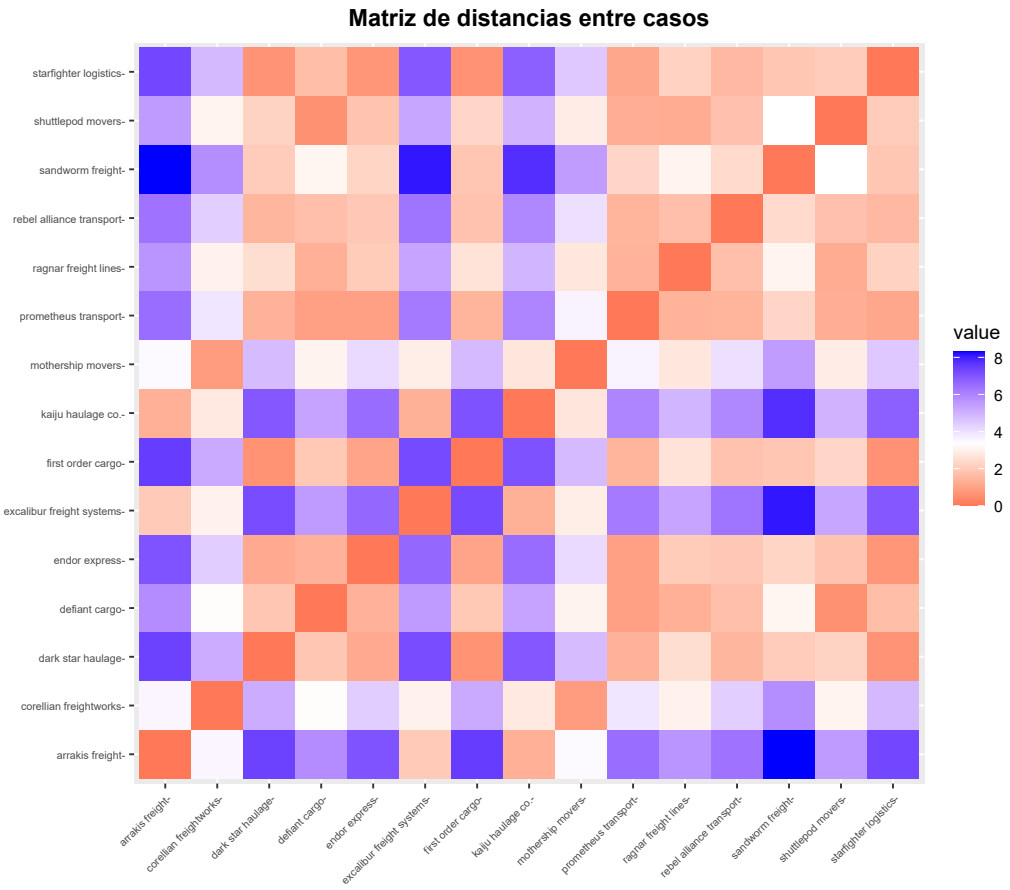


Figura 8.3

El mapa de calor revela patrones interesantes. Compañías como *Shuttlepod Movers* y *Defiant Cargo* presentan tonos anaranjados muy intensos entre sí, lo que indica que los clientes las perciben de manera muy similar. Lo mismo ocurre entre *Starfighter Logistics* y *Endor Express*. En el extremo opuesto, *Sandworm Freight* destaca por su fila y columna dominadas por tonos azulados: es la compañía más «peculiar» del grupo. También se aprecian bloques de color anaranjado entre las grandes empresas de flota renovada, confirmando que los clientes las perciben como un grupo homogéneo.

Pasamos a decidir **cuántas dimensiones** utilizar. Aunque nuestro objetivo final es un mapa bidimensional (el más fácil de interpretar), necesitamos verificar que dos dimensiones son suficientes. La pieza `stress` recoge el Stress de cada solución, con su calificación según la escala de Kruskal, y la pieza `codo`, el gráfico de codo:

```
exploracion$stress
```

Dimensiones	Stress	Calidad
1	0.0422	Excelente
2	0.0196	Perfecta
3	0.0038	Perfecta
4	0.0024	Perfecta
5	0.0010	Perfecta
6	0.0000	Perfecta

Tabla 8.4

```
exploracion$codo
```

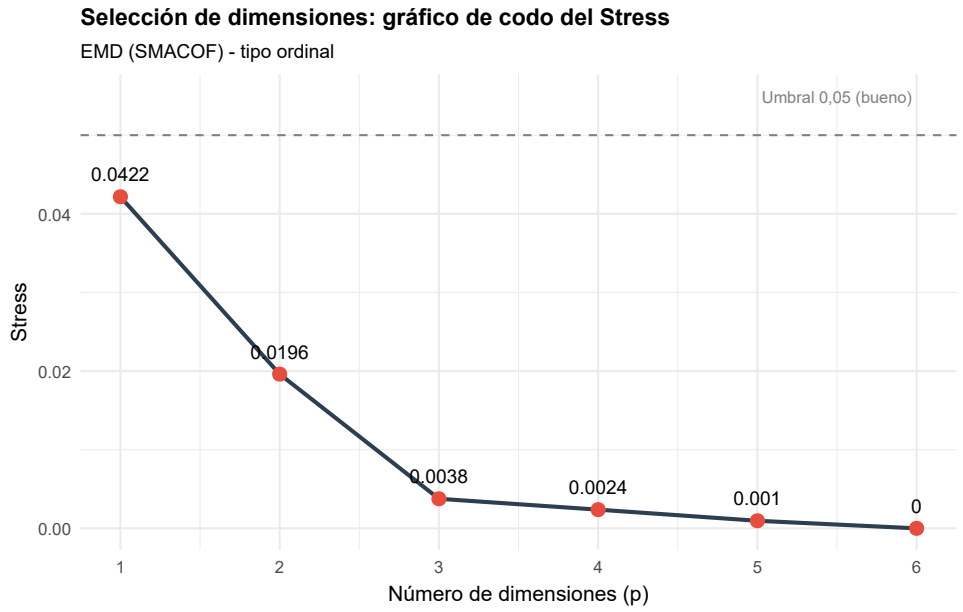


Figura 8.4

El Stress desciende marcadamente al pasar de una a dos dimensiones, y a partir de dos dimensiones la mejora es progresivamente menor. Con dos dimensiones, el Stress (0,0196) se sitúa ya en el rango de calidad **perfecta** de la escala de Kruskal, lo que confirma que **dos dimensiones son suficientes** para representar adecuadamente las proximidades perceptuales.

8.4.4 La solución en dos dimensiones.

Ajustamos el EMD no métrico con dos dimensiones mediante la función `lite_emd()`. El argumento `ndim` fija el número de dimensiones, y `titulo` y `subtitulo` rotulan los mapas:

```
mapa <- lite_emd(PERCEPCION, ndim = 2,
                 titulo    = "SECTOR INTERESTELAR DE TRANSPORTE DE MERCANCÍAS",
                 subtitulo = "Mapa perceptual - Configuración de opiniones de clientes")
```

La pieza `ajuste` muestra el valor del Stress y el número de iteraciones que ha necesitado el algoritmo SMACOF para converger:

```
mapa$ajuste
```

Dimensiones	Stress	Calidad	Iteraciones
2	0.0196	Perfecta	20

Tabla 8.5

Las coordenadas de las 15 empresas en las dos dimensiones son:

```
mapa$coordenadas
```

	D1	D2
arrakis freight	-1.1718	-0.2889
excalibur freight systems	-1.1296	0.0797
kaiju haulage co.	-1.0581	-0.1057
mothership movers	-0.4822	0.1825
corellian freightworks	-0.5177	0.2925
shuttlepod movers	0.1442	-0.0251
defiant cargo	0.2253	0.0121
ragnar freight lines	0.1302	0.1224
rebel alliance transport	0.3663	-0.2313
prometheus transport	0.3642	0.0202
dark star haulage	0.5826	-0.1160
starfighter logistics	0.5496	-0.0130
endor express	0.4842	0.0661
first order cargo	0.6190	-0.0582
sandworm freight	0.8937	0.0626

Tabla 8.6

8.4.5 Diagrama de Shepard.

Para evaluar visualmente la calidad del ajuste, examinamos el **diagrama de Shepard**, que enfrenta las proximidades originales (eje horizontal) con las distancias obtenidas en la configuración bidimensional (eje vertical):

```
mapa$shepard
```

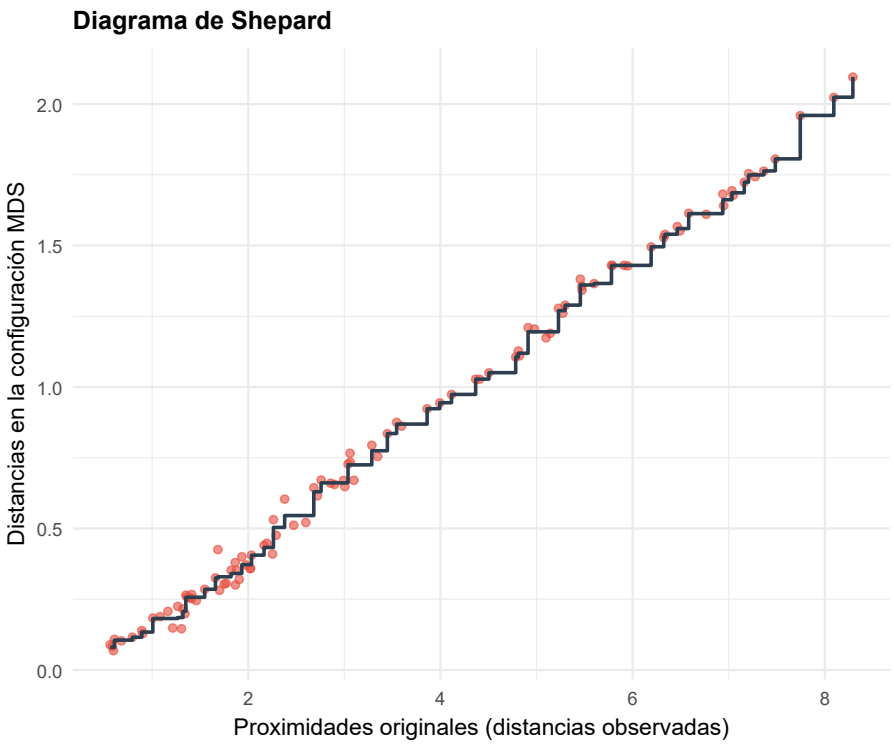


Figura 8.5

La línea escalonada es la **función de transformación monótona** que el algoritmo ha encontrado para relacionar las proximidades con las distancias. En el EMD no métrico, esta función no necesita ser lineal: solo necesita ser no decreciente. Los puntos representan los 105 pares de empresas: cuanto más cerca estén de la línea, mejor es el ajuste para ese par concreto. En nuestro caso, todos siguen de cerca la tendencia, en coherencia con el reducido valor del Stress.

8.4.6 El mapa perceptual.

Estamos en condiciones de examinar el mapa perceptual. Las empresas cercanas en el mapa son percibidas de forma similar por los clientes; las lejanas, de forma diferente:

```
mapa$mapa
```

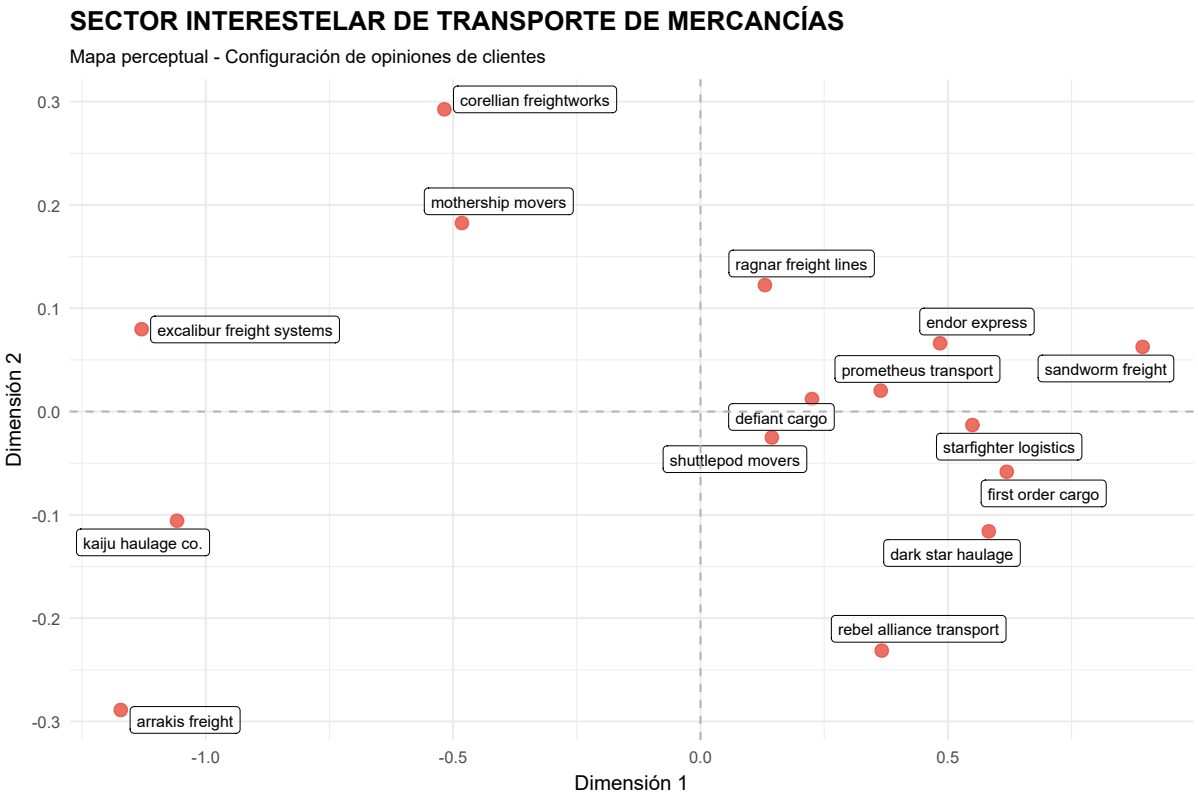


Figura 8.6

El mapa confirma y enriquece lo que el mapa de calor ya apuntaba. Las grandes compañías con flota renovada (*Arrakis Freight*, *Excalibur Freight Systems*, *Kaiju Haulage Co.*) se agrupan en la zona izquierda del mapa, claramente separadas del resto. Las compañías con flota antigua (*Sandworm Freight*, *First Order Cargo*, *Dark Star Haulage*, *Endor Express*, *Starfighter Logistics*) ocupan la zona derecha. Entre ambos grupos, las compañías con flota madura (*Shuttlepod Movers*, *Defiant Cargo*, *Ragnar Freight Lines*, *Prometheus Transport*, *Rebel Alliance Transport*) se sitúan en posiciones intermedias. Nótese también cómo las empresas que en el mapa de calor aparecían con tonos anaranjados intensos entre sí (*Shuttlepod Movers* y *Defiant Cargo*, por ejemplo) están ahora efectivamente muy próximas en el mapa, y cómo *Sandworm Freight* ocupa el extremo derecho, aislada de las demás.

Pero las dimensiones en sí mismas no tienen un significado predeterminado: el EMD nos dice *dónde* se sitúan las empresas, pero no *por qué* están ahí. Para responder a esta segunda pregunta, necesitamos interpretar las dimensiones.

8.4.7 Interpretación de las dimensiones.

Para averiguar qué representan las dos dimensiones, se calcula la **correlación** entre cada atributo original y las coordenadas de las empresas en cada dimensión. Los atributos con mayor correlación (en valor absoluto) con una dimensión nos indican qué está midiendo ese eje:

```
mapa$correlaciones
```

	Dim.1	Dim.2
FIABILIDAD	-0.702	0.441
PUNTUALIDAD	-0.969	-0.207
SEGURIDAD	-0.916	0.309
PRECIO	0.986	0.063
ATENCION	-0.927	-0.155
INNOVACION	-0.980	-0.112

Tabla 8.7

Para facilitar la lectura, la pieza `biplot` superpone los atributos como **vectores** sobre el mapa perceptual. La dirección del vector indica con qué dimensiones se asocia el atributo; su longitud, la intensidad de esa asociación:

```
mapa$biplot
```

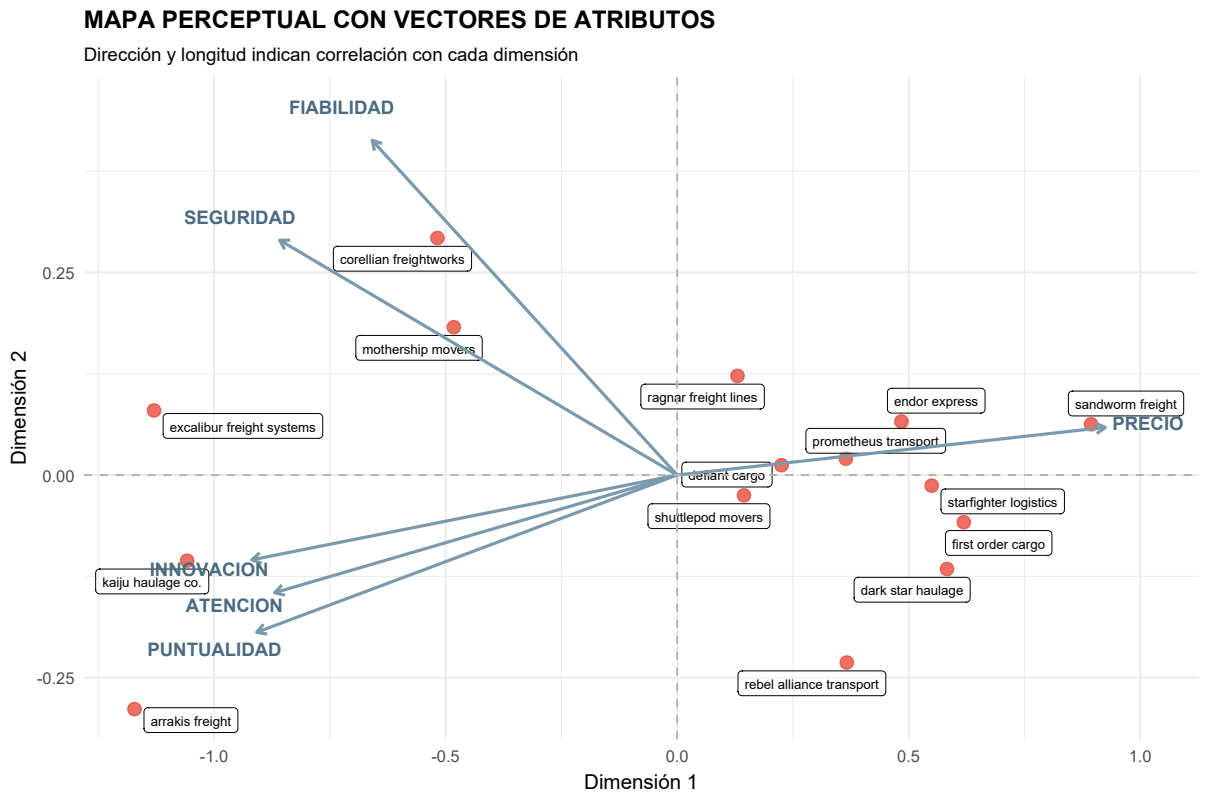


Figura 8.7

Este es el gráfico central del análisis, y su lectura permite al equipo de *Data-Evidence* interpretar las dimensiones latentes y extraer conclusiones sobre la estructura competitiva del sector.

La **Dimensión 1** (eje horizontal) es la que mayor variabilidad recoge, y separa las compañías esencialmente por un eje de **calidad percibida frente a precio**. Los vectores de INNOVACION, PUNTUALIDAD, ATENCION, SEGURIDAD y FIABILIDAD apuntan hacia la izquierda, donde se sitúan las compañías mejor valoradas en estos atributos (*Arrakis Freight*, *Excalibur Freight Systems*, *Kaiju Haulage Co.*). El vector de PRECIO (correlación de 0,986 con la dimensión) apunta en

la dirección opuesta, hacia la derecha, donde están las compañías percibidas como más económicas pero con peor servicio (*Sandworm Freight*, *First Order Cargo*). Esta dimensión refleja, por tanto, un continuo que va de «caro pero excelente» a «económico pero deficiente».

La **Dimensión 2** (eje vertical) introduce un matiz adicional: FIABILIDAD y SEGURIDAD apuntan hacia arriba, mientras que PUNTUALIDAD y ATENCION lo hacen ligeramente hacia abajo. Esto distingue, dentro de las compañías de calidad similar, entre aquellas que destacan por la seguridad e integridad de la carga (zona superior: *Corellian Freightworks*, *Mothership Movers*) y las que destacan más por la puntualidad y la atención al cliente (zona inferior: *Arrakis Freight*, *Kaiju Haulage Co.*).

8.4.8 Ampliación: la solución en tres dimensiones.

El gráfico de codo mostró que dos dimensiones proporcionan un ajuste satisfactorio. Sin embargo, puede resultar instructivo explorar qué aporta una **tercera dimensión** al análisis. Basta con cambiar el argumento `ndim`:

```
mapa3 <- lite_emd(PERCEPCION, ndim = 3)
```

```
mapa3$ajuste
```

Dimensiones	Stress	Calidad	Iteraciones
3	0.0038	Perfecta	12

Tabla 8.8

```
mapa3$correlaciones
```

	Dim.1	Dim.2	Dim.3
FIABILIDAD	-0.696	0.491	0.490
PUNTUALIDAD	-0.966	-0.196	-0.008
SEGURIDAD	-0.924	0.308	-0.201
PRECIO	0.984	0.047	-0.099
ATENCION	-0.920	-0.152	0.211
INNOVACION	-0.984	-0.104	-0.101

Tabla 8.9

El Stress baja hasta 0,0038, y las correlaciones de las dos primeras dimensiones apenas cambian. La tercera dimensión recoge, sobre todo, la **FIABILIDAD** (correlación de 0,49) y, en menor medida, la ATENCION: un aspecto de la percepción que no quedaba del todo representado con solo dos ejes.

Con tres dimensiones existen tres combinaciones posibles de pares de ejes: D1-D2, D1-D3 y D2-D3. Cada combinación genera un mapa perceptual que muestra una proyección distinta de las posiciones de las compañías. La pieza `mapas` los reúne en una sola composición:

```
mapa3$mapas[[1]]
```

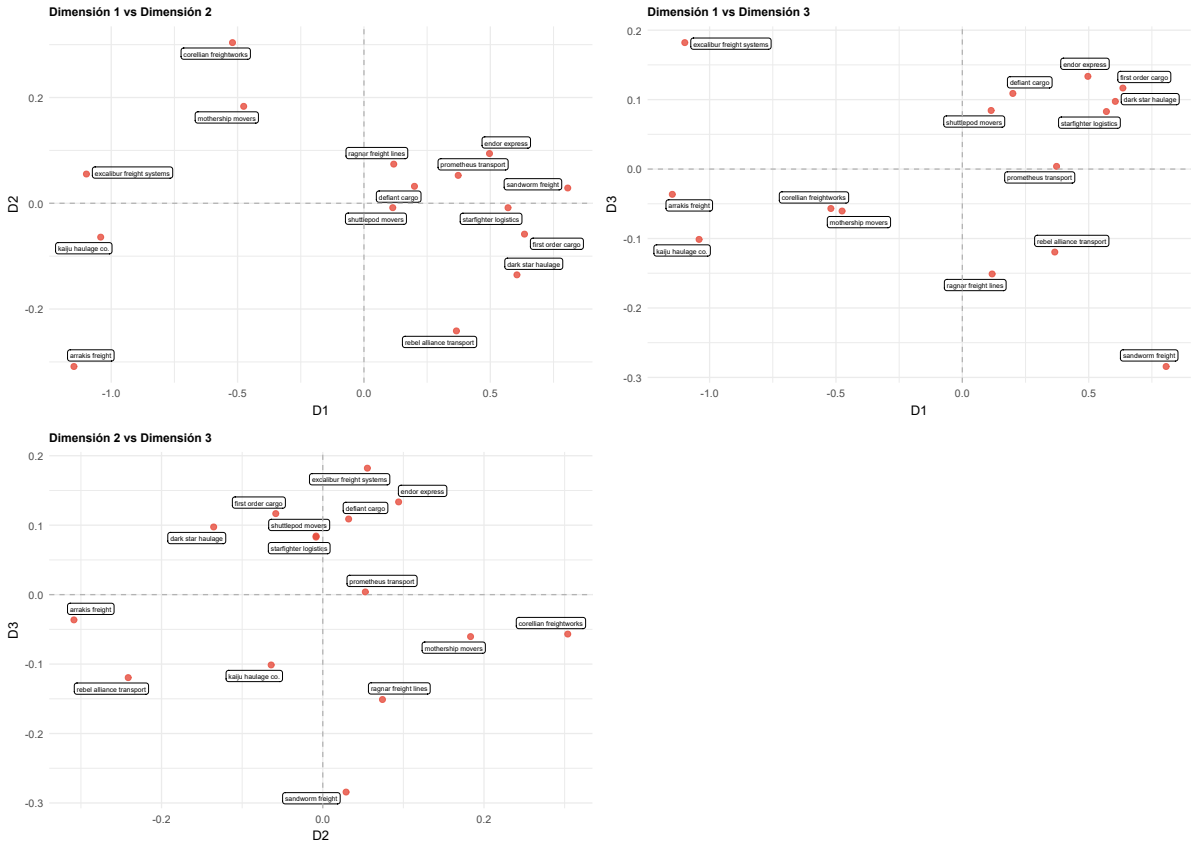


Figura 8.8

La lectura conjunta de los tres paneles revela información que el mapa bidimensional no podía mostrar por sí solo:

- **Panel D1–D2** (arriba a la izquierda): reproduce la estructura principal del análisis bidimensional. Los grupos de compañías (RENOVADA a la izquierda, ANTIGUA a la derecha, MADURA en el centro) se mantienen estables, lo que indica que las dos primeras dimensiones son robustas.
- **Panel D1–D3** (arriba a la derecha): la tercera dimensión reorganiza verticalmente a las compañías. El cambio más llamativo afecta a las compañías de flota antigua: *Endor Express*, *First Order Cargo*, *Starfighter Logistics* y *Dark Star Haulage*, que en el plano D1-D2 aparecían como un grupo relativamente compacto, se separan ahora en el eje D3. Esto indica que, aunque todas sean percibidas como «económicas», los clientes detectan diferencias entre ellas, relacionadas sobre todo con la fiabilidad.
- **Panel D2–D3** (abajo a la izquierda): al prescindir de la primera dimensión (la de mayor variabilidad), este plano aísla los matices más finos de la percepción. Aquí se aprecia cómo compañías que en los otros paneles se solapaban (por compartir valores similares en D1) se diferencian en las dimensiones secundarias.

8.5 Cierre: el informe de *Data-Evidence*.

El equipo de *Data-Evidence* presenta su mapa perceptual ante la Asamblea General de la ASTI —por boca de la propia **Li Ti-Oh**, directora ejecutiva de la consultora, que para la ocasión solo tuvo que cruzar el desierto de Tatooine— con tres conclusiones principales:

1. **El sector no es percibido como homogéneo: existen grupos de posicionamiento claramente diferenciados.** Lejos de la percepción generalizada de que «todas las navieras son iguales», el mapa revela al menos tres perfiles perceptuales distintos, organizados en torno a dos dimensiones latentes que los clientes utilizan intuitivamente para evaluar a las compañías. Las grandes corporaciones con flota renovada se agrupan en una zona del mapa claramente diferenciada de las compañías de flota antigua, y a su vez de las empresas con flota madura que ocupan posiciones intermedias.
2. **Las dimensiones latentes del mapa perceptual revelan los ejes de diferenciación que el sector debería comunicar.** La calidad del servicio frente al precio es el eje principal; la seguridad y fiabilidad frente a la puntualidad y la atención, el secundario. Las compañías que deseen reposicionarse deben trabajar sobre los atributos que definen estas dimensiones.
3. **El mapa identifica oportunidades de nicho.** Las zonas del espacio perceptual con baja densidad de competidores representan posiciones de mercado no cubiertas. Una compañía que logre ubicarse en una de estas zonas tendría una ventaja competitiva perceptual sobre las demás.

Cuentan las crónicas que, tras la presentación, varias compañías del sector solicitaron a *Data-Evidence* estudios de reposicionamiento individuales. Que *Tasha Tachybaptus*, CEO de *Shuttlepod Movers*, tomó nota de la posición de su empresa en el mapa y comentó que «ahora entiendo por qué nos comparan con *Defiant Cargo*, y también por qué no nos comparan con *Arrakis*». Y que *Arg-us Korp*, que no aparecía en el estudio pero había leído con atención el informe, murmuró: «*Interesante... si yo estuviera en ese mapa, ¿dónde me colocaría?*». Li Ti-Oh, que alcanzó a oírle, se limitó a responder: «*En la zona de baja densidad, señor Korp. Siempre en la zona de baja densidad.*»

8.6 Materiales para realizar las prácticas del capítulo.

En esta sección se muestran los links de acceso a los diferentes materiales (*scripts*, datos...) necesarios para llevar a cabo los contenidos prácticos del capítulo.

Datos (en formato Microsoft® Excel®):

- percepcion_interestelar.xlsx (obtener aquí), o bien, desde R: `lite_datos("percepcion_interestelar")`

Script:

- emd_lite.R (obtener aquí)

Bibliografía

Aggarwal, C. C. 2015. *Data Mining: The Textbook*. Cham: Springer. https://doi.org/10.1007/978-3-319-14142-8.

Jain, A. K. 2010. «Data Clustering: 50 Years Beyond K-Means». *Pattern Recognition Letters* 31 (8): 651-66. https://doi.org/10.1016/j.patrec.2009.09.011.

Kaufman, L., y P. J. Rousseeuw. 1990. *Finding Groups in Data: An Introduction to Cluster Analysis*. Wiley Series en Probability y Mathematical Statistics. New York: John Wiley & Sons.

Mood, A. M., y F. A. Graybill. 1963. *Introduction to the Theory of Statistics (2nd Edition)*. Mc Graw-Hill.

Rubin, D. B. 1976. «Inference and Missing Data». *Biometrika* 63 (3): 581-92. https://doi.org/10.1093/biomet/63.3.581.

———. 1987. *Multiple Imputation for Nonresponse in Surveys*. Wiley Series en Probability y Mathematical Statistics. New York: John Wiley & Sons. https://doi.org/10.1002/9780470316696.

Xu, R., y D. Wunsch. 2005. «Survey of Clustering Algorithms». *IEEE Transactions on Neural Networks* 16 (3): 645-78. https://doi.org/10.1109/TNN.2005.845141.

Apéndice: Guía de uso de `MATlite`.

Qué es `MATlite` y cómo funciona.

`MATlite` es el paquete de R de la asignatura. Reúne en un pequeño número de funciones, todas con el prefijo `lite_`, el código que en *R-Stars: La Guía* ocupa decenas de líneas por técnica. Las funciones reproducen los mismos cálculos y los mismos resultados que los *scripts* de La Guía, de modo que el usuario puede concentrarse en **interpretar** los resultados.

`MATlite` no está en CRAN. Se instala desde GitHub, una sola vez:

```
# install.packages("remotes")          # solo si no está instalado
remotes::install_github("teckel71/MATlite")
```

Al instalarlo se instalan también, automáticamente, los paquetes de los que depende (entre ellos, `{MATrstars}`, el paquete de funciones auxiliares de La Guía). En cada sesión de trabajo basta con activarlo:

```
library(MATlite)
```

El código fuente del paquete está en https://github.com/teckel71/MATlite.

Tres ideas para usar el paquete.

1. **Se ejecuta la función una vez y se guarda el resultado en un objeto.** Por ejemplo: `componentes <- lite_acp(seleccion_so)`.
2. **Escribir el nombre del objeto lo muestra todo.** Las tablas aparecen juntas en el panel *Viewer* de RStudio y los gráficos, en el panel *Plots* (con las flechas de ese panel se pasa de uno a otro). En la consola aparece, además, un índice de las piezas que contiene el objeto.
3. **Cada resultado es una "pieza" del objeto, a la que se accede con `$`.** Por ejemplo, `componentes$cargas` muestra solo la tabla de cargas. Algunas piezas son, a su vez, listas (por ejemplo, la composición de cada grupo de un clúster); sus elementos se muestran con dobles corchetes: `grupos$composicion[[1]]`.

Las variables se indican siempre **sin comillas** (`RENECO`, `c(RENECO, ACTIVO)`), y si una función admite el argumento `variables` y no se indica, utiliza todas las variables numéricas del *data frame*. Para consultar la ayuda de cualquier función, basta con anteponerle una interrogación: `?lite_logit`.

Mapa de funciones.

Capítulo	Funciones
1. Introducción	`lite_comprueba()`, `lite_datos()`
2. Datos	`lite_importa()`, `lite_resumen()`, `select()`, `filter()`, `arrange()`, `mutate()`, `%>%`
3. Análisis previo	`lite_na()`, `lite_outliers()`, `lite_describe()`, `lite_correlaciones()`
4. Componentes principales	`lite_acp()`, `lite_acp_ranking()`
5. Clúster jerárquico	`lite_cluster_ward()`
6. Elección discreta	`lite_factor()`, `lite_logit_descriptivo()`, `lite_particion()`, `lite_logit()`, `lite_logit_escenarios()`, `lite_logit_seleccion()`
7. Tablas de contingencia	`lite_recodifica()`, `lite_contingencia()`
8. Escalado multidimensional	`lite_emd_dimensiones()`, `lite_emd()`
Auxiliares	`lite_tabla()`, `lite_patchwork()`

Tabla A.1

Funciones generales.

`lite_comprueba()`.

Para qué sirve. Comprueba que la instalación está completa: versión de R, paquetes necesarios y ficheros de datos presentes en la carpeta de trabajo. Para cada problema, indica la instrucción que lo resuelve. Conviene ejecutarla la primera vez.

```
lite_comprueba()
```

Argumentos. No tiene.

Devuelve. Una tabla con el resultado de cada comprobación (en la consola).

`lite_datos()`.

Para qué sirve. Descarga los ficheros de datos del libro a la carpeta de trabajo.

```
lite_datos()                              # descarga todos
lite_datos("interestelar_100")            # descarga uno
lite_datos(c("interestelar_25", "interestelar_300"))
```

Argumentos.

- `nombre`: nombre de uno o varios ficheros, con o sin `.xlsx`. Si se omite, se descargan todos.
- `destino`: carpeta de destino. Por defecto, la carpeta de trabajo.

`lite_importa()`.

Para qué sirve. Importa una hoja de un fichero Excel y, si se desea, convierte la primera columna en nombres de fila (los nombres de las empresas).

```
interestelar_100 <- lite_importa("interestelar_100.xlsx")
```

Argumentos.

- `archivo`: nombre (o ruta) del fichero Excel.
- `hoja`: nombre o número de la hoja. Por defecto, `"Datos"`.
- `na`: texto que debe leerse como valor ausente. Por defecto, `"n.d."`.
- `nombres_fila`: si es `TRUE` (por defecto), la primera columna pasa a ser el nombre de las filas.

Devuelve. Un *data frame*.

`lite_resumen()`.

Para qué sirve. Presenta un resumen visual de todas las variables de un *data frame*: tipo, gráfico de distribución, porcentaje de valores ausentes y estadísticos básicos.

```
lite_resumen(interestelar_100)
```

Argumentos. `datos` (*data frame*) y `titulo` (opcional; por defecto, el nombre del *data frame*).

Verbos de `{dplyr}`.

Al activar `MATlite` quedan disponibles, sin cargar otros paquetes, el operador `%>%` y los verbos de `{dplyr}` utilizados en el libro: `select()` (seleccionar variables), `filter()` (seleccionar casos), `arrange()` y `desc()` (ordenar), `mutate()` (crear o transformar variables), `rename()`, `slice()`, `group_by()` y `summarise()`. Su uso se explica en el capítulo 2.

Análisis previo de datos.

`lite_na()`.

Para qué sirve. Localiza los valores ausentes (*missing values*): muestra un mapa de ausencias y una tabla con los casos afectados. Opcionalmente, elimina esos casos.

```
muestra <- lite_na(muestra, RENECO, accion = "eliminar")
```

Argumentos.

- `datos`: *data frame*.
- `variables`: variables a analizar, sin comillas. Si se omiten, todas.
- `accion`: `"documentar"` (por defecto) solo muestra el diagnóstico; `"eliminar"` además quita los casos con algún valor ausente.
- `titulo`, `subtitulo`: títulos del gráfico.

Devuelve. El *data frame* (sin cambios, o sin los casos con valores ausentes). Si no hay valores ausentes, solo muestra un mensaje.

`lite_outliers()`.

Para qué sirve. Localiza los valores extremos (*outliers*). Con una variable aplica la regla de 1,5 veces el recorrido intercuartílico sobre un *box-plot*; con varias, la aplica sobre la distancia de Mahalanobis (*outliers* multivariantes). Opcionalmente, los elimina.

```
muestra_so   <- lite_outliers(muestra, RENECO, accion = "eliminar")
seleccion_so <- lite_outliers(seleccion, accion = "eliminar")   # Mahalanobis
```

Argumentos. Los mismos que `lite_na()`, más `escala`: `"auto"` (por defecto), `"lineal"` o `"pseudo_log"`, para el eje del *box-plot*.

Devuelve. El *data frame* (sin cambios, o sin los *outliers*).

`lite_describe()`.

Para qué sirve. Describe una variable métrica: distribución de frecuencias, estadísticos, contraste de normalidad de Shapiro-Wilk y cuatro gráficos.

```
descriptivo <- lite_describe(muestra_so, RENECO,
                             etiqueta = "Rentabilidad Económica (%)")
```

Argumentos.

- `datos`, `variable`: *data frame* y variable a describir.
- `intervalos`: número de intervalos de la distribución de frecuencias y del histograma: `"sturges"` (por defecto), `"fd"` (Freedman-Diaconis) o un número.
- `etiqueta`: texto para los ejes. Por defecto, el nombre de la variable.
- `titulo`, `subtitulo`: títulos del resumen gráfico.

Piezas. `$frecuencias`, `$estadisticos`, `$normalidad` (tablas); `$histograma`, `$densidad`, `$boxplot`, `$qq` y `$resumen` (los cuatro gráficos juntos).

`lite_correlaciones()`.

Para qué sirve. Construye la matriz gráfica de correlaciones de Pearson, con la significación de cada coeficiente. Opcionalmente, la compara con la de otro *data frame* (por ejemplo, el que aún conserva los *outliers*).

```
correlaciones <- lite_correlaciones(muestra2_so, comparar_con = muestra2)
```

Argumentos.

- `datos`, `variables`.
- `comparar_con`: *data frame* opcional para la comparación.
- `titulo`, `titulo_comparacion`: títulos de las dos matrices.

Piezas. `$matriz` (tabla de coeficientes), `$grafico` y, si hay comparación, `$grafico_comparacion` y `$comparacion` (las dos matrices lado a lado).

Componentes principales.

`lite_acp()`.

Para qué sirve. Realiza el análisis de componentes principales con las variables tipificadas: adecuación muestral (KMO y MSA, con la escala de Kaiser), varianza explicada, cargas, autovalores y número de componentes a retener (criterio del autovalor mayor que 1).

```
componentes <- lite_acp(seleccion_so)
```

Argumentos. `datos`, `variables` y `subtitulo` (de los gráficos).

Piezas. `$kmo`, `$varianza`, `$cargas`, `$autovalores`, `$retencion` (tablas); `$grafico_autovalores` y `$grafico_acumulada` (gráficos); `$n_retener` (número de componentes con autovalor mayor o igual que 1); `$modelo` (el objeto de R con el análisis completo).

`lite_acp_ranking()`.

Para qué sirve. Ordena los casos según su puntuación en una componente y presenta los primeros en una tabla y un gráfico.

```
ranking <- lite_acp_ranking(componentes, componente = 1, n = 10)
```

Argumentos.

- `acp`: resultado de `lite_acp()`.

- `datos`: *data frame* opcional con los casos que se quieren puntuar (por ejemplo, la selección que aún conserva los *outliers*). Si se omite, se usan los casos con que se calcularon las componentes.
- `componente`: número de la componente. Por defecto, 1.
- `n`: número de casos del ranking. Por defecto, 10.
- `etiquetas`, `caption`: nombres para las variables y título de la tabla.

Piezas. `$ranking` (tabla), `$grafico` y `$puntuaciones` (todas las puntuaciones).

Análisis clúster jerárquico.

`lite_cluster_ward()`.

Para qué sirve. Realiza el análisis clúster jerárquico con el método de Ward sobre las variables tipificadas. Se usa en dos fases:

1. **Exploración** (sin `k`): matriz de distancias, dendrograma y número de grupos sugerido por el método de la silueta.
2. **Resultados** (con `k`, el número de grupos decidido): grupos marcados en el dendrograma, centroides, composición de cada grupo y gráficos.

```
exploracion <- lite_cluster_ward(seleccion)          # fase 1
grupos      <- lite_cluster_ward(seleccion, k = 5)   # fase 2
```

Argumentos.

- `datos`, `variables`.
- `k`: número de grupos. Si se omite, solo se hace la exploración.
- `k_max`: número máximo de grupos que se prueba con la silueta. Por defecto, 15.
- `titulo`, `subtitulo`: títulos de los dendrogramas.
- `subtitulo_graficos`: subtítulo de los gráficos de medias y dispersión.

Piezas. En la exploración: `$distancias`, `$dendrograma`, `$silueta` y `$k_sugerido`. En los resultados: `$dendrograma`, `$centroides`, `$graficos_centroides`, `$composicion` (lista, un elemento por grupo), `$dispersion` y `$datos` (el *data frame* con una nueva columna, `grupo`). Los grupos se numeran de izquierda a derecha según el dendrograma.

Modelos de elección discreta.

`lite_factor()`.

Para qué sirve. Convierte una variable en factor y fija su categoría de referencia. Muestra en la consola la codificación de las variables *dummy*.

```
LICENCIAS <- lite_factor(LICENCIAS, EFLO, niveles = c("ANTIGUA", "MADURA", "RENOVADA"))
```

Argumentos.

- `datos`, `variable`.
- `niveles`: orden de las categorías (opcional). La primera es la referencia.
- `referencia`: categoría de referencia (opcional; alternativa a `niveles`).

Devuelve. El *data frame* con la variable convertida.

`lite_logit_descriptivo()`.

Para qué sirve. Compara los dos grupos que define la variable dependiente antes de estimar el modelo: tablas cruzadas y gráficos de barras para las variables categóricas, y medias por grupo para las métricas.

```
descriptivo <- lite_logit_descriptivo(LICENCIAS, LICENCIA,
                                      etiquetas = c("0" = "Denegada", "1" = "Concedida"))
```

Argumentos.

- `datos`, `dependiente`.
- `variables`: explicativas a describir. Si se omiten, todas (salvo las categóricas con más de 10 categorías).
- `etiquetas`: nombres para las dos categorías de la dependiente.

Piezas. `$dependiente`, `$cruzadas` (lista, una tabla por variable categórica), `$graficos_categoricas`, `$medias` y `$graficos_metricas` (lista de composiciones).

`lite_particion()`.

Para qué sirve. Divide los datos en una muestra de estimación y una de test. Por defecto, la partición es secuencial (los `n_estimacion` primeros casos para estimar); con `aleatoria = TRUE`, aleatoria.

```
muestras <- lite_particion(LICENCIAS, n_estimacion = 80, dependiente = LICENCIA)
```

Argumentos. `datos`, `n_estimacion`, `dependiente` (opcional, para mostrar su distribución en cada muestra), `aleatoria` (por defecto, `FALSE`) y `semilla` (por defecto, 123).

Piezas. `$resumen`, `$estimacion` y `$test` (los dos *data frames*).

`lite_logit()`.

Para qué sirve. Estima un modelo logit binomial y presenta todos sus resultados. Muestra en la consola la especificación estimada.

```
completo <- lite_logit(muestras$estimacion, LICENCIA,
                       explicativas = c(SOLVENCIA, IPUNT, TINCID, EFLO),
                       test = muestras$test)
```

Argumentos.

- `datos`: *data frame* de estimación.
- `dependiente`: variable dependiente con dos categorías. Se modeliza la probabilidad de la segunda (por ejemplo, el 1 en una variable 0/1).
- `explicativas`: variables explicativas, por ejemplo `c(SOLVENCIA, IPUNT, EFLO)`.
- `test`: *data frame* de test (opcional).
- `umbral`: probabilidad a partir de la cual un caso se clasifica como "éxito". Por defecto, 0,5.

Piezas. `$coeficientes` (con el contraste de Wald individual), `$wald_factores` (contraste de Wald conjunto de los factores con más de dos categorías), `$odds` (*odd ratios*), `$ajuste` (pseudo R^2 de Nagelkerke, AIC, devianzas), `$devianza` (análisis de la devianza), `$aic`, `$confusion` y `$confusion_test` (matrices de confusión), `$modelo` (el objeto de R con el modelo).

`lite_logit_escenarios()`.

Para qué sirve. Calcula la probabilidad estimada, su intervalo de confianza y la clasificación para unos casos hipotéticos (escenarios) definidos en una hoja de Excel. La hoja debe tener una columna identificativa y una columna por cada variable explicativa del modelo, con los mismos nombres.

```
escenarios <- lite_logit_escenarios(completo, "escenarios_logit_rstars.xlsx")
```

Argumentos.

- `logit`: resultado de `lite_logit()` o de `lite_logit_seleccion()`.
- `archivo`, `hoja` (por defecto, `"Escenarios"`) e `id` (columna identificativa; por defecto, `"ESCENARIO"`).
- `umbral`: por defecto, el del modelo.
- `nivel`: nivel de confianza del intervalo. Por defecto, 0,95.

Piezas. `$tabla` y `$datos`.

`lite_logit_seleccion()`.

Para qué sirve. Busca una especificación más sencilla del modelo con el algoritmo *step* (eliminación sucesiva de variables según el AIC) y la compara con el modelo de partida.

```
reducido <- lite_logit_seleccion(completo)
```

Argumentos. `logit` (resultado de `lite_logit()`) y `mostrar_pasos` (si es `TRUE`, por defecto, muestra cada paso en la consola).

Piezas. Las mismas que `lite_logit()`, para el modelo reducido, más `$comparacion` (modelo de partida frente a reducido).

Tablas de contingencia.

`lite_recodifica()`.

Para qué sirve. Cambia el nombre de algunas categorías de una variable. Las categorías no mencionadas se mantienen.

```
seleccion <- lite_recodifica(seleccion, GALAXIA,
                             c("Galaxia de Andrómeda" = "Andrómeda"))
```

Argumentos. `datos`, `variable` y `cambios`: vector de la forma `c("nombre actual" = "nombre nuevo", ...)`.

Devuelve. El *data frame* con la variable recodificada.

`lite_contingencia()`.

Para qué sirve. Analiza la asociación entre dos atributos: tabla de contingencia, gráficos de mosaico y de barras, contraste ji-cuadrado de independencia, residuos estandarizados ajustados, gráfico de asociación y medidas de asociación.

```
galaxia_fjur <- lite_contingencia(seleccion, GALAXIA, FJUR)
```

Argumentos.

- `datos`, `fila`, `columna`: *data frame* y atributos de filas y columnas.
- `alfa`: nivel de significación. Por defecto, 0,05.
- `titulo`, `subtitulo`: títulos de los gráficos.

Piezas. `$tabla`, `$mosaico`, `$barras`, `$chi2`, `$esperadas` (frecuencias esperadas bajo independencia), `$residuos`, `$asociacion` y `$medidas` (coeficiente de contingencia C, su máximo y su valor corregido, V de Cramér y, en tablas 2×2, Phi).

Escalado multidimensional.

`lite_emd_dimensiones()`.

Para qué sirve. Fase exploratoria del escalado multidimensional: perfiles de los casos, matriz de distancias euclídeas y Stress de las soluciones de 1 a `max_dim` dimensiones, con su calificación según la escala de Kruskal.

```
exploracion <- lite_emd_dimensiones(PERCEPCION)
```

Argumentos.

- `datos`, `variables`: *data frame* con los atributos de cada caso.
- `max_dim`: número máximo de dimensiones. Por defecto, 6.
- `tipo`: `"ordinal"` (EMD no métrico, por defecto) o `"interval"`/`"ratio"` (métrico).

Piezas. `$tabla_perfiles`, `$perfiles`, `$distancias`, `$stress` y `$codo`.

`lite_emd()`.

Para qué sirve. Obtiene la solución del escalado multidimensional en el número de dimensiones elegido y construye el mapa perceptual.

```
mapa <- lite_emd(PERCEPCION, ndim = 2)
```

Argumentos. `datos`, `variables`, `ndim` (por defecto, 2), `tipo` (por defecto, `"ordinal"`), y `titulo` y `subtitulo` del mapa.

Piezas. `$ajuste` (Stress e iteraciones), `$coordenadas`, `$shepard`, `$correlaciones` (atributos frente a dimensiones) y, con dos dimensiones, `$mapa` y `$biplot` (mapa con los vectores de los atributos); con tres o más, `$mapas` (los mapas de cada par de dimensiones). `$modelo` guarda el objeto de R con la solución.

Funciones auxiliares.

`lite_tabla()`.

Para qué sirve. Presenta un *data frame* o una matriz como tabla con el estilo del libro.

```
lite_tabla(head(interestelar_100), caption = "Primeras empresas", digits = 2)
```

Argumentos. `x` (*data frame* o matriz) y, opcionalmente, `caption` (título), `col.names` (nombres de las columnas) y `digits` (decimales).

`lite_patchwork()`.

Para qué sirve. Agrupa una lista de gráficos en composiciones de 2×2 (cuatro gráficos por composición). Es la función que usan internamente otras funciones del paquete para presentar baterías de gráficos.

```
composiciones <- lite_patchwork(lista_de_graficos)
composiciones
```

Argumentos. `graficos`: lista de gráficos `ggplot`.

Devuelve. Una lista de composiciones, que se muestran todas al escribir el nombre del objeto.

Licencia

Esta obra de **Miguel Ángel Tarancón Morán** está publicada bajo una Licencia Creative Commons Atribución-NoComercial-SinDerivadas 4.0 Internacional (CC BY-NC-ND 4.0).

Esto significa que usted puede **descargar, leer, imprimir y compartir** libremente esta obra, siempre que:

- **Cite** al autor y la fuente de forma adecuada.
- **No la utilice con fines comerciales.**
- **No distribuya versiones modificadas** de la misma.

Para usos que excedan estos términos (uso comercial, traducciones, adaptaciones, etc.), contacte con el autor en miguelangel.tarancon@uclm.es.

Cita sugerida

> Tarancón Morán, M. Á. (2026). *R-Stars Lite*. Disponible en https://teckel71.github.io/RStarslite-book/.

BibTeX

```
@book{tarancon2026RStarsLite,
  author = {Tarancón Morán, Miguel Ángel},
  title  = {R-Stars Lite},
  year   = {2026},
  url    = {https://teckel71.github.io/RStarslite-book/},
  note   = {Licencia CC BY-NC-ND 4.0}
}
```

El texto completo de la licencia puede consultarse en el archivo `LICENSE.md` del repositorio o en https://creativecommons.org/licenses/by-nc-nd/4.0/legalcode.es.